



Εισαγωγή στη Βιοπληροφορική

Ακαδημαϊκό Έτος 2025-2026

ΤΕΧΝΙΚΗ ΑΝΑΦΟΡΑ

**Συγκεκριμένα θα ήθελα να εξεταστώ στις 24/06 λόγω
εξετάσεων σε άλλα μαθήματα**

1^η Εργασία

ΚΙΟΥΡΤ-ΜΕΧΜΕΤΑΛΗ ΑΧΜΕΤ

A.M.: 1084672

up1084672@ac.upatras.gr

Πάτρα, 2026

Περιεχόμενα

Ερώτημα 1	3
1.1 Μελέτη Σύγχρονων Εργαλείων Πρόβλεψης Πρωτεϊνικών Δομών	3
1.2 Αναζήτηση BLASTP στη Βάση Δεδομένων NCBI.....	4
1.3 Πολλαπλή Στοιχισή.....	7
1.4 Επιλογή των χειρότερων επιλογών	14
1.5 Μία άλλη αξιολόγηση	18
Ερώτημα 2	20
2.1 Αναζήτηση Cytochrome c - Homo sapiens	20
2.2. Χρήση Κώδικα και Σταδιακή Ανάκτηση Πληροφορίας.....	20
2.3 Απαντήσεις στα Ερωτήματα.....	24
Ερώτημα 3	25
3.1 Ορισμός και Αναζήτηση Αλληλουχίας με Χρήση Κώδικα	25
3.2 Επιβεβαίωση Λειτουργίας Πρωτεΐνης μέσω Βιβλιογραφική Αναζήτηση	27
3.3 Απαντήσεις στα Ερωτήματα.....	28
Ερώτημα 4	30
4.1 Εύρεση Μέγιστης Κοινής Υποακολουθίας Ανάμεσα σε SARS-CoV-2 και SARS-CoV-1	30
4.2 Σύγκριση Δομής των SARS-CoV-1 και SARS-CoV-2	34
Ερώτημα 5	39
5.1 Ολική Στοιχισή	39
5.2 Τοπική Στοιχισή	40
Ερώτηση 6	42
6.1. Βελτιστοποιημένη Αναζήτηση σε Suffix Tree με Χρονικό Περιορισμό k	42
Παράδειγμα Εφαρμογής	43
6.2 Τεχνικές Συνδυασμού Bloom Filters, Suffix Arrays και Burrows Wheeler για Δεικτοδότηση Βιολογικών Δεδομένων	44

Ερώτημα 1

1.1 Μελέτη Σύγχρονων Εργαλείων Πρόβλεψης Πρωτεϊνικών Δομών

Η πρόβλεψη της πρωτεϊνικής δομής αποτελεί ένα από τα πιο κρίσιμα προβλήματα στη βιολογία, καθώς η τρισδιάστατη δομή μιας πρωτεΐνης καθορίζει τη λειτουργία της. Η ανάπτυξη εργαλείων τεχνητής νοημοσύνης έχει βελτιώσει σημαντικά την ακρίβεια της πρόβλεψης πρωτεϊνικών δομών. Στην παρούσα αναφορά, παρουσιάζονται δύο σύγχρονα εργαλεία: AlphaFold3 και ESMFold.

AlphaFold3

Το AlphaFold3 αποτελεί τη νέα έκδοση του AlphaFold, ενός εργαλείου που αναπτύχθηκε από την DeepMind και έχει φέρει επανάσταση στην πρόβλεψη της δομής των πρωτεϊνών.

Βασική λειτουργικότητα

Το AlphaFold3 χρησιμοποιεί βαθιά νευρωνικά δίκτυα και εξελιγμένα αλγοριθμικά μοντέλα για να προβλέψει με ακρίβεια την τρισδιάστατη δομή μιας πρωτεΐνης αποκλειστικά από την αλληλουχία των αμινοξέων της. Αντί για τις παραδοσιακές προσεγγίσεις που βασίζονται σε πειραματικά δεδομένα ή πρότυπα ομοιότητας, το AlphaFold3 χρησιμοποιεί ένα διπλό μοντέλο πρόβλεψης, που περιλαμβάνει ένα δίκτυο για την εκτίμηση αποστάσεων μεταξύ καταλοίπων και ένα άλλο για την πρόβλεψη των γωνιών στρέψης των πεπτιδικών δεσμών. Αυτό επιτρέπει υψηλότερη ακρίβεια στις προβλέψεις και την εξαγωγή αξιόπιστων δομών ακόμα και για πρωτεΐνες χωρίς γνωστές ομόλογες δομές.

Διαδικασία χρήσης

1. **Είσοδος δεδομένων:** Ο χρήστης εισάγει την αλληλουχία αμινοξέων μιας πρωτεΐνης σε μορφή FASTA.
2. **Επεξεργασία δεδομένων:** Το εργαλείο αναλύει την αλληλουχία και εφαρμόζει νευρωνικά δίκτυα για την πρόβλεψη των αποστάσεων μεταξύ καταλοίπων και των γωνιών των δεσμών.
3. **Εξαγωγή αποτελεσμάτων:** Το AlphaFold3 επιστρέφει ένα τρισδιάστατο μοντέλο της πρωτεΐνης σε μορφή PDB (Protein Data Bank), το οποίο μπορεί να χρησιμοποιηθεί για περαιτέρω ανάλυση ή οπτικοποίηση μέσω λογισμικού όπως PyMOL ή Chimera.

Οι χρήστες μπορούν να χρησιμοποιήσουν την υπηρεσία μέσω του επίσημου διακομιστή ([AlphaFold Server](#)) ή μέσω του ColabFold, που επιτρέπει την εκτέλεση προβλέψεων μέσω Google Colab χωρίς την ανάγκη ισχυρών υπολογιστικών πόρων ([ColabFold στο GitHub](#)).

ESMFold

Το ESMFold είναι ένα εργαλείο πρόβλεψης πρωτεϊνικής δομής που αναπτύχθηκε από την ομάδα Facebook AI Research (Meta). Αντίθετα από το AlphaFold3, το ESMFold βασίζεται σε προεκπαιδευμένα γλωσσικά μοντέλα και χρησιμοποιεί μεγάλες βάσεις δεδομένων πρωτεϊνικών αλληλουχιών για τη βελτίωση της πρόβλεψης δομών.

Βασική λειτουργικότητα

Το ESMFold λειτουργεί με βάση μετασχηματιστικά μοντέλα (transformers), παρόμοια με αυτά που χρησιμοποιούνται στην επεξεργασία φυσικής γλώσσας (NLP), για την ανάλυση των πρωτεϊνικών αλληλουχιών. Το μοντέλο έχει εκπαιδευτεί σε εκατομμύρια πρωτεϊνικές αλληλουχίες, επιτρέποντάς του να εξαγάγει χρήσιμες πληροφορίες για τη δομή τους ακόμα και χωρίς τη χρήση δεδομένων ομολογίας. Αυτό καθιστά το ESMFold ιδιαίτερα χρήσιμο για την πρόβλεψη πρωτεϊνικών δομών σε οργανισμούς που δεν έχουν μελετηθεί εκτενώς.

Διαδικασία χρήσης

1. **Είσοδος δεδομένων:** Ο χρήστης εισάγει την πρωτεϊνική αλληλουχία σε μορφή FASTA.
2. **Επεξεργασία δεδομένων:** Το μοντέλο αναλύει την αλληλουχία χρησιμοποιώντας τεχνικές NLP και προβλέπει την τρισδιάστατη δομή της πρωτεΐνης.
3. **Εξαγωγή αποτελεσμάτων:** Παράγει ένα αρχείο PDB ή άλλες μορφές μοντελοποίησης, το οποίο μπορεί να χρησιμοποιηθεί για περαιτέρω ανάλυση.

Το εργαλείο λειτουργεί εξαιρετικά γρήγορα σε σύγκριση με το AlphaFold3, καθώς απαιτεί λιγότερους υπολογιστικούς πόρους. Ωστόσο, η ακρίβειά του είναι γενικά χαμηλότερη σε δομές υψηλής πολυπλοκότητας. Ο κώδικας του είναι διαθέσιμος στο GitHub, επιτρέποντας την ενσωμάτωσή του σε ερευνητικά και βιοτεχνολογικά περιβάλλοντα.

Και τα δύο εργαλεία, AlphaFold3 και ESMFold, προσφέρουν νέες δυνατότητες στην πρόβλεψη πρωτεϊνικών δομών. Το AlphaFold3 υπερέρχει σε ακρίβεια και χρησιμοποιείται ευρέως στην επιστημονική κοινότητα, ενώ το ESMFold είναι ταχύτερο και ευκολότερο στην ενσωμάτωση σε αυτοματοποιημένα pipelines. Η επιλογή του κατάλληλου εργαλείου εξαρτάται από τις ανάγκες της εκάστοτε εφαρμογής.

1.2 Αναζήτηση BLASTP στη Βάση Δεδομένων NCBI

Αρχικά, μεταβαίνουμε στη βάση δεδομένων NCBI και πραγματοποιούμε BLASTP protein-to-protein αναζήτηση πάνω στη πρωτεΐνη με RefSeq accession number NP_000509, η οποία είναι η **B-υπομονάδα της αιμοσφαιρίνης**. Η συγκεκριμένη μέθοδος αναζήτησης διασπά την αλληλουχία της πρωτεΐνης που εισαγάγαμε σε μικρά "κλειδιά" (words) και ψάχνει για ακριβές ή σχεδόν ακριβές ταίριασμα αυτών των "κλειδιών" στη βάση δεδομένων. Όταν βρει πιθανές περιοχές ομοιότητας, επεκτείνει το ταίριασμα και υπολογίζει το σκορ ευθυγράμμισης. Έτσι, εμφανίζονται οι πρωτεΐνες που είναι ομόλογες ή παρόμοιες με τη συγκεκριμένη και για κάθε ταίριασμα δίνεται το ποσοστό ομοιότητας (Per. Ident.), το μήκος ευθυγράμμισης (Acc. Len.), το E-value (στατιστική σημαντικότητα) και το συνολικό σκορ (Total Score).

Συγκεκριμένα κάνουμε την αναζήτηση γράφοντας το accession number και επιλέγοντας την default βάση δεδομένων όπως μπορούμε να παρατηρήσουμε και στην επόμενη εικόνα.

Εικόνα 1: Αναζήτηση σε Βάση Δεδομένων NCBI

Στη συνέχεια επιλέγουμε τις πρώτες δέκα πρωτεΐνες, όπως περιγράφεται τόσο στην εκκώνηση όσο και στην επόμενη εικόνα, όπου απεικονίζεται η διαδικασία. Φυσικά, θα μπορούσαμε να επιλέξουμε και οποιεσδήποτε άλλες δέκα πρωτεΐνες, καθώς δεν είναι υποχρεωτικό να περιοριστούμε στις πρώτες της λίστας. Ωστόσο, οι πρωτεΐνες που εμφανίζονται στις πρώτες θέσεις γενικά παρουσιάζουν τη μεγαλύτερη ομοιότητα με το ερώτημα της αναζήτησης μας (query cover).

Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	100%	9e-103	100.00%	148	AAX37051.1
hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	100%	9e-103	100.00%	148	AAX39567.1
hemoglobin subunit beta [Homo sapiens]	Homo sapiens	301	301	100%	1e-102	100.00%	147	NP_000509.1
hemoglobin subunit beta [Gorilla gorilla gorilla]	Gorilla gorilla, go...	300	300	100%	4e-102	99.32%	147	XP_018891709.1
beta globin chain variant [Homo sapiens]	Homo sapiens	299	299	100%	5e-102	99.32%	147	AAN84548.1
beta-globin [Homo sapiens]	Homo sapiens	299	299	100%	5e-102	99.32%	147	ACU56984.1
beta globin [Homo sapiens]	Homo sapiens	299	299	100%	5e-102	99.32%	147	AAZ39780.1
hemoglobin beta chain [Homo sapiens]	Homo sapiens	299	299	100%	6e-102	99.32%	147	AAO19696.1
HBB, partial [synthetic construct]	synthetic construct	299	299	100%	6e-102	99.32%	147	AKI70610.1
HBB, partial [synthetic construct]	synthetic construct	299	299	100%	9e-102	99.32%	147	AKI70611.1

Εικόνα 2: Πρώτα 10 πρωτεΐνες

Πιο κάτω βλέπουμε τα πρώτα 26 αποτελέσματα που επιστρέφονται από την αναζήτηση με τις αντίστοιχες πληροφορίες που αναφέραμε.

Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per Ident	Acc. Len	Accession
hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	100%	9e-103	100.00%	148	AAX37051.1
hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	100%	9e-103	100.00%	148	AAX29557.1
hemoglobin subunit beta [Homo sapiens]	Homo sapiens	301	301	100%	1e-102	100.00%	147	NP_000509.1
hemoglobin subunit beta [Gorilla gorilla gorilla]	Gorilla gorilla go	300	300	100%	4e-102	99.32%	147	XP_018891709.1
beta globin chain variant [Homo sapiens]	Homo sapiens	299	299	100%	5e-102	99.32%	147	AAN84548.1
beta-globin [Homo sapiens]	Homo sapiens	299	299	100%	5e-102	99.32%	147	ACU56984.1
beta globin [Homo sapiens]	Homo sapiens	299	299	100%	5e-102	99.32%	147	AAZ39780.1
hemoglobin beta chain [Homo sapiens]	Homo sapiens	299	299	100%	6e-102	99.32%	147	AAD19696.1
HBB, partial [synthetic construct]	synthetic construct	299	299	100%	6e-102	99.32%	147	AKI70610.1
HBB, partial [synthetic construct]	synthetic construct	299	299	100%	9e-102	99.32%	147	AKI70611.1
Chain B, HEMOGLOBIN (BETA CHAIN) [Homo sapiens]	Homo sapiens	298	298	99%	9e-102	100.00%	146	1A3N_B
hemoglobin subunit beta [Homo sapiens]	Homo sapiens	298	298	100%	1e-101	99.32%	147	QBH68124.1
HBB, partial [synthetic construct]	synthetic construct	298	298	100%	1e-101	99.32%	147	AKI70608.1
beta-globin [Homo sapiens]	Homo sapiens	298	298	100%	1e-101	99.32%	147	AAA88054.1
Chain B, Hemoglobin subunit beta [Homo sapiens]	Homo sapiens	298	298	100%	1e-101	99.32%	148	7K4M_B
HBB, partial [synthetic construct]	synthetic construct	298	298	100%	2e-101	99.32%	147	AKI70609.1
Chain B, Hemoglobin subunit beta [Homo sapiens]	Homo sapiens	298	298	99%	2e-101	99.32%	146	ZYRS_B
Chain B, HEMOGLOBIN (BETA CHAIN) [Homo sapiens]	Homo sapiens	297	297	99%	2e-101	99.32%	146	1A0U_B
Chain B, Hemoglobin subunit beta [Homo sapiens]	Homo sapiens	297	297	99%	2e-101	99.32%	146	4MQG_B
Chain B, HEMOGLOBIN (DEOXY) (BETA CHAIN) [Homo sapiens]	Homo sapiens	297	297	99%	3e-101	99.32%	146	1HDB_B
Chain B, HEMOGLOBIN (DEOXY) (BETA CHAIN) [Homo sapiens]	Homo sapiens	297	297	99%	3e-101	100.00%	146	1DXV_B
Chain B, Hemoglobin subunit beta [Homo sapiens]	Homo sapiens	297	297	99%	3e-101	100.00%	145	SE29_B
mutant beta-globin [Homo sapiens]	Homo sapiens	297	297	100%	3e-101	99.32%	147	AAI68978.1
Chain B, Hemoglobin beta chain [Homo sapiens]	Homo sapiens	297	297	99%	4e-101	99.32%	146	1NQP_B
Chain B, HEMOGLOBIN BETA CHAIN [Homo sapiens]	Homo sapiens	297	297	99%	4e-101	99.32%	146	1K1K_B
hemoglobin beta chain variant Hb S-Wake [Homo sapiens]	Homo sapiens	296	296	100%	6e-101	98.64%	147	AAN11320.1

Εικόνα 3: Αποτελέσματα BLASTP αναζήτησης

Παρουσίαση Αποτελεσμάτων BLAST

Στο τέλος του συγκεκριμένου υποερωτήματος παρουσιάζουμε τις δέκα πρωτεΐνες για τις οποίες έχουμε επιλέξει τη μορφή **FASTA (complete sequence)**, που περιγράφουν:

- **Τα κεφαλαία γράμματα:** Αντιπροσωπεύουν τα **αμινοξέα**. Κάθε γράμμα είναι ένας σύντομος κωδικός για ένα συγκεκριμένο αμινοξύ (π.χ. M = Μεθειονίνη, V = Βαλίνη).
- **Η αλληλουχία:** Η σειρά των γραμμάτων δείχνει πώς είναι χτισμένη ουσιαστικά η πρωτεΐνη. Ακόμα και μια αλλαγή σε ένα γράμμα μπορεί να αλλάξει τη λειτουργία της αιμοσφαιρίνης.

seqdump.txt αρχείο

```
>AAX37051.1 hemoglobin beta, partial [synthetic construct]
MVHLTPPEEKSAVTALWGKVNVDENVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGGKVL
GAFSDGLAHL
NLKGTFTATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVANALAHKYHD
>AAX29557.1 hemoglobin beta, partial [synthetic construct]
MVHLTPPEEKSAVTALWGKVNVDENVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGGKVL
GAFSDGLAHL
NLKGTFTATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVANALAHKYHL
>NP_000509.1 hemoglobin subunit beta [Homo sapiens]
MVHLTPPEEKSAVTALWGKVNVDENVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGGKVL
GAFSDGLAHL
NLKGTFTATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVANALAHKYH
>XP_018891709.1 hemoglobin subunit beta [Gorilla gorilla gorilla]
MVHLTPPEEKSAVTALWGKVNVDENVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGGKVL
GAFSDGLAHL
NLKGTFTATLSELHCDKLHVDPENFKLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVANALAHKYH
>AAN84548.1 beta globin chain variant [Homo sapiens]
MVHLTPPEEKSAVTALWGKVNVDENVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGGKVL
GAFSDGLAHL
NLKGTFTATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKKEFTPPVQAAYQKVVAGVANALAHKYH
>ACU56984.1 beta-globin [Homo sapiens]
```

```

MVHLTPEEKSAVTALWGKVNVDDEVGGEALGRLLVVYPWTQRFFKSFGDLSTPDAMGNPKVKAHGKKVL
GAFSDGLAHL
NLKGTFFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAAYQKVVAGVANALAHKYH
>AAZ39780.1 beta globin [Homo sapiens]
MVHLTPEEKSAVTALWGKVNVDDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPKVKAHGKKVL
GAFSDGLAHL
NLKGTFFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAAYQKVVAGVANALAHKYH
>AAD19696.1 hemoglobin beta chain [Homo sapiens]
MVHLTPEEKSAVTALWGKVNVDDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPKVKAHGKKVL
GAFSDGLAHL
NLKGTFFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAAYQKVVAGVANALAHKYH
>AKI70610.1 HBB, partial [synthetic construct]
MVHLTPEEKSAVTALWGKVNVDDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPKVKAHGKKVL
GAFSDGLAHL
NLKGTFFATLSELHCDKLHVDPENLRLLGNVLVCVLAHHFGKEFTPPVQAAAYQKVVAGVANALAHKYH
>AKI70611.1 HBB, partial [synthetic construct]
MVHLTPEEKSAVTALWGKVNVDDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPKVKAHGKKVL
GAFSDGLAHL
NLKGTFFATLSELHCDKLHVDPENFRLLGNVLVCVLDHFGKEFTPPVQAAAYQKVVAGVANALAHKYH

```

1.3 Πολλαπλή Στοίχιση

MAFFT

Το MAFFT (Multiple Alignment using Fast Fourier Transform) είναι ένα γρήγορο και ευέλικτο εργαλείο πολλαπλής στοίχισης αλληλουχιών, το οποίο χρησιμοποιεί τον αλγόριθμο Fast Fourier Transform (FFT) για να εντοπίζει περιοχές ομοιότητας μεταξύ των αλληλουχιών. Αυτό επιτρέπει την εξαιρετικά ταχεία στοίχιση ακόμα και πολύ μεγάλων συνόλων δεδομένων, με χιλιάδες αλληλουχίες. Το MAFFT προσφέρει διαφορετικούς τρόπους στοίχισης προσαρμοσμένους είτε στην ταχύτητα είτε στην ακρίβεια, και είναι ιδιαίτερα χρήσιμο σε φυλογενετικές αναλύσεις και σε συγκρίσεις γονιδιωμάτων μεγάλης κλίμακας.

Οι βασικές παράμετροι που χρησιμοποιούνται για την στοίχιση είναι οι εξής:

- **OUTPUT FORMAT:** Καθορίζει τη μορφή του αποτελέσματος της στοίχισης (FASTA / ClustalW).
- **MATRIX:** Καθορίζει τα μητρώα αντικατάστασης που καθορίζει το σκορ αντικατάστασης μεταξύ δύο αμινοξέων. Σαν επιλογές έχουμε τα BLOSUM (BLOCKS Substitution Matrix) μητρώα, τα οποία βασίζονται σε ευθυγραμμισμένες περιοχές πρωτεϊνών (blocks). Ο αριθμός από δίπλα δείχνει το επίπεδο ομοιότητας των ακολουθιών που χρησιμοποιήθηκαν για τη δημιουργία του πίνακα. (BLOSUM30 / BLOSUM45 / BLOSUM62 / BLOSUM80). Επίσης, έχουμε και τα JTT PAM (Jones Taylor–Thornton / Point Accepted Mutation) μητρώα, τα οποία είναι μαθηματικά εξελικτικά μοντέλα υποκατάστασης και χρησιμοποιούνται όταν υπάρχει γνωστή εξελικτική απόσταση (JTT PAM100 / JTT PAM200).
- **GAP OPEN PENALTY:** Αντιπροσωπεύει το κόστος εισαγωγής της νέου κενού στη στοίχιση.
- **GAP EXTENSION PENALTY:** Αντιπροσωπεύει το κόστος επέκτασης της υπάρχοντος κενού.
- **ORDER:** Καθορίζει αν οι ακολουθίες επιστρέφονται με τη σειρά που έχουν εισαχθεί (input) ή με τη σειρά που εμφανίζονται στη στοίχιση (aligned).

- **TREE REBUILDING NUMBER:** Καθορίζει πόσες φορές θα ξαναυπολογιστεί το guide tree κατά την ευθυγράμμιση. Περισσότερες επαναλήψεις συνήθως οδηγούν σε βελτιωμένη στοίχιση.
- **GUIDE TREE OUTPUT:** Καθορίζει αν αποθηκεύεται και εμφανίζεται το guide tree που χρησιμοποιήθηκε κατά τη στοίχιση (on / off).
- **MAX ITERATE:** Είναι ο μέγιστος αριθμός επαναλήψεων για τη βελτίωση τις στοίχισης. Υψηλότερες τιμές οδηγούν σε πιο ακριβή στοίχιση αλλά απαιτούν περισσότερο χρόνο.
- **PERFORM FFTS:** Καθορίζει αν θα χρησιμοποιηθεί ή όχι ο αλγόριθμος FFT. Σαν επιλογές δίνονται η localpair όπου χρησιμοποιείται η Smith-Waterman στοίχιση για όλες τις ακολουθίες, η globalpair όπου χρησιμοποιείται η Needleman-Wunsch στοίχιση και η gnapair, η οποία είναι μια γενικευμένη μέθοδος ευθυγράμμισης με βέλτιστη στοίχιση ζεύγους και βελτιωμένο guide tree.

By default έχουν επιλεγθεί οι επιλογές που εμφανίζονται στην παρακάτω εικόνα:

Parameters		OUTPUT FORMAT ⓘ	MATRIX (PROTEIN ONLY) ⓘ	GAP OPEN PENALTY ⓘ	GAP EXTENSION PENALTY ⓘ	ORDER ⓘ	TREE REBUILDING NUMBER ⓘ
		Pearson/FASTA	BLOSUM62	1.53	0.123	aligned	2
		GUIDE TREE OUTPUT ⓘ	MAX ITERATE ⓘ	PERFORM FFTS ⓘ			
		on	2	none			

Εικόνα 4: Παράμετροι MAFFT

MUSCLE

Το MUSCLE (Multiple Sequence Comparison by Log-Expectation) βασίζεται σε μια προοδευτική στρατηγική στοίχισης, ξεκινώντας από την ταχεία κατασκευή ενός δέντρου ομοιότητας, το οποίο χρησιμοποιείται για την αρχική στοίχιση και ακολουθείται από επαναληπτική βελτιστοποίηση (refinement) ώστε να βελτιωθεί η ακρίβεια του τελικού αποτελέσματος. Παρά το ότι είναι ταχύτερο από παραδοσιακές μεθόδους όπως το ClustalW, διατηρεί υψηλή ακρίβεια και θεωρείται ιδανικό για μικρού έως μεσαίου μεγέθους δεδομένα. Χρησιμοποιείται ευρέως για στοίχιση πρωτεϊνών και νουκλεοτιδικών αλληλουχιών στη μελέτη γονιδιωμάτων και εξελικτικών σχέσεων.

Οι βασικές παράμετροι που χρησιμοποιούνται για την στοίχιση είναι οι εξής:

- **OUTPUT FORMAT:** Καθορίζει τη μορφή του αποτελέσματος της στοίχισης (FASTA / ClustalW / ClustalW(strict) / HTML / GCG MSF / Phylip interleaved / Phylip sequential). Τα δύο τελευταία formats αφορούν φυλογενετικά δέντρα.
- **OUTPUT TREE:** Αφορά το guide tree που χρησιμοποιείται για να αποφασιστεί η σειρά ευθυγράμμισης και παίρνει τις τιμές none (καμία έξοδος), from first iteration (εκτυπώνει το guide tree από την πρώτη επανάληψη) και from second iteration (εκτυπώνει το δέντρο μετά από την τελική αναπροσαρμογή).

By default έχουν επιλεγθεί οι επιλογές που εμφανίζονται στην παρακάτω εικόνα:

Parameters	OUTPUT FORMAT ⓘ	OUTPUT TREE ⓘ
	ClustalW	none

Εικόνα 5: Default Επιλογές MUSCLE

T-COFFEE

Το T-COFFEE (Tree-based Consistency Objective Function for Alignment Evaluation) χρησιμοποιεί μια διαφορετική προσέγγιση βασισμένη στη λογική της συνέπειας, καθώς ενσωματώνει πληροφορία από όλες τις δυνατές στοιχίσεις ανά ζεύγη (pairwise alignments) πριν κατασκευάσει τη τελική πολλαπλή στοίχιση. Αυτό του επιτρέπει να διατηρεί τη βέλτιστη ποιότητα ευθυγράμμισης ακόμη και σε περιπτώσεις πολύ διαφορετικών αλληλουχιών. Αν και είναι πιο αργό από το MAFFT ή το MUSCLE, παρέχει πολύ αξιόπιστα αποτελέσματα και είναι ιδιαίτερα χρήσιμο όταν απαιτείται υψηλή ακρίβεια, όπως στη μελέτη ομόλογων γονιδίων με χαμηλή ομοιότητα.

Οι βασικές παράμετροι που χρησιμοποιούνται για την στοίχιση είναι οι εξής:

- **OUTPUT FORMAT:** Καθορίζει τη μορφή του αποτελέσματος της στοίχισης (FASTA / ClustalW / HTML / MSF / PHYLIP).
- **MATRIX:** Καθορίζει τα μητρώα αντικατάστασης που καθορίζει το σκορ αντικατάστασης μεταξύ δύο αμινοξέων. Σαν επιλογές έχουμε τα BLOSUM και τα PAM μητρώα.
- **ORDER:** Καθορίζει αν οι ακολουθίες επιστρέφονται με τη σειρά που έχουν εισαχθεί (input) ή με τη σειρά που εμφανίζονται στη στοίχιση (aligned).

By default έχουν επιλεγθεί οι επιλογές που εμφανίζονται στην παρακάτω εικόνα:

Parameters	OUTPUT FORMAT ⓘ ClustalW ▼	MATRIX ⓘ None ▼	ORDER ⓘ aligned ▼
------------	-------------------------------	--------------------	----------------------

Εικόνα 6: Παράμετροι T-COFFEE

Είναι σημαντικό ωστόσο ως **OUTPUT FORMAT** να οριστεί το **FASTA** και για τα τρία μοντέλα, προκειμένου τα αποτελέσματα να είναι συγκρίσιμα μεταξύ τους. Επιπλέον, το format FASTA είναι το πιο κατάλληλο για τον ακριβή υπολογισμό των μετρικών ποιότητας στοίχισης στη συνέχεια.

Αφού τρέξουμε κάθε πολλαπλή στοίχιση στο παράθυρο “Tool Output” υπάρχει η επιλογή “Coloured sequences” όπου μπορούμε να συγκρίνουμε οπτικά τις στοιχίσεις ανάμεσα στις πρωτεΐνες με χρωματική κωδικοποίηση ανά νουκλεοτίδιο. Οι ταυτόσημοι χαρακτήρες σημειώνονται με το ίδιο χρώμα, οι διαφορετικοί με ξεχωριστά χρώματα και επίσης σημειώνονται και τα κενά. Βέβαια μπορούμε να έχουμε το αποτέλεσμα και σε αρχείο .aln-fasta που με διάφορα tools στο διαδίκτυο μπορούμε να συγκρίνουμε το αποτέλεσμα σε διάφορες μορφές για καλύτερη κατανόηση.

```

>AAX37051.1 hemoglobin beta, partial [synthetic construct]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>AAX29557.1 hemoglobin beta, partial [synthetic construct]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>NP_089589.1 hemoglobin subunit beta [Homo sapiens]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>XP_018891789.1 hemoglobin subunit beta [Gorilla gorilla gorilla]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>AAB84548.1 beta globin chain variant [Homo sapiens]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>AAD19696.1 hemoglobin beta chain [Homo sapiens]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>ACU56984.1 beta-globin [Homo sapiens]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>AKI78618.1 HBB, partial [synthetic construct]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>AKI78611.1 HBB, partial [synthetic construct]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>AAX37051.1 hemoglobin beta, partial [synthetic construct]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>AAX29557.1 hemoglobin beta, partial [synthetic construct]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>NP_089589.1 hemoglobin subunit beta [Homo sapiens]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

>XP_018891789.1 hemoglobin subunit beta [Gorilla gorilla gorilla]
MVHLTPEEKSAVTALMGKVNDVGGELGRLLVVPYPTQRFESFGDLSTPDVGNPK
VKANGKIVLGFASDGLAH.DNLKGTATLSELHCDLHVDPENRLLGNVLCVLAHFG
KEFTPPVQAAYQIVVAGVANALAHKYH

```

MAFFT

MUSCLE

T-COFFEE

Εικόνα 7: Σύγκριση Μεθόδων

Από τα παραπάνω συμπεραίνουμε οπτικά ότι το **MAFFT** φαίνεται να δίνει έμφαση στη **διατήρηση συμπαγών blocks** στην αρχή και το μέσο των αλληλουχιών, τοποθετώντας gaps κυρίως στο τέλος των μικρότερων αλληλουχιών (όπως στην AAX37051.1) για να διατηρήσει την ευθυγράμμιση των ομόλογων περιοχών. Αντίθετα, το **MUSCLE** προσφέρει μια **πιο συντηρητική στοίχιση**, ελαχιστοποιώντας τη χρήση gaps και προσπαθώντας να κρατήσει τα residues ευθυγραμμισμένα σε όλο το μήκος, ακόμα και αν αυτό οδηγήσει σε λιγότερο "έντονη" ομαδοποίηση των χρωμάτων σε ορισμένα σημεία. Το **T-COFFEE**, τέλος, **προσφέρει την πιο ομοιόμορφη στοίχιση**, επιτυγχάνοντας μια εξαιρετική global εικόνα όπου οι συντηρημένες περιοχές (όπως το μοτίβο MVHLTPEE) ευθυγραμμίζονται με μεγάλη ακρίβεια σε όλα τα δείγματα, υποδεικνύοντας υψηλή αξιοπιστία στη θέση κάθε αμινοξέος.

Όσον αφορά την αξιολόγηση της ποιότητας και της ακρίβειας της στοίχισης, τα συγκεκριμένα εργαλεία δεν μας παρέχουν απευθείας την δυνατότητα υπολογισμού μετρικών όπως percent identity, percent gaps και SP score, γι' αυτό και τα υπολογίζουμε μέσω ενός Python script. Το percent identity δηλώνει το ποσοστό των θέσεων στην πολλαπλή στοίχιση στις οποίες τα αμινοξέα (ή νουκλεοτίδια) είναι ίδια μεταξύ των ακολουθιών. Στην πράξη, μετράει τη συντηρητικότητα της στοίχισης. Το percent gaps δείχνει το ποσοστό των συνολικών θέσεων σε όλη τη στοίχιση (σε όλες τις ακολουθίες) που περιέχουν το χαρακτήρα "-", δηλαδή κενά (gaps) που εισήχθησαν για να ευθυγραμμιστούν σωστά οι αλληλουχίες. Τέλος, το SP score μετράει πόσες φορές σε κάθε στήλη δύο ακολουθίες έχουν ίδιο χαρακτήρα (όχι gap). Είναι η πιο τυπική μετρική για πολλαπλές στοίχισεις.

Πιο συγκεκριμένα, υλοποιούμε τη συνάρτηση **analyze_alignment()**, η οποία διαβάζει τη στοίχιση με χρήση της βιβλιοθήκης **Biopython (AlignIO.read)** και υπολογίζει τρεις βασικές μετρικές αξιολόγησης: ποσοστό ταύτισης (percent identity), ποσοστό κενού (percent gaps), και το normalized SP score (sum-of-pairs). Για κάθε στήλη της στοίχισης, μετρά πόσα από τα σύμβολα είναι κενά και ποιο είναι το συχνότερο μη-κενό σύμβολο ώστε να

υπολογίσει το ποσοστό ταύτισης, δηλαδή πόσοι χαρακτήρες ταυτίζονται σε κάθε θέση της στοίχισης. Επίσης, υπολογίζεται το ποσοστό gaps ως το ποσοστό των συνολικών κελιών που περιέχουν κενό. Τέλος, το **SP score** προκύπτει συγκρίνοντας κάθε πιθανό ζεύγος αλληλουχιών σε κάθε θέση, αυξάνοντας τη βαθμολογία όταν δύο χαρακτήρες είναι ίδιοι και δεν είναι κενά, και κανονικοποιείται ως ποσοστό ως προς τη μέγιστη δυνατή βαθμολογία. Η συνάρτηση επιστρέφει τα αποτελέσματα σε μορφή λεξικού με τις τιμές όλων των μετρικών, το όνομα της μεθόδου που χρησιμοποιήθηκε, και γενικές πληροφορίες για τη στοίχιση, όπως το συνολικό μήκος και τον αριθμό των αλληλουχιών. Αυτό επιτρέπει την εύκολη σύγκριση ποιοτικά και ποσοτικά μεταξύ διαφορετικών αλγορίθμων στοίχισης.

Για την χρήση του python script που έχουμε δημιουργήσει θα χρειαστούμε το αρχείο .aln-fasta όπου μπορούμε να τα βρούμε στα “Result Files” μετά από κάθε χρήση μεθόδου (MAFFT, MUSCLE, T-Coffee).

Method	Total Sequences	Alignment Length	Percent Identity	Percent Gaps	Normalized SP Score
MAFFT	10	148	99.0326	0.3303	0.9838
MUSCLE	10	148	99.0326	0.3303	0.9838
T-Coffee	10	148	99.0326	0.3303	0.9838

Από τα παραπάνω συμπεραίνουμε οπτικά και υπολογιστικά ότι και τα τρία εργαλεία (**MAFFT, MUSCLE, T-COFFEE**) δίνουν **πανομοιότυπα αποτελέσματα** για τις συγκεκριμένες αλληλουχίες. Παρατηρούμε ότι το ποσοστό ταυτότητας (**Identity**) παραμένει σταθερό στο **99.03%**, το ποσοστό κενών (**Gaps**) στο **0.33%** και το **SP Score** στο **0.9838** και για τις τρεις μεθόδους. Αυτό συμβαίνει διότι οι αλληλουχίες της αιμοσφαιρίνης παρουσιάζουν εξαιρετικά υψηλή ομολογία, με αποτέλεσμα οι διαφορετικοί αλγόριθμοι να καταλήγουν στην ίδια βέλτιστη λύση χωρίς αποκλίσεις στην τοποθέτηση των gaps ή στη διατήρηση των τοπικών μοτίβων. Συγκεκριμένα:

- Το **MAFFT** επιτυγχάνει μέγιστη ευθυγράμμιση αμέσως λόγω της υψηλής συντήρησης των αλληλουχιών, χωρίς να χρειάζεται εκτενή χρήση gap penalties.
- Το **MUSCLE** παράγει την ίδια "σφιχτή" στοίχιση, καθώς οι φυσικές ομοιότητες των residues δεν αφήνουν περιθώριο για εναλλακτικές τοποθετήσεις.
- Το **T-COFFEE** επιβεβαιώνει την ορθότητα της στοίχισης, με το global score να ταυτίζεται πλήρως με τα υπόλοιπα εργαλεία, υποδεικνύοντας μια στοίχιση υψηλής αξιοπιστίας.

Τέλος, θέλουμε τώρα να μελετήσουμε την επίδραση των παραμέτρων των εργαλείων στη τελική στοίχιση. Στους παρακάτω πίνακες συνοψίζουμε τις διαφορετικές τιμές των παραμέτρων που θα αξιοποιήσουμε:

Για **MAFFT** έχουμε αλλάξει τους παραμέτρους:

- **Matrix (BLOSUM80):** Επιλέχθηκε για τη βέλτιστη σύγκριση αλληλουχιών με εξαιρετικά υψηλή ομολογία (άνω του 80%). Ο συγκεκριμένος πίνακας επιβάλλει αυστηρότερες ποινές σε αποκλίσεις αμινοξέων, αναδεικνύοντας τις ελάχιστες μεταλλάξεις μεταξύ των δειγμάτων.

- **Gap Open Penalty (2.0):** Η αύξηση της ποινής ανοίγματος κενών αποτρέπει την τεχνητή εισαγωγή ασυνεχειών στην ευθυγράμμιση, διατηρώντας τη δομική ακεραιότητα των συντηρημένων αλυσίδων αιμοσφαιρίνης.
- **Max Iterate (10):** Ο αριθμός των επαναλήψεων ορίστηκε στις 10 για τη διασφάλιση της μαθηματικής σύγκλισης και την εύρεση της πλέον βέλτιστης ευθυγράμμισης μέσω πολλαπλών κύκλων βελτιστοποίησης.
- **Order (Input):** Η διατήρηση της σειράς εισαγωγής διευκολύνει την άμεση οπτική σύγκριση των συνθετικών δειγμάτων με τις αλληλουχίες αναφοράς (ανθρώπου και γορίλα).

Το αποτέλεσμα παραμένει αμετάβλητο λόγω της **εξαιρετικά υψηλής ομολογίας** (99.03%) των αλληλουχιών, η οποία καθιστά την ευθυγράμμιση μαθηματικά προφανή. Καθώς δεν υπάρχουν εσωτερικά κενά (gaps) στα δεδομένα μας, οι αλλαγές στις ποινές (penalties) δεν επηρεάζουν τη δομή της ευθυγράμμισης, επιβεβαιώνοντας πως η λύση είναι ήδη η βέλτιστη.

Τις ίδιες διαδικασίες έχουμε κάνει και για τα MUSCLE μαζί με την T-COFFEE:

Όπου για MUSCLE βάλουμε το output tree σε **from first iteration** που είναι καλή για χρήση σε downstream bioinformatics αλλά και την άλλη επιλογή **from second iteration** για οπτική αξιολόγηση alignment και δέντρου.

Έπειτα για T-COFFEE επιλέξαμε να δοκιμάσουμε τους παραμέτρους για matrix **BLOSUM** και order **aligned** που προσπαθεί να φέρει ευθυγράμμιση υψηλής ακρίβειας ενώ με την χρήση του PAM στο matrix και input στο order δοκιμάσαμε την διαδικασία να διατηρεί την αρχική σειρά εισαγωγής.

Το συγκεκριμένο python script που χρησιμοποιούμε για να βρούμε τα αποτελέσματα, με τον ίδιο κώδικα αν χρησιμοποιούμε άλλες πρωτεΐνες είναι προφανές ότι θα δούμε κάποια αλλαγή πιο φανερή:

```
from Bio import AlignIO
import pandas as pd
import os

def analyze_alignment(filepath, method_name, format="fasta"):
    if not os.path.exists(filepath):
        print(f" Warning: File '{filepath}' not found. Skipping...")
        return None

    try:
        alignment = AlignIO.read(filepath, format)
    except Exception as e:
        print(f" Error reading {filepath}: {e}")
        return None

    n_seqs = len(alignment)
    aln_len = alignment.get_alignment_length()

    total_positions = n_seqs * aln_len
    total_pairs = n_seqs * (n_seqs - 1) / 2

    identity_matches = 0
    total_comparisons = 0
    gap_count = 0
    sp_score = 0
```

```

for i in range(aln_len):
    column = alignment[:, i]
    for a in range(n_seqs):
        for b in range(a + 1, n_seqs):
            aa = column[a]
            bb = column[b]

            if aa == "-" or bb == "-":
                gap_count += 1
                continue
            total_comparisons += 1

            if aa == bb:
                identity_matches += 1
                sp_score += 1

    # Calculate metrics
    percent_identity = (identity_matches / total_comparisons) * 100
if total_comparisons > 0 else 0
    # Normalized by all possible sequence pairs across all positions
    percent_gaps = (gap_count / (total_positions * (n_seqs - 1))) *
100
    normalized_sp = (sp_score / (total_pairs * aln_len))

    # CHANGED: All rounding updated to 4 decimal places
    return {
        "Method": method_name,
        "Total Seqs": n_seqs,
        "Length": aln_len,
        "Percent Identity": round(percent_identity, 4),
        "Percent Gaps": round(percent_gaps, 4),
        "Normalized SP Score": round(normalized_sp, 4)
    }

# --- THE EXECUTION PART vazoyme osa files theloyme kai ekteloyme ---
if __name__ == "__main__":
    files_to_run = [
        ("filename.aln-fasta", "MAFFT Default"),
        ("filename.aln-fasta", "MAFFT Custom"),
        ("filename.aln-fasta", "MAFFT Custom"),
        ("filename.aln-fasta", "MUSCLE Default"),
        ("filename.aln-fasta", "MUSCLE First"),
        ("filename.aln-fasta", "MUSCLE Second"),
        ("filename.aln-fasta", "T-COFFEE Default"),
        ("filename.aln-fasta", "T-COFFEE Blosum Aligned"),
        ("filename.aln-fasta", "T-COFFEE PAM Input")
    ]

    all_results = []

    for file_path, label in files_to_run:
        res = analyze_alignment(file_path, label)
        if res:
            all_results.append(res)

    if all_results:
        df = pd.DataFrame(all_results)

        print("\n" + "="*70)

```

```

        print("                                FINAL ALIGNMENT COMPARISON (High
Precision)")
        print("="*70)
        # Using to_string ensures the console doesn't truncate the
        decimals
        print(df.to_string(index=False))
        print("="*70)

        try:
            df.to_excel("Alignment_Comparison_Detailed.xlsx",
index=False)
            print("\n High-precision results saved to
'Alignment_Comparison_Detailed.xlsx'!")
        except Exception as e:
            print(f"\nCould not save to Excel: {e}")
        else:
            print("No files were processed. Check your filenames!")

```

1.4 Επιλογή των χειρότερων επιλογών

Σε αυτή την υποενότητα παρόλο που δεν υπάρχει μία ερώτηση θα εξηγήσουμε τις αλλαγές τις υποενότητας 1.3 με μία οπτική που θα φαίνονται οι αλλαγές επιλέγοντας πρωτεΐνες που δεν έχουν μεγάλο percent identity.

Για το συγκεκριμένο παράδειγμα χρησιμοποιήσαμε το **NP_002023** που βρήκαμε δεδομένα που δεν έχουν την αποκλειστικά την ίδια προσσέγιση όπως περιγραφουμε και παρακάτω αλλά παρατηρούμε και στην εικόνα.

☒	2 member(s), 1 organism(s)	birds	ferritin heavy chain isoform X2 [Nyctibius grandis]	350	350	99%	5e-119	91.16%	348	XP_068255060.1
☒	1 member(s), 1 organism(s)	greater spear-nosed bat	ferritin heavy chain [Phyllostomus hastatus]	350	350	98%	2e-119	91.06%	309	XP_045710709.1
☒	159 member(s), 151 organism(s)	amniotes	ferritin heavy chain [Gallus gallus]	343	343	98%	1e-118	91.06%	180	NP_990417.1
☒	2 member(s), 1 organism(s)	greater horseshoe bat	ferritin heavy chain 1 [Rhinolophus ferrumequinum]	335	335	95%	4e-115	90.75%	198	KAF6333098.1
☐	1 member(s), 1 organism(s)	California sea lion	ferritin heavy chain-like [Zalophus californianus]	349	349	100%	2e-119	90.71%	275	XP_035579278.1
☐	3 member(s), 3 organism(s)	great apes	ferritin heavy chain-like [Pongo abelii]	343	343	100%	1e-118	90.71%	183	XP_063578523.1
☐	1 member(s), 1 organism(s)	Angolan colobus	PREDICTED: LOW QUALITY PROTEIN: ferritin heavy chain-l...	345	345	99%	1e-118	90.66%	220	XP_011795970.1
☒	1 member(s), 1 organism(s)	donkey	ferritin heavy chain [Equus asinus]	347	347	98%	2e-118	90.56%	301	XP_014691356.3
☒	1 member(s), 1 organism(s)	Chinese soft-shelled turtle	ferritin heavy chain isoform X1 [Pelodiscus sinensis]	337	337	96%	8e-116	90.29%	210	XP_075784488.1
☐	1 member(s), 1 organism(s)	southern two-toed sloth	LOW QUALITY PROTEIN: ferritin heavy chain-like [Choloepu...	345	345	100%	1e-118	90.16%	246	XP_037695528.1
☒	2 member(s), 1 organism(s)	sheep	hypothetical protein R6Z07M_017370 [Ovis aries]	345	345	98%	5e-117	89.94%	330	XDC66188.1
☐	1 member(s), 1 organism(s)	narwhal	LOW QUALITY PROTEIN: uncharacterized protein LOC1148...	349	349	100%	7e-117	89.62%	455	XP_029082898.1
☐	2 member(s), 2 organism(s)	marine dolphins	LOW QUALITY PROTEIN: ferritin heavy chain-like [Orcinus o...	337	337	100%	3e-116	89.62%	182	XP_049572095.1
☐	1 member(s), 1 organism(s)	California sea lion	ferritin, mitochondrial-like [Zalophus californianus]	340	340	100%	1e-114	89.62%	373	XP_035583431.1
☒	1 member(s), 1 organism(s)	Cape elephant shrew	PREDICTED: ferritin heavy chain-like [Elephantulus edwardii]	345	345	99%	2e-118	89.56%	239	XP_006878994.1
☒	1 member(s), 1 organism(s)	plains zebra	ferritin heavy chain-like, partial [Equus quagga]	339	339	98%	2e-116	89.39%	214	XP_046538020.1
☒	2 member(s), 2 organism(s)	bats	ferritin heavy chain-like [Sturmira hondurensis]	339	339	98%	5e-116	89.39%	254	XP_036884873.1

Εικόνα 8: Λιγότερο percent identity και query cover για καλύτερη ανάλυση

Βλέπουμε στην 7^η στήλη ότι δεν έχουμε μεγάλο identity όπως είχαμε προηγουμένως, πράγμα που θα μπορούμε να δούμε αλλαγές για καλύτερα συμπεράσματα επίσης προσπαθήσαμε να διαλέξουμε και query covers που δεν είναι 100%.

Όπου σαν **seqdumpnew2.txt** έχουμε:

```

>XP_068255060.1:168-348 ferritin heavy chain isoform X2 [Nyctibius
grandis]
AAPPSQVRQNYHQDCEAAINRQINLELYASYVYLSMSYFYDRDDVALKNFAKYFRHQSHQEEREHAELKLM
KLQNQRGGRIF

```

LQDVKKPDRDDWENGLTAMECALHLEKNVNQSLLELHKLATEKNDPHLCDFIETHYLDEQVKS IKELGD
 HVTNLRKMGAP
 KYGMAEYLFDKHTLGSDSDS
 >XP_045710709.1:128-306 ferritin heavy chain [Phyllostomus hastatus]
 IMTTSVSQVRQNYHQDSEAAINRQINLELYASYVYLSMSYFYFDRDDVALKNFAKYFLHQSHEEREHAEK
 LMKLQNRGGR
 IFLQDIKKPERDDWENGLNAMECALHLEKSVNQSLDLHKLATEKNDPHLCDFIETHYLDEQVKA IKEL
 GDHVTNLRRLG
 APGAGMAEYLFDKHTLGDS
 >NP_990417.1:2-180 ferritin heavy chain [Gallus gallus]
 ATPPSQVRQNYHQDCEAAINRQINLELYASYVYLSMSYFYFDRDDVALKNFAKYFLHQSHEEREHAEKLM
 KLQNRGGRI
 LQDIKKPDRDDWENGLTAMECALHLEKNVNQSLLELHKLATEKNDPHLCDFIETHYLDEQVKA IKQLGD
 HVTNLRKMGAP
 KYGMAEYLFDKHTLGESDS
 >KAF6333098.1:1-173 ferritin heavy chain 1 [Rhinolophus
 ferrumequinum]
 MTSATSSQVRQNYHQDSEAAINRQINLELYASYVYLSMSYFYFDRDDVALKNFAKYFLHQSHEEREHAEK
 LMKLQNRGGR
 IFLQDVKKPDRDDWENGLNAMECALHLEKSVNQSLDLHKLATDKNDAHLCDFIETHYLNEQVKS IKEL
 GDYITNLRKMG
 APESGMAEYFPFGR
 >XP_014691356.3:120-299 ferritin heavy chain [Equus asinus]
 VTTAFPSQVRQNYHQDSEAAINRQINLELHVSCVYLSMSFYFDRDDVALKNFAKYFLHQSHEEREHAEK
 LMKLQNRGGR
 IFLQDIKKPDQDDWENGLKAMECALHLEKNVNESLLELHKLATDKNDPHLCDFLETHYLNEQVKA IKEL
 GDHVTNLRRLG
 PPESGMAEYLFDKHTLGECD
 >XP_075784488.1:36-210 ferritin heavy chain isoform X1 [Pelodiscus
 sinensis]
 VRQNYHQDCEAAVNRQINLELYASYAYLSMSFYFDRDDVALKNFAKYFLHQSHDEREHAEKLMKLQNR
 GGRIFLQDIKK
 PDRDDWENGLTALECALHLEKNVNQSLDLHKLATDKNDPHLCDFIETHYLDEQVKA IKELGDHVTNLR
 KMGAPKNGMAE
 YLFDKHTLGDCGNQS
 >XDC66188.1:152-330 hypothetical protein R6Z07M_017370 [Ovis aries]
 SADLAKVRQNYHQDSEAAINRQINLELYASYVYLSMSYFYFDRDDVALKNFAKYFLHQSHEEREHAERLM
 KLQNRGGRI
 LQDIKKPDRDDWENGLNAMECALCLERSVNQSLLELHKLATEKNDPHLCDFIETHYLNEQVEAIKELGD
 HITNLRKMGAP
 GSGMAEYLFDKHTLGHSDS
 >XP_006878994.1:58-239 PREDICTED: ferritin heavy chain-like
 [Elephantulus edwardii]
 VTASPSQVRQNYNQDSEAAIHRQINLELYASYVFLSMSYFYFDRDDVGLKNFAKYFLHQSHEERKHTEKL
 MKLQNRGGRI
 FLQDIKKPDRDDWESGLNAMECALHLEKSVNQSLLELHKLATDKNGPHLCDFIETHYLDEQVKS IKQLG
 DYVTNLRKTGA
 PDSGLAEYLLDKHTLGSDGES
 >XP_046538020.1:34-212 ferritin heavy chain-like, partial [Equus
 quagga]
 SAAFPSQVRQNYHQDSEAAVNRQISLELHASVYVLSMSFYFDRDDVALKNFAKYFLHQSHEEREHAEKL
 MKLQNRGGWI
 FLQDIKKPDHDDWENGLKAMECALHLGKNVNESLLELHKLATDKNDPHLCDFLKTHTYLNEQVKA IKELG
 DHVTNLRRLG
 PESGMAEYLFDKHTLGDCD
 >XP_036884873.1:73-251 ferritin heavy chain-like [Sturnira
 hondurensis]
 IMTTSVSQVRQNYHQDSEATINRQINLELYASYVYLSMSYFYFGRDDVALKNFAKYFLHQSHEEREHAEK
 LMKLQNRGGW
 IFLQDIKKPERDDWENGLNAMECALHLEKSVNQSLDLHKLATEKNDPHLCDFIETHYLDEQVKS IKEL
 GDHVTNLRRLGAPGSGMAEYLFDKHTLGDS

Η διαφορά που θα μπορούμε να αναλύσουμε και να συγκρίνουμε οπτικά τις στοιχίσεις ανάμεσα στις πρωτεΐνες με χρωματική κωδικοποίηση ανά νουκλεοτίδιο όπως προηγουμένως:



Εικόνα 9: Σύγκριση Μεθόδων Επιλέγοντας Πρωτεΐνες με Λιγότερο Percent Identity

Το T-COFFEE αναδεικνύεται ως η ποιοτικότερη επιλογή για το συγκεκριμένο δείγμα, καθώς επιτυγχάνει την πιο "συμπαγή" ευθυγράμμιση των συντηρημένων περιοχών (όπως τα μπλοκ με το πράσινο και μωβ χρώμα), μειώνοντας τις άσκοπες μετατοπίσεις αμινοξέων. Το MAFFT παρουσιάζει την πιο καθαρή οπτική απεικόνιση και είναι εξαιρετικά γρήγορο, αλλά στην αλληλουχία του *Nyctibius grandis* (πάνω αριστερά σε κάθε πλαίσιο) φαίνεται να αφήνει μεγαλύτερα κενά στην αρχή σε σχέση με τους άλλους. Το MUSCLE παράγει ένα αποτέλεσμα ενδιάμεσης ακρίβειας, πολύ κοντινό στο MAFFT, αλλά με ελαφρώς διαφορετική στοίχιση στις τερματικές περιοχές (N-terminal) των αλληλουχιών, όπου η μεταβλητότητα είναι μεγαλύτερη.

MAFFT

MATRIX	GAP OPEN PENALTY	GAP EXTENSION PENALTY	MAX ITERATE	Status
BLOSUM62	1.53	0.123	2	Default
BLOSUM45	1.0	0.2	2	Worse Quality
BLOSUM80	3.0	1	2	Better Quality

Αποτελέσματα για το MAFFT:

Total Sequences	Alignment Length	Percent Identity	Percent Gaps	Normalized SP Score
10	183	88.0859	1.9429	0.8466
10	183	88.0859	1.9429	0.8466
10	183	88.0859	1.9429	0.8466

MUSCLE

Output Tree	Total Sequences	Alignment Length	Percent Identity	Percent Gaps	Normalized SP Score
Default	10	183	88.0859	1.9429	0.8466
From first iteration	10	183	88.0859	1.9429	0.8466
From second iteration	10	183	88.0859	1.9429	0.8466

T-COFFEE

Matrix	Order
none	aligned
BLOSUM	aligned
PAM	input

Αποτελέσματα για το T-COFFEE

Total Sequences	Alignment Length	Percent Identity	Percent Gaps	Normalized SP Score
10	183	88.2412	1.9794	0.8475
10	183	88.2412	1.9794	0.8475
10	183	88.1714	1.9551	0.8472

Η μόνη μέθοδος που κατάφερε να διαφοροποιηθεί ελαφρώς ήταν το **T-COFFEE**, το οποίο αύξησε το **Percent Identity στο 88.24%**. Αυτό οφείλεται στην πιο σύνθετη φύση του αλγορίθμου, ο οποίος χτίζει μια βιβλιοθήκη συνέπειας (consistency library) πριν την τελική ευθυγράμμιση. Ωστόσο, αυτή η μικρή βελτίωση στην ταύτιση των αμινοξέων συνοδεύτηκε από μια μικρή αύξηση στα κενά (**1.97% Gaps** έναντι **1.94%**), επιβεβαιώνοντας τη μόνιμη υπολογιστική ανταλλαγή (trade-off) μεταξύ ακρίβειας ταύτισης και εισαγωγής κενών.

Η προσπάθεια χρήσης του **FFT (Fast Fourier Transform)** με τη ρύθμιση **localpair** και αυξημένο **Max Iterate (10)** αποσκοπούσε στη μεγιστοποίηση της τοπικής ακρίβειας. Ενώ θεωρητικά αυτή η ρύθμιση (L-INS-i) είναι η πλέον ακριβής του MAFFT, η εμφάνιση σφαλμάτων κατά την εκτέλεση αναδεικνύει την ευαισθησία των προχωρημένων αλγορίθμων στη δομή των αρχείων εισόδου (FASTA format). Η χρήση του **BLOSUM80** σε συνδυασμό με αυστηρότερες ποινές κενών (**Gap Open 2.5**) είναι η ορθότερη προσέγγιση

για τόσο όμοιες πρωτεΐνες, καθώς περιορίζει τις λανθασμένες ευθυγραμμίσεις σε περιοχές με μεταβλητότητα.

1.5 Μία άλλη αξιολόγηση

Όπου παίρνουμε διάφορα παραδείγματα και τα ξανά αξιολογούμε με αποτέλεσμα να έχουμε σε όλες τις κατηγορίες το ίδιο αποτέλεσμα όπως μπορούμε να δούμε και παρακάτω.

FINAL ALIGNMENT COMPARISON (High Precision)						
Method	Total Seqs	Length	Percent Identity	Percent Gaps	Normalized SP Score	
MAFFT Default	10	170	96.0544	6.7647	0.8306	
MAFFT Custom	10	170	96.0544	6.7647	0.8306	
MAFFT Custom	10	170	96.0544	6.7647	0.8306	
MUSCLE Default	10	170	96.0544	6.7647	0.8306	
MUSCLE First	10	170	96.0544	6.7647	0.8306	
MUSCLE Second	10	170	96.0544	6.7647	0.8306	
T-COFFEE Default	10	170	96.0544	6.7647	0.8306	
T-COFFEE Blosum Aligned	10	170	96.0544	6.7647	0.8306	
T-COFFEE PAM Input	10	170	96.0544	6.7647	0.8306	

Εικόνα 10: Μία Άλλη Αξιολόγηση

Μετέπειτα Αξιολόγηση που Διαφέρει

Συμπερασματικά, για μελέτες φυλογενετικής ή δομικής βιολογίας με αλληλουχίες υψηλής ομοιότητας, οι προκαθορισμένες (default) παράμετροι των σύγχρονων εργαλείων είναι εξαιρετικά αξιόπιστες. Οι εξειδικευμένες ρυθμίσεις και οι αλγόριθμοι όπως το T-COFFEE προσφέρουν οριακές βελτιώσεις, οι οποίες όμως αποκτούν ουσιαστική σημασία μόνο όταν οι πρωτεΐνες εισόδου παρουσιάζουν μεγαλύτερη εξελικτική απόσταση (κάτω από 50-60% identity), όπου η σωστή επιλογή του πίνακα αντικατάστασης (Matrix) και των FFTs καθίσταται κρίσιμη για την αποφυγή σφαλμάτων.

Αξίζει να σημειωθεί ότι η σημασία των παραμέτρων **FFT** και η ευαισθησία του αλγορίθμου έγιναν ακόμα πιο σαφείς κατά τη σύγκριση με τα δεδομένα της πρωτεΐνης **NP_000137**. Σε εκείνη την περίπτωση, η ενεργοποίηση των FFTs και η σωστή παραμετροποίηση επέφεραν ορατές αλλαγές στα αποτελέσματα, επιτρέποντας μια πιο λεπτομερή ανάλυση της ευθυγράμμισης. Η αντίθεση αυτή μεταξύ των δύο σετ δεδομένων προσφέρει ένα ολοκληρωμένο συμπέρασμα: ενώ σε πολύ όμοιες αλληλουχίες οι αλλαγές μπορεί να φαίνονται αμελητέες, η χρήση προχωρημένων εργαλείων όπως το FFT είναι καθοριστική για την εξαγωγή ακριβέστερων βιολογικών συμπερασμάτων όταν η πολυπλοκότητα των δεδομένων το απαιτεί.

MATRIX	GAP OPEN PENALTY	GAP EXTENSION PENALTY	MAX ITERATE	PERFORM FFTS	Περιγραφή (Description)
BLOSUM62	1.53	0.123	2	none	Default

MATRIX	GAP OPEN PENALTY	GAP EXTENSION PENALTY	MAX ITERATE	PERFORM FFTS	Περιγραφή (Description)
BLOSUM45	1.0	0.2	100	localpair	Για local motifs, υψηλής ευαισθησίας
JTT PAM100	1.8	0.05	100	globalpair	Για ισχυρή global στοίχιση
BLOSUM30	1.0	0.15	5	genafpair	Ευέλικτη προσέγγιση για δύσκολες περιπτώσεις

Λαμβάνουμε τα αποτελέσματα που είναι:

Total Sequences	Alignment Length	Percent Identity	Percent Gaps	Normalized SP Score
10	267	99.1005	17.1536	0.6510
10	261	98.9872	16.3729	0.6657
10	261	98.9619	16.3729	0.6656
10	267	99.0751	17.1536	0.6509

Από την ανάλυση των δεδομένων προκύπτει ότι όλες οι στοιχίσεις παρουσιάζουν εξαιρετικά υψηλή συνάφεια, με το ποσοστό ταυτότητας (Percent Identity) να κυμαίνεται μεταξύ 98.96% και 99.10%, γεγονός που υποδηλώνει ότι οι αλληλουχίες είναι πολύ παρόμοιες και οι αλλαγές στις παραμέτρους δεν επηρεάζουν δραστικά τη συνολική ομοιομορφία. Η μέγιστη τιμή ταυτότητας (99.1005%) επιτυγχάνεται με τις προκαθορισμένες (default) ρυθμίσεις (BLOSUM62, none), ενώ οι επιλογές BLOSUM45 και JTT PAM100 οδηγούν σε ελαφρώς χαμηλότερα ποσοστά (98.96%–98.98%), πιθανώς λόγω της έμφασης που δίνουν σε διαφορετική ευαισθησία για συντηρημένες ή εξελικτικά παλαιότερες περιοχές. Τέλος, αυτή η μικρή απόκλιση στο ποσοστό ταυτότητας

συνοδεύεται από πιο αισθητές διαφοροποιήσεις σε άλλες μετρικές, όπως το ποσοστό κενών (gaps) που κυμαίνεται από 16.37% έως 17.15% και το SP score, στοιχεία που αποτυπώνονται αναλυτικά στον πίνακα των στατιστικών.

Ερώτημα 2

2.1 Αναζήτηση Cytochrome c - Homo sapiens

Ο κύριος σκοπός της παρούσας εργασίας είναι η μελέτη της **εξελικτικής διατήρησης** της πρωτεΐνης **Cytochrome C** (Κυτόχρωμα C) εντός της κλάσης των θηλαστικών (**Mammalia**). Το Κυτόχρωμα C είναι μια εξαιρετικά σημαντική πρωτεΐνη που συμμετέχει στην αναπνευστική αλυσίδα των μιτοχονδρίων και η δομή της παραμένει σε μεγάλο βαθμό σταθερή κατά τη διάρκεια της εξέλιξης λόγω του κρίσιμου ρόλου της στην παραγωγή ενέργειας.

Ως σημείο αναφοράς για τη σύγκριση επιλέχθηκε η ανθρώπινη πρωτεΐνη (Homo sapiens), η οποία εντοπίστηκε στη βάση δεδομένων **UniProt** με τον μοναδικό κωδικό πρόσβασης (Accession Number) **P99999**.

Κάνουμε την αναζήτηση και παρατηρούμε το κυτόχρωμα C με όλα τα απαραίτητα δεδομένα και αναζητήσεις που έχουν γίνει ως τούτου. Που μπορείτε να τα παρατηρήσετε και εδώ: <https://www.uniprot.org/uniprotkb/P99999/entry>

P99999 · CYC_HUMAN

Protein¹ | Cytochrome c
Gene¹ | CYCS
Status¹ | UniProtKB reviewed (Swiss-Prot)
Organism¹ | Homo sapiens (Human)

Amino acids | 105 (go to sequence)
Protein existence¹ | Evidence at protein level
Annotation score¹ | C-S

Entry Variant viewer¹ Feature viewer Genomic coordinates Publications External links History

Tools Download Add Add a publication Entry feedback

Function¹
Electron carrier protein. The oxidized form of the cytochrome c heme group can accept an electron from the heme group of the cytochrome c1 subunit of cytochrome reductase. Cytochrome c then transfers this electron to the cytochrome oxidase complex, the final protein carrier in the mitochondrial electron-transport chain.
Plays a role in apoptosis. Suppression of the anti-apoptotic members or activation of the pro-apoptotic members of the Bcl-2 family leads to altered mitochondrial membrane permeability resulting in release of cytochrome c into the cytosol. Binding of cytochrome c to Apaf-1 triggers the activation of caspase-9, which then accelerates apoptosis by activating other caspases.

Features
Showing features for binding site¹.

Download

10 20 30 40 50 60 70 80 90 100 39

±	TYPE	ID	POSITION(S)	DESCRIPTION
+	Binding site	15		heme c (UniProtKB ChEBI C ²); covalent PROSITE-ProRule Annotation 1 Publication
+	Binding site	18		heme c (UniProtKB ChEBI C ²); covalent PROSITE-ProRule Annotation 1 Publication

Εικόνα 11: Στιγμιότυπο από UniProt σχετικά για το κυτόχρωμα C.

2.2. Χρήση Κώδικα και Σταδιακή Ανάκτηση Πληροφορίας

Με βάση τα βήματα που περιγράφει η εκφώνηση, χρησιμοποιούμε την βιβλιοθήκη Biopython με αποτέλεσμα να πετύχουμε τα συγκεκριμένα βήματα:

- **Fetching:** Σύνδεση με τη βάση δεδομένων NCBI μέσω της μονάδας Entrez για την αυτόματη λήψη της αλληλουχίας της ανθρώπινης πρωτεΐνης (Accession Number: P99999) σε μορφή FASTA.
- **BLAST Query:** Χρήση του αλγορίθμου BLASTP μέσω της συνάρτησης qblast. Η αναζήτηση περιορίστηκε αυστηρά εντός της κλάσης των θηλαστικών μέσω της παραμέτρου `entrez_query="Mammalia[Orgn]"`, ώστε να εντοπιστούν μόνο σχετικές ομόλογες αλληλουχίες.
- **Data Collection & Parsing:** Αυτό το κρίσιμο στάδιο περιλαμβάνει την ανάγνωση των αποτελεσμάτων που επέστρεψε το BLAST σε μορφή XML. Χρησιμοποιώντας την κλάση `NCBIXML.read`, ο κώδικας πραγματοποιεί parsing του αρχείου για να εξάγει τα Accession IDs των επικρατέστερων αποτελεσμάτων (hits). Στη συνέχεια, για κάθε hit, πραγματοποιείται νέο αίτημα `efetch` ώστε να ανακτηθεί η πλήρης αλληλουχία αμινοξέων του κάθε οργανισμού.
- **Pairwise Alignment:** Για κάθε ομόλογη πρωτεΐνη που αναλύθηκε, πραγματοποιήθηκε στοίχιση ανά ζεύγη (pairwise alignment) με την ανθρώπινη αλληλουχία αναφοράς, χρησιμοποιώντας το εργαλείο `PairwiseAligner`.
- **Identity Calculation:** Ανάπτυξη συνάρτησης για τον υπολογισμό του ποσοστού ταυτότητας (Identity %). Η συνάρτηση συγκρίνει τις αλληλουχίες θέση-προς-θέση (\$i\$) και μετράει τον αριθμό των ταυτώσεων αμινοξέων προς το συνολικό μήκος της αλληλουχίας.

Τα παραπάνω βήματα περιγράφονται και στο κώδικα που έχουμε παρακάτω με σταδιακή εκτέλεση και ανάλυση έτσι ώστε να έχουμε τα αποτελέσματα. Παραθέτουμε και ένα email στην αρχή του κώδικα επειδή ο NCBI ζητάει το email μας ώστε, αν κατά λάθος το πρόγραμμα μας κάνει πάρα πολλά αιτήματα το δευτερόλεπτο και "κουράσει" τους servers τους, να μπορούν να επικοινωνήσουν μαζί μας πριν μας κόψουν την πρόσβαση με block. Αλλά και για να ελέγχουν ότι οι χρήστες είναι πραγματικοί άνθρωποι και όχι κακόβουλα bots.

Ο κώδικας που εκτελούμε είναι ο (**ex2.py**) συγκεκριμένος:

```
from Bio import Entrez, SeqIO
from Bio.Blast import NCBIWWW, NCBIXML
from Bio.Align import PairwiseAligner

# Πυθμίσεις Entrez
Entrez.email = "up1084672@ac.upatras.gr" # Βάλε το email σου εδώ
human_id = "P99999"

# --- BHMA 1: Fetching της ανθρώπινης πρωτεΐνης ---
print(f"Ανάκτηση αλληλουχίας για το ID: {human_id}...")
with Entrez.efetch(db="protein", id=human_id, rettype="fasta",
retmode="text") as handle:
    human_record = SeqIO.read(handle, "fasta")
    human_seq = human_record.seq

print(f"Η αλληλουχία ανακτήθηκε: {human_record.description[:50]}...")

# --- BHMA 2: BLAST Query (Περιορισμός στα Mammalia) ---
print("Εκτέλεση BLASTP στα Mammalia (αυτό μπορεί να πάρει λίγη
ώρα)...")
result_handle = NCBIWWW.qblast(
    program="blastp",
    database="nr",
```

```

sequence=human_seq,
entrez_query="Mammalia[Orgn]",
hitlist_size=5 # Περιορίζουμε στα πρώτα 5 hits για ταχύτητα
)

# --- BHMA 3: Data Collection & Parsing ---
blast_record = NCBIXML.read(result_handle)
aligner = PairwiseAligner()

print("\n--- ΑΠΟΤΕΛΕΣΜΑΤΑ ΣΥΓΚΡΙΣΗΣ ---")
print(f"{'Accession':<15} | {'Description':<40} | {'Identity %'}")
print("-" * 75)

for alignment in blast_record.alignments:
    hit_id = alignment.accession
    hit_def = alignment.hit_def

    # Ανάκτηση της αλληλουχίας του "hit" για ακριβή σύγκριση
    with Entrez.efetch(db="protein", id=hit_id, rettype="fasta",
retmode="text") as h_handle:
        hit_record = SeqIO.read(h_handle, "fasta")
        hit_seq = hit_record.seq

    # --- BHMA 4 & 5: Alignment & Identity Calculation ---
    # Κάνουμε pairwise alignment
    alignments = aligner.align(human_seq, hit_seq)
    best_alignment = alignments[0]

    # Υπολογισμός ταυτότητας βάσει του ορισμού της άσκησης:
    # Μετράμε πόσα αμινοξέα είναι ίδια στις αντίστοιχες θέσεις
    matches = 0
    # Χρησιμοποιούμε το μικρότερο μήκος για αποφυγή index error αν
διαφέρουν
    min_len = min(len(human_seq), len(hit_seq))

    for i in range(min_len):
        if human_seq[i] == hit_seq[i]:
            matches += 1

    identity_percentage = (matches / len(human_seq)) * 100

    print(f"{'hit_id':<15} | {'hit_def[:40]':<40} |
{'identity_percentage:.2f}%")

```

Μετά την εκτέλεση του κώδικα έχουμε το αποτέλεσμα:

```
Ανάκτηση αλληλουχίας για το ID: P99999...
Η αλληλουχία ανακτήθηκε: sp|P99999.2|CYC_HUMAN RecName: Full=Cytochrome c...
Εκτέλεση BLASTP στα Mammalia (αυτό μπορεί να πάρει λίγη ώρα)...

--- ΑΠΟΤΕΛΕΣΜΑΤΑ ΣΥΓΚΡΙΣΗΣ ---
Accession      | Description                                     | Identity %
-----
NP_001065289   | cytochrome c [Pan troglodytes] >ref|NP_0    | 100.00%
XP_055149593   | cytochrome c isoform X1 [Symphalangus sy    | 8.57%
XP_003895289   | cytochrome c [Papio anubis] >ref|XP_0038    | 99.05%
AAH68464       | Cytochrome c, somatic [Homo sapiens]         | 99.05%
AEP27195       | cytochrome c [Symphalangus syndactylus]     | 99.05%
PS C:\Users\User\Desktop\bioinfo\2> █
```

Εικόνα 12: Αποτέλεσμα Κώδικας Cytochrome C και Εκτέλεση BLASTP στα Mammalia

Το γεγονός ότι βλέπουμε ποσοστά κοντά στο 100% επιβεβαιώνει ότι το Κυτόχρωμα C είναι μια τρομερά συντηρημένη πρωτεΐνη στα θηλαστικά.

Συνεχίζουμε με μία σύντομα περιγραφή με όλα τα δεδομένα που έχουμε σαν αποτέλεσμα:

1. Pan troglodytes (Χιμπατζής) - 100.00%

Αυτό είναι αναμενόμενο. Ο χιμπατζής είναι ο πλησιέστερος εξελικτικός συγγενής του ανθρώπου, και η συγκεκριμένη πρωτεΐνη είναι πανομοιότυπη και στα δύο είδη.

2. Papio anubis & Symphalangus syndactylus - 99.05%

Πρόκειται για έναν Μπαμπούινο και έναν Γίββωνα. Το **99.05%** σημαίνει ότι σε ολόκληρη την πρωτεΐνη (περίπου 105 αμινοξέα), μόνο **ένα** αμινοξύ είναι διαφορετικό σε σχέση με τον άνθρωπο. Αυτό δείχνει την τεράστια ομοιότητα μεταξύ των πρωτευνόντων θηλαστικών.

3. Το παράξενο αποτέλεσμα (XP_055149593) - 8.57%

Αυτό το **8.57%** είναι πολύ χαμηλό για θηλαστικό. Αυτό συμβαίνει συνήθως για έναν από τους δύο λόγους:

- Είναι μια isoform, δηλαδή μια εναλλακτική μορφή που μπορεί να μην είναι η κύρια λειτουργική πρωτεΐνη.
- Μπορεί να είναι ένα partial sequence (ατελής αλληλουχία) που υπάρχει στη βάση δεδομένων, οπότε ο αλγόριθμος σύγκρινε μόνο ένα μικρό κομμάτι της.

Το τρίτο και τελευταίο αποτέλεσμα είναι μία πιθανή ατελή αλληλουχία ή εναλλακτική ισομορφή που δεν αντιπροσωπεύει την κύρια λειτουργική πρωτεΐνη.

2.3 Απαντήσεις στα Ερωτήματα

Με βάση την εκτέλεση του κώδικα και τα αποτελέσματα που έχουμε με την αναζήτηση, ακολουθούν οι απαντήσεις στα ερωτήματα (ερώτηση/απάντηση):

- **Στο βήμα 2 για ποιους λόγους χρησιμοποιήθηκε ο αλγόριθμος blastp η βάση nr και για πιο λόγο θέλουμε να περιορίσουμε τη σύγκριση στα θηλαστικά; Τι αναμένετε να συμβεί αν δεν περιοριστεί η αναζήτηση;**

Χρησιμοποιήθηκε blastp επειδή η αλληλουχία εισόδου μας (query) είναι πρωτεΐνη και θέλουμε να την συγκρίνουμε με άλλες πρωτεΐνες. Αν είχαμε DNA, θα χρησιμοποιούσαμε blastn.

Η Βάση nr (Non-redundant) είναι η πληρέστερη βάση δεδομένων του NCBI. Περιέχει όλες τις γνωστές πρωτεΐνες χωρίς διπλότυπες εγγραφές, εξασφαλίζοντας ότι η αναζήτησή μας καλύπτει όλα τα καταγεγραμμένα είδη.

Ο Περιορισμός στα θηλαστικά και ο στόχος της άσκησης είναι η μελέτη της διατήρησης εντός μιας συγκεκριμένης κλάσης. Αν δεν περιορίζαμε την αναζήτηση, το BLAST θα επέστρεφε εκατοντάδες αποτελέσματα από βακτήρια, φυτά και μύκητες (καθώς το Κυτόχρωμα C υπάρχει σε όλους τους ευκαρυωτικούς οργανισμούς). Αυτό θα έκανε την ανάλυση των θηλαστικών πολύ δύσκολη λόγω του όγκου άσχετων δεδομένων.

- **Αν κατά την αναζήτηση BLAST θέταμε πολύ "χαλαρά" κριτήρια (π.χ. πολύ υψηλό Evalue), ποιος θα ήταν ο κίνδυνος για τα αποτελέσματα της στοίχισης;**

Αν θέσουμε πολύ υψηλό E-value, το BLAST θα επιστρέψει αλληλουχίες που έχουν πολύ μικρή ομοιότητα με την ανθρώπινη.

Όμως στο στάδιο της στοίχισης (alignment), οι αλληλουχίες αυτές δεν θα "κουμπώνουν" καλά. Το ποσοστό ταυτότητας θα είναι εξαιρετικά χαμηλό και τα συμπεράσματά μας για την εξελικτική συγγένεια θα είναι λανθασμένα, καθώς θα συγκρίνουμε μη ομόλογες πρωτεΐνες (ψευδώς θετικά αποτελέσματα).

- **Υπάρχουν περιοχές στην πρωτεΐνη που είναι απόλυτα συντηρημένες (100% ταυτότητα) σε όλα τα αποτελέσματα της αναζήτησης ;**

Το Κυτόχρωμα C έχει συγκεκριμένες περιοχές που είναι κρίσιμες για τη λειτουργία του (π.χ. το σημείο πρόσδεσης της ομάδας αίμης - heme binding site).

Για να το επιβεβαιώσουμε με κώδικα, θα χρειαζόταν μια Πολλαπλή Στοίχιση (Multiple Sequence Alignment) που δεν είναι διαθέσιμο. Από τα αποτελέσματα που πήραμε (99% και 100%), φαίνεται ότι σχεδόν όλη η πρωτεΐνη είναι συντηρημένη στα θηλαστικά, καθώς μόνο 1-2 αμινοξέα αλλάζουν.

- **Ποια είδη παρουσιάζουν μεγαλύτερη απόκλιση από τον άνθρωπο;**

Ο Χιμπατζής (*Pan troglodytes*) έχει μηδενική απόκλιση (100% identity).

Ο Μπαμπούνος (*Papio anubis*) και ο Γίββωνας (*Symphalangus syndactylus*) παρουσιάζουν μικρή απόκλιση (~99%).

Μεγαλύτερη απόκλιση θα παρουσίαζαν θηλαστικά που δεν ανήκουν στα Πρωτεύοντα (π.χ. τρωκτικά ή οπληφόρα), αν είχαμε αυξήσει το πλήθος των αποτελεσμάτων. Τέλος, στην περίπτωση μας το αποτέλεσμα με 8.57% (*Symphalangus*) είναι τεχνικό σφάλμα της βάσης (partial sequence) και δεν αποτελεί πραγματική εξελικτική απόκλιση.

Ερώτημα 3

3.1 Ορισμός και Αναζήτηση Αλληλουχίας με Χρήση Κώδικα

Αρχικά για το πρώτο υποερώτημα του ερωτήματος με βάση και των υποδείξεων της εκφώνησης θα χρησιμοποιήσουμε έναν κώδικα με βιβλιοθήκη `biopython` όπου αυτός ο κώδικας θα στέλνει την αλληλουχία `GIVEQCCTSIICSLYQLENYCN` στη βάση δεδομένων του NCBI μέσω BLAST.

Ο κώδικας `sequence_search_with_filter.py` που χρησιμοποιούμε είναι:

```
from Bio.Blast import NCBIWWW
from Bio.Blast import NCBIXML

# Βήμα 1: Ορισμός της αλληλουχίας
sequence = "GIVEQCCTSIICSLYQLENYCN"

print("Εκτέλεση BLAST... Παρακαλώ περιμένετε (μπορεί να πάρει 5-6
λεπτά).")

# Βήμα 2: Χρήση της qblast
# Αν θέλουμε αναζήτηση ΜΟΝΟ για ανθρώπους, βάζουμε # στην αρχή των
2ον και 3ον φίλτρων.
# Αν θέλουμε τη βασική αναζήτηση, βάζουμε ένα # στην αρχή των 1ον και
3ον.
# Αν θέλουμε να περιορίσουμε την αναζήτηση μόνο σε "Bacteria"
χρησιμοποιούμε το 3ο φίλτρο και βάζουμε # στα άλλα δύο παραπάνω

#result_handle = NCBIWWW.qblast("blastp", "nr", sequence,
entrez_query="Homo sapiens[ORGN]") # Φίλτρο Ανθρώπου
#result_handle = NCBIWWW.qblast("blastp", "nr", sequence) # Βασική
αναζήτηση
result_handle = NCBIWWW.qblast("blastp", "nr", sequence,
entrez_query="Bacteria[ORGN]") # Bacteria ΓΙΑ ΤΟ ΤΕΛΕΥΤΑΙΟ ΥΠΟΕΡΩΤΗΜΑ

# Βήμα 3: Ανάγνωση αποτελεσμάτων
blast_record = NCBIXML.read(result_handle)

# Εύρεση του πρώτου hit (με το χαμηλότερο E-value)
if blast_record.alignments:
    first_alignment = blast_record.alignments[0]
    hsp = first_alignment.hsps[0]

    print("\n--- Αποτελέσματα BLAST ---")
    print(f"Πρωτεΐνη/Τίτλος: {first_alignment.title}")
    print(f"E-value: {hsp.expect}")
else:
    print("Δεν βρέθηκαν αποτελέσματα.")
```

Με χρήση της βιβλιοθήκης `biopython` που αναφερθήκαμε πραγματοποιείται μια αυτοματοποιημένη αναζήτηση **BLAST** μέσω του διαδικτύου. Αρχικά, ορίζει μια αλληλουχία αμινοξέων και την αποστέλλει στους διακομιστές του NCBI χρησιμοποιώντας

τη συνάρτηση qblast, η οποία συγκρίνει την αλληλουχία με τη βάση δεδομένων μη-πλεοναζουσών πρωτεϊνών (nr).

Στη συνέχεια, το πρόγραμμα διαβάσει την απόκριση σε μορφή XML και εξάγει **το πρώτο και πιο σημαντικό αποτέλεσμα** (όπως αναφέρετε στην εκφώνηση) το "hit" με το χαμηλότερο **E-value**, εκτυπώνοντας την περιγραφή της πρωτεΐνης που ταιριάζει περισσότερο καθώς και τη στατιστική πιθανότητα η αντιστοίχιση να είναι τυχαία.

Με χρήση της βιβλιοθήκης **biopython** που αναφερθήκαμε πραγματοποιείται μια αυτοματοποιημένη αναζήτηση **BLAST** στα servers του NCBI. Αρχικά, ορίζει μια αλληλουχία αμινοξέων και τη στέλνει μέσω της συνάρτησης qblast για σύγκριση με τη βάση δεδομένων πρωτεϊνών (nr).

Στη συνέχεια, το πρόγραμμα λαμβάνει τα αποτελέσματα σε μορφή XML, τα αναλύει (parsing) και εκτυπώνει την πρώτη και πιο σημαντική αντιστοιχία που βρέθηκε, εμφανίζοντας τον τίτλο της πρωτεΐνης και το **E-value**, το οποίο υποδεικνύει τη στατιστική σημαντικότητα της ομοιότητας.

Τέλος, με την εκτέλεση του κώδικα παρατηρούμε ότι έχουμε το αποτέλεσμα:

```
--- Αποτελέσματα BLAST ---  
Πρωτεΐνη/Τίτλος: ref|XP_026338704.1| insulin [Ursus arctos] >ref|XP_040495583.1| insulin [Ursus maritimus]  
E-value: 1.64815e-05
```

Εικόνα 13: 1^η Περίπτωση → Αποτέλεσμα εκτέλεσης κώδικα για αναζήτηση BLAST χωρίς φίλτρα

Με βάση το παραπάνω αποτέλεσμα η πρωτεΐνη που βρίσκουμε είναι η Ινσουλίνη (Insulin), ενώ σαν οργανισμούς βρίσκουμε τα *Ursus arctos* και *Ursus maritimus* που είναι η καφέ και πολική αρκούδα αντίστοιχα.

Από το παραπάνω αποτέλεσμα βλέπουμε ότι το BLAST βρήκε **πολλαπλές καταχωρήσεις** που έχουν την **ίδια ακριβώς αλληλουχία**. Αντί να μας γεμίσει την οθόνη με 50 γραμμές που όλες λένε το ίδιο πράγμα, τις συμπύσσει σε μία γραμμή. Που το κάνει για λόγους redundancy για το λόγο ότι στις βάσεις δεδομένων υπάρχουν εκατομμύρια πρωτεΐνες. Πολλές από αυτές είναι ίδιες μεταξύ τους.

Βέβαια επειδή γίνεται η ομαδοποίηση και σταματάμε την αναζήτηση στο πρώτο hit δεν βλέπουμε και θα βλέπαμε και άλλα τέτοια γκρουπ που περιλαμβάνουν τον άνθρωπο, τον χοίρο ή τον χιμπατζή.

Η αλληλουχία της ινσουλίνης (Α-αλυσίδα) είναι **100% ίδια** στον άνθρωπο, στην καφέ αρκούδα και στην πολική αρκούδα. Δεν υπάρχει ούτε ένα αμινοξύ διαφορά. Επειδή η ταύτιση είναι 100% και στα τρία είδη, το «σκορ» είναι ακριβώς το ίδιο. Όταν υπάρχει ισοπαλία, το BLAST δεν έχει βιολογικό κριτήριο για να διαλέξει.

Το σύστημα εμφανίζει αυτό που καταχωρήθηκε πιο πρόσφατα στη βάση δεδομένων ή αυτό που έχει τον μικρότερο κωδικό πρόσβασης (accession number). Στην παρούσα φάση, οι αρκούδες έτυχε να είναι πιο ψηλά στη λίστα του NCBI από τον άνθρωπο.

Παρόλο αυτό όμως, σε περίπτωση που θέλουμε να δούμε και αποτελέσματα από άνθρωπο σαν δείγματα (*homo sapiens*) έχουμε προσθέσει στο κώδικα το φίλτρο που μας εμφανίζει μόνο τις ανθρώπινες αλληλουχίες, με βάση τις οδηγίες που προσθέσαμε στο

κώδικα σαν σχόλιο μπορούμε να κάνουμε αυτή την μετατροπή και να επισημαίνουμε το αποτέλεσμα:

```
--- Αποτελέσματα BLAST ---
Πρωτεΐνη/Τίτλος: gb|QMS45321.1| insulin isoform U1 [Homo sapiens]
E-value: 8.33139e-09
```

Εικόνα 14: 2^η Περίπτωση → Αποτέλεσμα εκτέλεσης κώδικα για αναζήτηση BLAST με φίλτρο homo sapiens

Σε περίπτωση που θέλουμε να δούμε τα πρώτα 5 αποτελέσματα έχουμε αυτά τα 5 πρώτα που πράγματι οι αρκούδες είναι οι πρώτες αναλόγως το e-value. Ο κώδικας που χρησιμοποιήσαμε για τα πρώτα 5 αποτελέσματα είναι το **seq_top_5_results.py**

```
--- Εμφάνιση των πρώτων 5 αποτελεσμάτων ---
Hit #1:
Πρωτεΐνη/Τίτλος: ref|XP_026338784.1| insulin [Ursus arctos] >ref|XP_048495583.1| insulin [Ursus maritimus]
E-value: 1.64915e-05
Score: 114.0
-----
Hit #2:
Πρωτεΐνη/Τίτλος: ref|XP_045626785.1| insulin [Ursus americanus]
E-value: 1.93819e-05
Score: 113.0
-----
Hit #3:
Πρωτεΐνη/Τίτλος: gb|KAG8522541.1| Insulin [Galomys pyrenaeus]
E-value: 2.43184e-05
Score: 113.0
-----
Hit #4:
Πρωτεΐνη/Τίτλος: ref|XP_081389424.1| insulin [Giraffa tippelskirchi] >ref|XP_081389425.1| insulin [Giraffa tippelskirchi]
E-value: 3.11111e-05
Score: 112.0
-----
Hit #5:
Πρωτεΐνη/Τίτλος: ref|XP_076971473.1| insulin isoform X2 [Tamandua tetradactyla]
E-value: 3.89632e-05
Score: 111.0
-----
```

Εικόνα 15: 5 πρώτα αποτελέσματα με την αναζήτηση BLAST

3.2 Επιβεβαίωση Λειτουργίας Πρωτεΐνης μέσω Βιβλιογραφική Αναζήτηση

Αρχικά, αν κάνουμε μία αναζήτηση στην βάση δεδομένων του NCBI με τις παρακάτω παραμέτρους:


The screenshot shows the NCBI BLAST search interface. The 'Enter Query Sequence' section has a text box containing 'GIVEQCCTSCISLYQLENYCN'. Below it, there are options for 'Or, upload file' (Choose File, No file chosen) and 'Job Title' (Enter a descriptive title for your BLAST search). There is also a checkbox for 'Align two or more sequences'. The 'Choose Search Set' section has a 'Database' dropdown set to 'ClusteredNR (nr cluster seq)' and an 'Organism' dropdown set to 'Homo sapiens (taxid:9606)'. There is an 'Add organism' button and a note about showing top taxa. The 'Program Selection' section has a radio button selected for 'blastp (protein-protein BLAST)' and an option for 'PSI-BLAST (Position-Specific Iterated BLAST)'. At the bottom, there is a 'BLAST' button and a checkbox for 'Show results in a new window'.

Εικόνα 16: Αναζήτηση Ινσουλίνης σε Βάση Δεδομένων NCBI

Σαν αποτέλεσμα πράγματι, θα έχουμε την ινσουλίνη που μας επιβεβαιώνει ότι η αλληλουχία που έχουμε ανήκει στην αναφερόμενη διαδικασία. Κάνοντας BLAST το βλέπουμε:

select all 97 clusters selected		GenPept		Graphics	Distance tree of results	Multiple alignment	MSA Viewer			
	Cluster Composition	Cluster Ancestor	Cluster Representative Sequence	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
	Click the  to see the cluster contents									
☒	32 member(s), 6 organism(s)	root	Chain A, Insulin [Homo sapiens]	75.3	75.3	100%	3e-19	100.00%	22	5MHD_A
☒	8 member(s), 3 organism(s)	placentals	Chain A, Insulin [Homo sapiens]	75.3	75.3	100%	6e-18	100.00%	53	8PIH_A
☒	2 member(s), 2 organism(s)	human	mini-proinsulin, partial [synthetic construct]	75.3	75.3	100%	8e-18	100.00%	59	ABP93829.1
☒	1 member(s), 1 organism(s)	human	Chain A, Insulin B chain, Insulin A chain [Homo sapiens]	75.3	75.3	100%	1e-17	100.00%	63	8PI6_A
☒	1 member(s), 1 organism(s)	human	Chain D, Insulin [Homo sapiens]	75.3	75.3	100%	2e-17	100.00%	74	6PXV_D
☒	5 member(s), 5 organism(s)	primates	INS isoform 5 [Pongo abelii]	75.3	75.3	100%	3e-17	100.00%	98	PNU16423.1
☒	3 member(s), 3 organism(s)	primates	insulin [Pan paniscus]	75.3	75.3	100%	3e-17	100.00%	204	XP_034787832.1
☒	18 member(s), 12 organism(s)	placentals	insulin preproprotein [Pan troglodytes]	75.3	75.3	100%	3e-17	100.00%	110	NP_001008996.1
☒	5 member(s), 5 organism(s)	primates	insulin isoform X1 [Macaca nemestrina]	75.3	75.3	100%	3e-17	100.00%	153	XP_011719619.2
☒	1 member(s), 1 organism(s)	unclassified sequences	Chain A, Insulin [unidentified]	69.4	69.4	100%	1e-15	95.24%	57	2JZQ_A
☒	1 member(s), 1 organism(s)	human	Chain A, INSULIN [Homo sapiens]	63.0	63.0	81%	1e-14	100.00%	17	2W44_A
☒	1 member(s), 1 organism(s)	human	Chain A, Insulin [Homo sapiens]	66.4	66.4	95%	2e-14	95.00%	59	6U46_A
☒	1 member(s), 1 organism(s)	human	Chain A, Insulin A chain [Homo sapiens]	61.7	61.7	100%	6e-14	85.71%	21	2L1Z_A
☒	13 member(s), 13 organism(s)	eukaryotes	RecName: Full=Insulin; Contains: RecName: Full=Insulin B chain...	62.6	62.6	100%	3e-13	85.71%	51	P67968.1
☒	2 member(s), 1 organism(s)	human	Chain A, Single-chain insulin analog [Homo sapiens]	61.7	61.7	100%	9e-13	90.48%	57	5WDM_A
☒	2 member(s), 2 organism(s)	placentals	unnamed protein product, partial [Homo sapiens]	30.3	30.3	95%	0.16	60.00%	49	CAA27156.1
☒	2 member(s), 1 organism(s)	human	Chain A, Insulin-like growth factor II [Homo sapiens]	30.3	30.3	95%	0.17	60.00%	69	SL3N_A
☒	4 member(s), 2 organism(s)	primates	IGF2 protein, partial [Callithrix jacchus]	30.3	30.3	95%	0.17	60.00%	72	CAA04657.1

Εικόνα 17: Αποτέλεσμα BLAST



Εικόνα 18: Αποτέλεσμα σε αναζήτηση μηχανής

Homo sapiens (Άνθρωπος): E-value: 8.33×10^{-9} (πολύ χαμηλό, άρα εξαιρετικά αξιόπιστο)

Ursus arctos / maritimus (Αρκούδα): E-value 1.64×10^{-5}

Τελικά, η πρωτεΐνη είναι η **ινσουλίνη**. Η λειτουργία της ως ορμόνη που ρυθμίζει το σάκχαρο είναι καθολική στα θηλαστικά (από τον άνθρωπο μέχρι την αρκούδα), γεγονός που εξηγεί γιατί το BLAST που έβγαλε παρόμοια αποτελέσματα για διαφορετικά είδη. Η υψηλή ομολογία (similarity) επιβεβαιώνει ότι πρόκειται για μια κρίσιμη, διατηρημένη πρωτεΐνη.

3.3 Απαντήσεις στα Ερωτήματα

Με βάση την εκτέλεση του κώδικα και τα αποτελέσματα που έχουμε με την αναζήτηση, ακολουθούν οι απαντήσεις στα ερωτήματα (ερώτηση/απάντηση):

- **Ποιο είναι το όνομα της πρωτεΐνης που βρήκε το BLAST και σε ποιον οργανισμό ανήκει; (Συμφωνεί με την υπόθεση ότι είναι "ανθρώπινη");**

Η ταυτοποίηση της αλληλουχίας επιβεβαιώνει ότι πρόκειται για την A-αλυσίδα της ινσουλίνης (**Insulin Chain A**). Παρόλο που τα αρχικά αποτελέσματα της ανάλυσης BLAST εμφάνισαν υψηλή συνάφεια με είδη αρκούδας (**Ursus arctos**, **Ursus maritimus**), η εφαρμογή του φίλτρου **entrez_query="Homo sapiens[ORGN]"**, για τον άνθρωπο (Homo sapiens) επιβεβαίωσε την παρουσία της πρωτεΐνης στον ανθρώπινο οργανισμό.

Το γεγονός αυτό συμφωνεί απόλυτα με την αρχική υπόθεση, καθώς η ινσουλίνη αποτελεί μια εξαιρετικά συντηρημένη πρωτεΐνη μεταξύ των θηλαστικών. Η εξελικτική αυτή διατήρηση εξηγεί γιατί η αλληλουχία παραμένει σχεδόν πανομοιότυπη σε διαφορετικά είδη, αντικατοπτρίζοντας τον κρίσιμο βιολογικό της ρόλο που παρέμεινε σταθερός κατά τη διάρκεια της εξέλιξης.

- **Αν το E-value του πρώτου αποτελέσματος είναι εξαιρετικά χαμηλό (κοντά στο μηδέν). Τι σημαίνει αυτό για την αξιοπιστία της απάντησης; Ποιο ήταν το E-Value της αναζήτησης που κάνατε;**

Το E-value (Expect value) εκφράζει την πιθανότητα η ομοιότητα που βρέθηκε να οφείλεται σε καθαρή τύχη. Όσο πιο κοντά στο μηδέν είναι, τόσο πιο στατιστικά σημαντικό είναι το αποτέλεσμα. Ένα τόσο χαμηλό E-value σημαίνει ότι η ταυτοποίηση είναι εξαιρετικά αξιόπιστη και δεν είναι τυχαία.

Στις δικές μας περιπτώσεις για τις αρκούδες και τον άνθρωπο όπως αναφερθήκαμε και παραπάνω έχουμε 1.64×10^{-5} και 8.33×10^{-9} αντίστοιχα. Παρόλο που τα αποτελέσματα δεν είναι ακριβώς μηδέν (λόγω του πολύ μικρού μήκους της αλληλουχίας των 21 αμινοξέων), θεωρείται πολύ ισχυρό αποτέλεσμα.

- **Με βάση μια απλή αναζήτηση, ποιος είναι ο κύριος ρόλος αυτής της πρωτεΐνης στο ανθρώπινο σώμα;**


Η ινσουλίνη είναι μια ορμόνη που παράγεται από τα β-κύτταρα του παγκρέατος. Ο βασικός της ρόλος είναι η ρύθμιση της γλυκόζης (σακχάρου) στο αίμα. Δρα ως κλειδί που επιτρέπει στη γλυκόζη να εισέλθει στα κύτταρα (κυρίως στους μύες και το ήπαρ) για να χρησιμοποιηθεί ως ενέργεια ή να αποθηκευτεί.

- **Αν τρέχατε το ίδιο BLAST με την αλληλουχία αυτή, αλλά περιορίζες την αναζήτηση μόνο σε "Bacteria" (μέσω `entrez_query`), τι αναμένετε ως αποτέλεσμα; Θα βρεθεί η ανθρώπινη ινσουλίνη ή κάτι άλλο; Μπορείτε να δοκιμάσετε να κάνετε την αναζήτηση αυτή**

Για το τελευταίο υποερώτημα του ερωτήματος θα χρησιμοποιήσουμε το φίλτρο που είναι γραμμένο στο κώδικα `sequence_search_with_filter.py`:

```
result_handle = NCBIWWW.qblast("blastp", "nr", sequence,
                                entrez_query="Bacteria[ORGN]")
```

που με την εκτέλεση του κώδικα με χρήση του παραπάνω φίλτρου παίρνουμε το αποτέλεσμα:



Εκτέλεση BLAST... Παρακαλώ περιμένετε (μπορεί να πάρει 5-6 λεπτά).
Δεν βρέθηκαν αποτελέσματα.

Εικόνα 19: Η χρήση φίλτρου *bacteria* δεν μας βγάζει κάποιο αποτέλεσμα

Παρατηρούμε ότι έχουμε το αναμενόμενο αποτέλεσμα το οποίο είναι το «Δεν βρέθηκαν αποτελέσματα». Ο λόγος είναι επειδή η ινσουλίνη είναι μια εξειδικευμένη ορμόνη των σπονδυλωτών. Η απουσία της από το βακτηριακό βασίλειο οφείλεται στην έλλειψη των απαραίτητων ενζυμικών μηχανισμών για τη σωστή αναδίπλωση της πρωτεΐνης, καθώς και στην απουσία εξελικτικής ανάγκης για ορμονική ρύθμιση της γλυκόζης σε μονοκύτταρους.

Αναλυτικά θα μπορούσαμε να πούμε ότι η ινσουλίνη είναι μια εξειδικευμένη ορμόνη των σπονδυλωτών, η οποία εξυπηρετεί την ανάγκη επικοινωνίας μεταξύ διαφορετικών οργάνων σε έναν πολυκύτταρο οργανισμό. Ένα μονοκύτταρο βακτήριο δεν διαθέτει κυκλοφορικό σύστημα ούτε την εξελικτική ανάγκη να ρυθμίσει τη γλυκόζη με ορμονικό τρόπο, καθώς απορροφά θρεπτικά συστατικά απευθείας από το περιβάλλον του.

Επιπλέον, η βιοσύνθεση της ινσουλίνης απαιτεί πολύπλοκους μηχανισμούς **μεταφραστικής τροποποίησης**, τους οποίους τα βακτήρια δεν διαθέτουν. Στο ανθρώπινο σώμα, η πρωτεΐνη παράγεται ως **preproinsulin** και υφίσταται συγκεκριμένες ενζυμικές κοπές και τη δημιουργία δισουλφιδικών δεσμών μέσα σε εξειδικευμένα οργάνδια, όπως το Ενδοπλασματικό Δίκτυο και η συσκευή Golgi. Τα βακτήρια στερούνται αυτών των δομών, με αποτέλεσμα, ακόμη και αν εισαχθεί τεχνητά το ανθρώπινο γονίδιο σε αυτά, να μην μπορούν να μοντάρουν τη λειτουργική μορφή της ορμόνης χωρίς ειδική εργαστηριακή παρέμβαση.

Ερώτημα 4

4.1 Εύρεση Μέγιστης Κοινής Υποακολουθίας Ανάμεσα σε SARS-CoV-2 και SARS-CoV-1

Αρχικά, μεταβαίνουμε στη βάση δεδομένων NCBI όπου βρίσκουμε το RefSeq (Reference Sequence) για το πλήρες γονιδίωμα του κορονοϊού SARS-CoV-2. Από εκεί μπορούμε να δούμε ολόκληρη τη νουκλεοτιδική αλληλουχία RNA του ιού καθώς και annotations που περιγράφουν:

- Ποια τμήματα του γονιδιώματος μεταγράφονται σε πρωτεΐνες
- Ποια είναι η θέση κάθε γονιδίου (π.χ. 21563..25384 για Spike)
- Ποιο είναι το σχετικό protein_id για κάθε γονίδιο

Όπου κάνοντας CDS στην βάση μας μπορούμε να δούμε την συγκεκριμένη θέση και λεπτομέρειες:

```
21563..25384
/ gene="S"
/ locus_tag="GU280_gp02"
/ gene_synonym="spike glycoprotein"
/ note="structural protein; spike protein"
/ codon_start=1
/ product="surface glycoprotein"
/ protein_id="YP_009724390.1"
/ db_xref="GeneID: 43740568"
/ translation="MFVFLVLLPLVSSQCVNLTTRTQLPPAYTNSFTRGVVYPDKVFR
SSVLHSTQDLFLPFFSNVTFWFAIHVSGTNGTKRFDNPVLPFNDGVYFASTEKSNIR
GWIFGTTLDSTQSLLIINNATNVVVKVCEQFCNDPFLGVVYHKNNKSHMESEFRVY
SSANNCTFEYVSQPFLLMDLEGKQGNFKNLREFVKINIDGVFKIYSKHTPINLVRDLPO
GSALEPLVDLPIGINITRFQTLALHRSYLTGDSSSGWTAGAAAYVGYLQPRFTL
LKYNENGITDAVDCALDPLSEKTKLSFTVEKGIYQTSNFRVQPTESIVRFPNITN
LCPPGEVFNATRFASVYAWNRKRISNCAVSVLYNSASFSTFKCYGVSPKTLNDLCF
TNVYADSFVIRGDEVQRQIAPGQGTGKIADYNYKLDDFTGCVIAHNSNLDKVGNNYN
YLYRLFRKSNLKPFRDITETIYQAGSTPCNGVEGFNCYFPLQSYGFQPTNGVGQPY
RVVLSFELLHAPATVCGPKKSTNLVKNKCNVFNFGTLGTGVLTESNKKFLPFQFG
RDIADTTDAVRDPQTLLEILDITPCSGFGVSVITPGTNTSNQVAVLYQDVNCTEVPVAI
HADQLPTWRVYSTGSNVFQTRAGCLIGAETHVNSYECDIPIGAGICASYQTQNSPR
RARSVASQSIAYTMSLGAENSVAYSNNISAIPTNFTISVTTEILPVSMKTSVDCIM
YICGDSSTECNLLQYGSFCTQLNRALTGIAVEQDKNTQEVFAQVKQIYKTPPIKDFG
GFNFSQILPDPSKPSKRSFIEDLLFNKVTLADAGFIKQYGDCLGDIARDLCAQKFN
GLTVLPPLLTDemiaQYTSALLAGTITSGMTFGAGAAQITPFAHQMAYRNFNGIVTQN
VLYENQKLIANQFNSAIGKIQDSLSTASALGKLQDVVNQNAQALNTLVKQLSSNFGA
ISSVLNDILSRLDKVEAEVQIDRLITGRLQSLQTYVTQQLIRAAEIRASANLAATKMS
ECVLGQSKRVDFCGKGYHLSFPQSPHGVVFLHVTYVPAQEKNTTAPAICHGKAH
FPREGVFSNGTHMFTQRFYEPQIITDNTFVSGNCDVIGVNNNTVYDPLQPELD
SFKEELDKYFNHTSPDVLGDISGINASVNNIQKEIDRLNEVAKNLNESLIDLQELG
KYEQYIKWPHYIWLGFIAGLIAIVMTIMLCMTSCCSCSLKGCCSCGSCCKFDEDDSE
PVLKGVKLHYT"
```

Εικόνα 20: Στιγμιότυπο πατώντας CDS

Αρχικά από όλες αυτές τις πληροφορίες κατεβάζουμε στο αρχείο **SARS-CoV-2_sequence.fasta** μόνο την ακολουθία όλων των διαφορετικών πρωτεϊνών που περιέχονται στον ιό, όπως οι membrane protein (gene=M), envelope protein (gene=E), nucleocapsid (gene=N) κ. ά. Στη δικιά μας περίπτωση ωστόσο μας ενδιαφέρει μόνο η ακολουθία της spike (ακίδας) πρωτεΐνης και μάλιστα γνωρίζουμε ότι το γονίδιο Spike (gene=S) βρίσκεται στις θέσεις 21563 έως 25384 της γονιδιακής ακολουθίας, το οποίο προκύπτει από το εξής τμήμα: gene 21563..25384 /gene="S"

Για να μπορέσουμε να απομονώσουμε το .fasta αρχείο που κατεβάσαμε με διαφορετικά "gene" θα χρησιμοποιήσουμε ένα script που θα μας δημιουργήσει ένα νέο αρχείο που θα το ονομάσει SARS-CoV-2_spike_sequence.fasta μόνο την ακολουθία της spike πρωτεΐνης.

Το script που χρησιμοποιήσαμε είναι το συγκεκριμένο **ex4.py**:

```
from Bio import SeqIO
import os

# --- CONFIGURATION ---
# Using the paths from your desktop directory
input_fasta = r"C:\Users\User\Desktop\bioinfo\3\SARS-CoV-2_sequence.fasta"
output_fasta = r"C:\Users\User\Desktop\bioinfo\3\SARS-CoV-2_spike_sequence.fasta"

def extract_spike_protein(input_path, output_path):
    print(f"Searching for Spike protein (gene=S) in: {input_path}")
```

```

found = False
try:
    with open(input_path, "r") as infile:
        # Parse the main fasta file
        for record in SeqIO.parse(infile, "fasta"):
            # Identify the spike protein by the "gene=S" tag in
the header
            if "gene=S" in record.description:
                with open(output_path, "w") as outfile:
                    SeqIO.write(record, outfile, "fasta")

                    found = True
                    print("--- Extraction Complete ---")
                    print(f"ID: {record.id}")
                    print(f>Description: {record.description}")
                    print(f>Sequence Length: {len(record.seq)} amino
acids")

                    print(f>Saved to: {output_path}")
                    break

            if not found:
                print("Status: Process finished, but no entry with
'gene=S' was found.")

except FileNotFoundError:
    print(f>Error: The file '{input_path}' was not found. Please
check the path.")
except Exception as e:
    print(f>An unexpected error occurred: {e}")

if __name__ == "__main__":
    extract_spike_protein(input_fasta, output_fasta)

```

Ο κώδικας χρησιμοποιεί τη βιβλιοθήκη **Biopython** για να απομονώσει την αλληλουχία της **πρωτεΐνης-ακίδας (Spike protein)** από ένα αρχείο μορφής FASTA που περιέχει δεδομένα του ιού SARS-CoV-2. Συγκεκριμένα, διαβάζει το αρχείο εισόδου αναζητώντας στις κεφαλίδες των εγγραφών την ένδειξη `gene=S`, και μόλις την εντοπίσει, εξάγει τη συγκεκριμένη αλληλουχία και την αποθηκεύει σε ένα νέο αρχείο, εμφανίζοντας παράλληλα πληροφορίες για το αναγνωριστικό και το μήκος της αλληλουχίας.

Το αρχείο **SARS-CoV-2_spike_sequence.fasta** που δημιούργησε ο κώδικας:

```

>1c1|NC_045512.2_prot_YP_009724390.1_3 [gene=S]
[locus_tag=GU280_gp02] [db_xref=GeneID:43740568] [protein=surface
glycoprotein] [protein_id=YP_009724390.1] [location=21563..25384]
[gbkey=CDS]
MFVFLVLLPLVSSQCVNLTTTRTQLPPAYTNSFTRGVYYPDKVFRSSVLHSTQDLFLPFFS
NVTWFHAIHVSGTNGTKRFDNPVLPFNDGVYFASTSEKSNIIRGWIFGTTLDSTQSLIIV
NNATNVVIKVCSEFQFCNDPFLGVYHKNKSWMESEFRVYSSANNCTFEYVSQPFLMDLE
GKQGNFKNLREFVFKNIDGYFKIYSKHTPINLVRDLPGQFSALEPLVDLPIGINITRFQT
LLALHRSYLTTPGDSSSGWTAGAAAYVGYLQPRTFLLKYNENGTITDAVDCALDPLSETK
CTLKSFTVEKGIYQTSNFRVQPTESIVRFPNITNLCPFGEVFNATRFASVYAWNRRKRISN
CVADYSVLYNSASFSTFKCYGVSPSTKLNDLCFTNVYADSFVIRGDEVQRQIAPGQTGKIAD
YNYKLPPDDFTGCVIAWNSNNLDSKVGNGYNYLYRLFRKSNLKPFERDISTEYQAGSTPC
NGVEGFNCYFPLQSYGFQPTNGVGYQPYRVVLSFELLHAPATVCGPKKSTNLVKNKCVN
FNFNGLTGTGVLTESNKKFLPFQQFGRDIADTTDAVRDPQTLEILDITPCSFGGVSVITP
GTNTSNQVAVLYQDVNCTEVPVAIHADQLTPTWRVYSTGSNVFQTRAGCLIGAETHVNNYSY
ECDIPIGAGICASYQTQTNPPRRARSVASQSIIAYTMSLGAENSVAYSNNNSIAIPTNFTI
SVTTEILPVSMTKTSVDCTMYICGDSTECNLLQYGSFCTQLNRALTGIAVEQDKNTQE

```


VFAQVKQIYKTPPIKDFGGFNFSQILPDPSKPSKRSFIEDLLFNKVTLADAGFIKQYGDC
 LGDIAARDLICAQKFNGLTVLPPLLTDEMIAQYTSALLAGTITSGWTFGAGAALQIPFAM
 QMAYRFNGIGVTONVLYENQKLIANQFNQSAIGKIQDSLSTASALGKLQDVVNQNAQALN
 TLVKQLSSNFGAISSVLNDILSRLDKVEAEVQIDRLITGRLQSLQTYVTQQLIRAAEIRA
 SANLAATKMSECVLGQSKRVDFCGKGYHLMSFPQSAPHGVVFLHVTVYVPAQEKNFTTAPA
 ICHDGKAHFPPREGVVFVSNNGTHWFVTQRNFYEPQIITTDNTFVSGNCDVVIGIVNNTVYDP
 LQPELDSFKEELDKEYFKNHTSPDVLGDISGINASVVNIQKEIDRLNEVAKNLNESLIDL
 QELGKYEQYIKWPWYIWLGFIAGLIAIVMVTIMLCMTSCCSCCLKGCCSCGSCCKFDEDD
 SEPVLLKGVKLHYT

Για το δεύτερο κομμάτι της ερώτησης που μας ζητιέται να βρούμε και να κατεβάσουμε την ακίδα (spike) πρωτεΐνης για τον κορονοϊό *Severe acute respiratory syndrome coronavirus (SARS-CoV)-1* το οποίο είναι και το αποθηκεύουμε ως **SARS-CoV-1_spike_sequence.fasta** :

```
>sp|P59594|SPIKE_SARS Spike glycoprotein OS=Severe acute respiratory
syndrome coronavirus OX=694009 GN=S PE=1 SV=1
MFIFLLFLTTLTSGSDLDRCTTFDDVQAPNYTQHTSSMRGVYYPDEIFRSDTLYLTQDLFL
PFYSNVTGFHTINHTFGNPVPIPKDGIYFAATEKSNVVRGWVFGSTMNKSQSIIINNS
TNVVIRACNFELCDNPFFAVSKPMGTQTHTMIFDNAFNCTFEYISDAFSLDVSEKSGNFK
HLREFVFKNKDGLYVYKGYQPIDVVRDLPSGFNTLKPFIKPLPLGINITNFRAILTAFSP
AQDIWGTSAAYFVGYLKPTTFMLKYDENGITITDAVDCSQNPLAELKCSVKSFEIDKGIY
QTSNFRVVPVSGDVVRFPNITNLCPFGEVFNATKFPVYAWERKKISNCVADYSVLNSTF
FSTFKCYGVSATKLNLDLCFSNVYADSFVVKGDDVRQIAPGQTGVIADYNKLPDDFMGCV
LAWNTRNIDATSTGNYNKYRYLRHGKLRPFERDISNVPFSPDGKPCPTPPALNCYWPLND
YGFYTTTGIGYQPYRVVLSFELLNAPATVCGPKLSTDLIKNQCVNFNFNGLTGTGVLTTP
SSKRFPQPFQFGRDVSDFTDSVRDPKTSEILDISPSCSFGGVSVITPGTNASSEVAVLYQD
VNCTDVSTAIHADQLTPAWRIYSTGNNVFQTAGCLIGAHEVDTSYECDIPIGAGICASY
HTVSLRSTSQKSIVAYTMSLGADSSIAYSNNTIAIPTNFSISITTEVMPVSMAKTSVDC
NMYICGDSTECANLLQYGSFCTQLNRALSGIAAEQDRNTREVFAQVKQMYKTPTLKYFG
GFNFSQILPDPLKPTKRSFIEDLLFNKVTLADAGFMKQYGECLGDINARDLICAQKFNGL
TVLPPLLTDDMIAAYTAALVSGTATAGWTFGAGAALQIPFAMQMAYRFNGIGVTONVLYE
NQKQIANQFNKAISQIQESLTTTSTALGKLQDVVNQNAQALNTLVKQLSSNFGAISSVLN
DILSRLDKVEAEVQIDRLITGRLQSLQTYVTQQLIRAAEIRASANLAATKMSECVLGQSK
RVDFCGKGYHLMSFPQAAPHGVVFLHVTVYVPSQERNFTTAPAICHEGKAYFPREGVVFVN
GTSWFITQRNFFSPQIITTDNTFVSGNCDVVIGIINNTVYDPLQPELDSFKEELDKEYFKN
HTSPDVLGDISGINASVVNIQKEIDRLNEVAKNLNESLIDLQELGKYEQYIKWPWYVWL
GFIAGLIAIVMVTILLCCMTSCCSCCLKGACSCGSCCKFDEDDSEPVLLKGVKLHYT
```

Έπειτα συγκρίνουμε τις 2 ακίδες των πρωτεϊνών με το εργαλείο EMBOS NEEDLE βάζοντας τα 2 sequences που έχουμε ανακτήσει στα προηγούμενα βήματα.

Το **EMBOSS Needle** είναι ένα εξειδικευμένο εργαλείο ανάλυσης βιολογικών αλληλουχιών που χρησιμοποιείται για την ολική ευθυγράμμιση δύο αλληλουχιών (Global Pairwise Sequence Alignment), είτε πρόκειται για πρωτεΐνες είτε για DNA/RNA.

Το εργαλείο χρησιμοποιεί τον αλγόριθμο Needleman-Wunsch για να συγκρίνει δύο αλληλουχίες σε όλο τους το μήκος, από την αρχή μέχρι το τέλος. Λειτουργεί προσπαθώντας να βρει τη βέλτιστη αντιστοίχιση μεταξύ των χαρακτήρων (αμινοξέων ή νουκλεοτιδίων), εισάγοντας κενά (gaps) όπου είναι απαραίτητο, ώστε να μεγιστοποιηθεί το σκορ ομοιότητας. Με αυτόν τον τρόπο, επιτρέπει στους επιστήμονες να εντοπίσουν πόσο στενά συνδέονται εξελικτικά ή λειτουργικά δύο βιομόρια, αναδεικνύοντας περιοχές που έχουν παραμείνει ίδιες ή έχουν υποστεί μεταλλάξεις κατά τη διάρκεια του χρόνου.

Είναι ιδανικό όταν οι δύο αλληλουχίες που συγκρίνουμε έχουν παρόμοιο μήκος και θέλεις μια συνολική εικόνα της ομοιότητάς τους όπως στην δική μας περίπτωση που έχουμε δύο sequences που είναι πάρα πολύ παρόμοια.

Αποτελέσματα Ανάλυσης SARS-CoV

Το αποτέλεσμα μπορείτε να το αναλύσετε από το αρχείο **emboss_needle-I20260309-153544-0329-23608003-p1m.out** που το έχουμε προσθέσει στο φάκελο 4.1 και τα άλλα αποτελέσματα μαζί με τα sequences στο φάκελο **emboss_needle_files** που και αυτό βρίσκεται στο 4.1.

Η ανάλυση πραγματοποιήθηκε με το εργαλείο EMBOSS Needle, το οποίο εκτέλεσε καθολική ευθυγράμμιση (global alignment) μεταξύ των πρωτεϊνών Spike (ακίδα) των δύο ιών. Το ποσοστό Ταυτότητας (Identity) ανέρχεται στο 76.4%, γεγονός που σημαίνει ότι 975 από τα 1.277 αμινοξέα είναι ακριβώς τα ίδια και στις δύο πρωτεΐνες. Το ποσοστό Ομοιότητας (Similarity) είναι ακόμη υψηλότερο, στο 87.0%, υποδεικνύοντας ότι πολλά από τα αμινοξέα που διαφέρουν έχουν παρόμοιες χημικές ιδιότητες, διατηρώντας έτσι τη δομή της πρωτεΐνης σε μεγάλο βαθμό.

Στην αλληλούχιση παρατηρήθηκαν ελάχιστα Κενά (Gaps), μόλις 2.0%. Αυτά τα κενά αντιπροσωπεύουν μικρές προσθήκες ή διαγραφές αμινοξέων που συνέβησαν κατά την εξέλιξη των δύο ιών. Οι περισσότερες διαφορές εντοπίζονται στο αμινοτελικό άκρο (N-terminal domain) της πρωτεΐνης, ενώ το καρβοξυτελικό άκρο (C-terminal), το οποίο είναι υπεύθυνο για τη σύντηξη του ιού με το κύτταρο, παραμένει εξαιρετικά συντηρημένο και σχεδόν πανομοιότυπο.

Το υψηλό σκορ ευθυγράμμισης (5230.0) επιβεβαιώνει τη στενή φυλογενετική συγγένεια μεταξύ του SARS-CoV-2 και του SARS-CoV. Η μεγάλη ομοιότητα εξηγεί γιατί και οι δύο ιοί χρησιμοποιούν τον ίδιο ανθρώπινο υποδοχέα (ACE2) για να εισβάλουν στα κύτταρα. Ωστόσο, το 23.6% των διαφορών στην ταυτότητα είναι αυτό που καθορίζει τις διαφορές στη μεταδοτικότητα και την αποτελεσματικότητα της πρόσδεσης του κάθε ιού στον ξενιστή.


4.2 Σύγκριση Δομής των SARS-CoV-1 και SARS-CoV-2

Αρχικά, εισάγουμε τις ακολουθίες στο εργαλείο SWISS-MODEL, το οποίο χρησιμοποιείται για τη πρόβλεψη της τρισδιάστατης δομής πρωτεϊνών από την αλληλουχία τους. Δουλεύει με βάση την αρχή της ομολογικής μοντελοποίησης (homology modeling), δηλαδή βασίζεται στην υπόθεση ότι πρωτεΐνες με παρόμοια αλληλουχία έχουν και παρόμοια δομή. Πιο συγκεκριμένα, για κάθε ακολουθία το εργαλείο ψάχνει σε βάσεις δεδομένων (όπως PDB) για γνωστές δομές πρωτεϊνών που μοιάζουν με την αλληλουχία που εισαγάγαμε (templates). Στη συνέχεια, χρησιμοποιεί ευθυγράμμιση για να προβλέψει πού θα τοποθετηθούν τα residues στη τρισδιάστατη δομή και με βάση την ευθυγράμμιση και το template δημιουργεί ένα τρισδιάστατο μοντέλο. By default κατατάσσει τα διάφορα μοντέλα με βάση το GMQE (Global Model Quality Estimate), το οποίο μας δείχνει πόσο καλό ποιοτικά είναι το αποτέλεσμα που παρήγαγε το μοντέλο συνολικά. Οι τιμές του κυμαίνονται από 0 έως 1 και όσο πιο κοντά στο 1 τείνουν, τόσο πιο αξιόπιστο θεωρείται το μοντέλο. Επομένως, προσπαθούμε να εντοπίσουμε το μοντέλο με το κατάλληλο συνδυασμό μετρικών GMQE και QMEANDisCo.

Για τον SARS-CoV-1 λαμβάνουμε την υπέρθεση των παρακάτω τρισδιάστατων μοντέλων:


Παρατηρούμε ότι το πιο αξιόπιστο μοντέλο είναι το Model 01 με GMQE=0.68 και QMEANDisCo = 0.70, δείχνοντας υψηλή ποιότητα πρόβλεψης. Και οι δύο δομές (SWISS-MODEL και PDB) ευθυγραμμίζονται πολύ καλά στο μεγαλύτερο μέρος τους (ειδικά στο εσωτερικό). Η αντιστοίχιση των δευτεροταγών δομών, όπως οι α-έλικες και οι β-πτυχωτές επιφάνειες, είναι εξαιρετικά ακριβής, γεγονός που επιβεβαιώνεται από το υψηλό ποσοστό κάλυψης της αλληλουχίας. Το μοντέλο βασίστηκε στο template 6zgf.1.A, το οποίο αφορά την πρωτεΐνη ακίδα του Bat Coronavirus RaTG13, και η ομολογία αυτή είναι επαρκής για να δώσει μια αξιόπιστη τρισδιάστατη αναπαράσταση, καθώς η δομή του SARS-CoV-1 παραμένει συντηρημένη σε μεγάλο βαθμό.

Όπως φαίνεται και στην οπτικοποίηση των δομών, οι μεγαλύτερες αποκλίσεις εντοπίζονται στις εξωτερικές περιοχές και στα loops, κάτι που δικαιολογείται από τη φύση αυτών των τμημάτων να είναι πιο εύκαμπτα και επιρρεπή σε αλλαγές κατά την πειραματική παρατήρηση. Συνολικά, με την τιμή GMQE να προσεγγίζει το 0.7, το μοντέλο κρίνεται πολύ ικανοποιητικό για περαιτέρω μελέτη, όπως την ανάλυση θέσεων πρόσδεσης ή τη μελέτη αντιγονικών καθοριστών. Η επιτυχία αυτή επιβεβαιώνει ότι η ομολογική μοντελοποίηση απέδωσε μια δομή που αντικατοπτρίζει πιστά τη βιολογική πραγματικότητα του ιού, παρά τη μικρή διαφορά στο μήκος της αλληλουχίας (1255 αμινοξέα) σε σύγκριση με το SARS-CoV-2.



Εικόνα 21: Spike glycoprotein SARS-CoV-1 Models


Προσθέτουμε και την πρωτεΐνη του model 1 που είναι το πιο αξιόπιστο από όλα τα δείγματα που έχουμε παράγει με το εργαλείο:




Εικόνα 22: Spike glycoprotein SARS CoV-2 Model 01

Για τον SARS-CoV-2 λαμβάνουμε την υπέρθεση των παρακάτω τρισδιάστατων μοντέλων:

Παρατηρούμε ότι το πιο αξιόπιστο μοντέλο είναι το Model 04 με GMQE=0.70 και QMEANDisCo = 0.72, δείχνοντας υψηλή ποιότητα πρόβλεψης. Και οι δύο δομές (SWISS-MODEL και PDB) ευθυγραμμίζονται πολύ καλά στο μεγαλύτερο μέρος τους (ειδικά στο εσωτερικό). Η σπειροειδής και φύλλο-β-δομή (β sheet) ευθυγραμμίζονται σχεδόν πλήρως, γεγονός που δείχνει υψηλή δομική ομοιότητα. Επίσης, υπάρχουν ελαφρές αποκλίσεις στα loops ή σε πιο ευέλικτες περιοχές (κυρίως στα άκρα), αλλά αυτό είναι αναμενόμενο λόγω μεταλλάξεων ή φυσικής ευκαμψίας. Συνολικά, υπάρχει σημαντική ομοιότητα μεταξύ της προβλεπόμενης και της πειραματικής δομής, γεγονός που δείχνει ότι η ομολογική μοντελοποίηση ήταν επιτυχής.



Εικόνα 23: Spike glycoprotein SARS-CoV-2 Models



Εικόνα 24: Spike glycoprotein SARS CoV-2 Model 04

Σύγκριση των Δομών των Δύο Πρωτεϊνών με Χρήση του εργαλείου RCSB

Το εργαλείο Alignment του RCSB Protein Data Bank αποτελεί μια εξειδικευμένη υπολογιστική πλατφόρμα για τη σύγκριση βιολογικών μακρομορίων, προσφέροντας δυνατότητες ευθυγράμμισης τόσο σε επίπεδο πρωτοταγούς αλληλουχίας (sequence alignment) όσο και σε επίπεδο τρισδιάστατης δομής (structural alignment). Μέσω προηγμένων αλγορίθμων, όπως ο FATCAT ή ο Smith-Waterman, το εργαλείο επιτρέπει την υπερθέση (superposition) πολλαπλών πρωτεϊνικών δομών στον χώρο, διευκολύνοντας τον εντοπισμό δομικών ομοιοτήτων που συχνά δεν είναι εμφανείς μόνο από την αλληλουχία των αμινοξέων. Η εξαγωγή ποσοτικών δεδομένων, όπως η τιμή RMSD (Root Mean Square Deviation), επιτρέπει την ακριβή αξιολόγηση της γεωμετρικής απόκλισης μεταξύ των δομών, καθιστώντας το εργαλείο απαραίτητο για τη μελέτη της εξελικτικής συντήρησης, την ανάλυση μεταλλάξεων και τον ορθολογικό σχεδιασμό φαρμάκων.

▼ Compare Protein Structures

File	Chain ID	Begin	End
🗑️ ▼ SARS_CoV_1_model1.pdb 🔗	A		
File	Chain ID	Begin	End
🗑️ ▼ SARS_CoV_2_model4.pdb 🔗	A		
⊕ ▼			
Alignment Method			
TM-align ▼			
		Compare	Clear


Εικόνα 25: Ανεβάζουμε τα 2 αρχεία για σύγκριση

Ανεβάζουμε τα 2 .pdb αρχεία έτσι ώστε να κάνουμε την σύγκριση και κατά τη διαδικασία της δομικής ευθυγράμμισης (structural alignment), ορίστηκε ως αναγνωριστικό αλυσίδας το "A" και για τις δύο πρωτεΐνες.

Αυτό έγινε διότι τα μοντέλα που παράγονται από το λογισμικό **SWISS-MODEL** ονομάζουν αυτόματα την κύρια πρωτεϊνική αλυσίδα ως "**Chain A**". Δηλώνοντας την αλυσίδα A στο εργαλείο του RCSB, δίνουμε την εντολή στον αλγόριθμο να συγκρίνει την κύρια δομή της πρώτης πρωτεΐνης με την αντίστοιχη κύρια δομή της δεύτερης, εξασφαλίζοντας έτσι τη σωστή γεωμετρική ταύτιση των δύο μοντέλων.

Παρατηρείται ότι το μοντέλο του SARS-CoV-2 παρουσιάζει την τεταρτοταγή δομή της πρωτεΐνης (τριμερές με αλυσίδες A, B, C), σε αντίθεση με το μοντέλο του SARS-CoV-1 που περιλαμβάνει μόνο τη μία αλυσίδα (A). Για την ορθή δομική ευθυγράμμιση, επιλέχθηκε η σύγκριση των **αλυσίδων A** και από τα δύο αρχεία, ώστε να συγκριθούν άμεσα οι αντίστοιχες πρωτοταγείς δομικές μονάδες των δύο ιών.

Η παρουσία της αλυσίδας C επιβεβαιώνει ότι το μοντέλο σου για τον SARS-CoV-2 είναι πιο πλήρες (δείχνει πώς ενώνονται πολλές αλυσίδες μαζί), αλλά για τη σύγκριση που σου ζητάει η άσκηση, η επιλογή **A με A** που έκανες είναι η πιο σωστή.



Εικόνα 26: Αποτελέσματα Σύγκρισης στο εργαλείο RCSB

Με βάση τη δομική ευθυγράμμιση των πρωτεϊνών ακίδων (Spike proteins) των ιών SARS-CoV-1 και SARS-CoV-2, προκύπτουν τα ακόλουθα συμπεράσματα:

- **Υψηλή Δομική Ομοιότητα (TM-score):** Το **TM-score 0.79** είναι ο πιο κρίσιμος δείκτης, καθώς τιμές πάνω από 0.5 υποδηλώνουν ότι οι δύο πρωτεΐνες υιοθετούν την ίδια ακριβώς αναδίπλωση (fold) στο χώρο. Παρά το γεγονός ότι πρόκειται για διαφορετικούς ιούς, η 3D αρχιτεκτονική τους παραμένει εξαιρετικά σταθερή.
- **Απόκλιση Ακολουθίας (Sequence Identity):** Η ταυτότητα αλληλουχίας ανέρχεται στο **67%**. Αυτό σημαίνει ότι το 33% των αμινοξέων έχει αλλάξει λόγω μεταλλάξεων κατά την εξέλιξη του ιού. Ωστόσο, αυτές οι αλλαγές στην πρώτη ύλη (αλληλουχία) δεν στάθηκαν ικανές να ανατρέψουν τη συνολική μορφολογία της πρωτεΐνης.
- **Συσχέτιση Ακολουθίας-Δομής:** Τα αποτελέσματα επιβεβαιώνουν μια βασική αρχή της βιοπληροφορικής. Η τρισδιάστατη δομή μιας πρωτεΐνης είναι πολύ πιο συντηρημένη από την πρωτοταγή αλληλουχία της. Οι μεταλλάξεις τείνουν να συσσωρεύονται σε περιοχές που δεν επηρεάζουν τον βασικό σκελετό της πρωτεΐνης, αλλά ίσως αλλάζουν την ικανότητα σύνδεσης με τον υποδοχέα (π.χ.

ACE2), επιτρέποντας στον ιό να προσαρμόζεται χωρίς να χάνει τη λειτουργικότητά του.

- **Ερμηνεία του RMSD:** Η τιμή **RMSD (4.82 Å)** για πρωτεΐνες τόσο μεγάλου μεγέθους (>1100 κατάλοιπα) θεωρείται αναμενόμενη. Δείχνει ότι ενώ ο κεντρικός πυρήνας της πρωτεΐνης ταυτίζεται, υπάρχουν τοπικές διαφοροποιήσεις (πιθανώς σε εξωτερικούς βρόχους/loops), οι οποίες ευθύνονται για τις διαφορετικές βιολογικές ιδιότητες των δύο ιών.

Η ανάλυση δείχνει ότι οι SARS-CoV-1 και SARS-CoV-2 είναι δομικά ομόλογες πρωτεΐνες. Η διατήρηση της δομής τους παρά τις σημαντικές αλλαγές στην αλληλουχία υπογραμμίζει τη λειτουργική πίεση που δέχεται ο ιός να διατηρήσει το σχήμα της ακίδας του προκειμένου να εισέρχεται στα κύτταρα ξενιστές.

Ερώτημα 5

Αποκλειστικά για λόγους καλύτερης παρουσίασης αξιοποιήθηκαν online εργαλεία για την οπτικοποίηση των δύο πινάκων που ζητούνται. Για την ολική στοίχιση χρησιμοποιήθηκε το [Global Alignment App](#) και για την τοπική στοίχιση ένα [εργαλείο εκπαίδευσης του αλγορίθμου Smith-Waterman](#).

5.1 Ολική Στοίχιση

Σε αυτή τη περίπτωση εφαρμόζουμε τον αλγόριθμο Needleman-Wunsch, ο οποίος χρησιμοποιεί δυναμικό προγραμματισμό. Πιο συγκεκριμένα, διατρέχουμε τον πίνακα F και τον συμπληρώνουμε καλώντας επαναληπτικά την παρακάτω σχέση:

$$F_{ij} = \max \begin{cases} F_{i-1,j-1} + s(a_i, b_j) \\ F_{i-1,j} + s(a_i, -) \\ F_{i,j-1} + s(-, b_j) \end{cases} = \max \begin{cases} F_{i-1,j-1} + 1, & a_i = b_j \leftarrow \text{match} \\ F_{i-1,j-1} - 1, & a_i \neq b_j \leftarrow \text{mismatch} \\ F_{i-1,j} - 1, & b_j = - \leftarrow \text{gap} \\ F_{i,j-1} - 1, & a_i = - \leftarrow \text{gap} \end{cases}$$

Ο αλγόριθμος αρχικοποιεί την πρώτη γραμμή και στήλη με τιμές που αντιστοιχούν σε συνεχόμενα gaps, και συνεχίζει γεμίζοντας τον πίνακα από πάνω αριστερά προς κάτω δεξιά. Η βέλτιστη στοίχιση εντοπίζεται μέσω **backtracking** ξεκινώντας από το τελευταίο κάτω δεξιά κελί και ακολουθώντας τη διαδρομή που έδωσε τη μέγιστη τιμή σε κάθε βήμα. Πιο συγκεκριμένα, σε κάθε βήμα:


- Αν ήρθαμε από διαγώνιο κελί δεν μπαίνει κενό, οπότε πραγματοποιείται στοίχιση χαρακτήρα με χαρακτήρα (match ή mismatch).
- Αν ήρθαμε από το πάνω κελί σημαίνει ότι έχει εισαχθεί gap στην ακολουθία B, οπότε προσθέτουμε τον χαρακτήρα της A κανονικά και για την B προσθέτουμε _.
- Αν ήρθαμε από το αριστερό κελί σημαίνει ότι έχει εισαχθεί gap στην ακολουθία A, οπότε προσθέτουμε _ για την A και τον χαρακτήρα της B κανονικά για την B.
- Αν φτάσουμε σε κελί με τιμή 0, η στοίχιση ολοκληρώνεται. Το αποτέλεσμα είναι η στοίχιση δύο ακολουθιών με μέγιστο συνολικό σκορ, λαμβάνοντας υπόψη την επιβράβευση για τα ταιριάσματα και τις ποινές για τα κενά ή τις ασυμφωνίες.

Το αποτέλεσμα είναι η στοίχιση δύο ακολουθιών με μέγιστο συνολικό σκορ, λαμβάνοντας υπόψη **την επιβράβευση για τα ταιριάσματα και τις ποινές για τα κενά ή τις ασυμφωνίες.**

Στον παρακάτω πίνακα φαίνεται το αποτέλεσμα της ολικής στοίχισης. Η πρώτη γραμμή και στήλη του πίνακα αρχικοποιούνται με τιμές κόστους στοίχισης με κενό, υποθέτοντας ότι μέχρι εκείνο το σημείο προσθέτουμε διαρκώς κενά. Για κάθε επόμενο κελί υπολογίζονται οι τιμές για στοίχιση, για ασυμφωνία και για στοίχιση με κενό, και αποθηκεύεται η μέγιστη από αυτές. Κάθε φορά που συμπληρώνεται μια τιμή, σημειώνεται και το κελί προέλευσης, ώστε αργότερα να εκτελεστεί το **traceback (κόκκινο μονοπάτι)**, το οποίο ξεκινάει από το τελευταίο κελί του πίνακα (κάτω δεξιά) μέχρι να φτάσει στην αρχή του πίνακα (πάνω αριστερά). Το μονοπάτι που θα δημιουργηθεί είναι η βέλτιστη στοίχιση.

Με τη χρήση του αλγορίθμου Needleman–Wunsch, επιβάλλεται μια πλήρης στοίχιση όλων των στοιχείων των ακολουθιών, ώστε να βρεθεί η καλύτερη δυνατή αντιστοίχιση σε όλο το μήκος της ακολουθίας.

Το αποτέλεσμα είναι η στοίχιση δύο ακολουθιών με μέγιστο συνολικό σκορ, λαμβάνοντας υπόψη την επιβράβευση για τα ταιριάσματα και τις ποινές για τα κενά ή τις ασυμφωνίες.



Εικόνα 27: Πίνακας δυναμικού προγραμματισμού ολικής στοίχισης

5.2 Τοπική Στοίχιση

Σε αυτή τη περίπτωση εφαρμόζουμε τον αλγόριθμο Smith-Waterman, ο οποίος χρησιμοποιεί και αυτός δυναμικό προγραμματισμό. Πιο συγκεκριμένα, διατρέχουμε τον πίνακα F και τον συμπληρώνουμε καλώντας επαναληπτικά την σχέση:


$$F_{i,j} = \max \begin{cases} F_{i-1,j-1} + s(a_i, b_j) \\ F_{i-1,j} + s(a_i, -) \\ F_{i,j-1} + s(-, b_j) \\ 0 \end{cases} = \max \begin{cases} F_{i-1,j-1} + 1, & a_i = b_j \leftarrow \text{match} \\ F_{i-1,j-1} - 1, & a_i \neq b_j \leftarrow \text{mismatch} \\ F_{i-1,j} - 1, & b_j = - \leftarrow \text{gap} \\ F_{i,j-1} - 1, & a_i = - \leftarrow \text{gap} \\ 0 \end{cases}$$

Σημειώνεται ότι το **F(i,j)** μπορεί να πάρει την τιμή 0 αν οι υπόλοιπες επιλογές δίνουν αρνητική βαθμολογία.

Ο αλγόριθμος υλοποιεί τοπική στοίχιση των δύο ακολουθιών εντοπίζοντας την περιοχή με τη μέγιστη ομοιότητα μεταξύ τους. Η διαδικασία ξεκινά με την αρχικοποίηση του πίνακα δυναμικού προγραμματισμού, όπου η πρώτη γραμμή και στήλη γεμίζονται με μηδενικά, επειδή επιτρέπεται η στοίχιση να ξεκινήσει από οποιοδήποτε σημείο. Στη συνέχεια, ο πίνακας συμπληρώνεται από πάνω αριστερά προς κάτω δεξιά. Η βέλτιστη τοπική στοίχιση ξεκινά από το κελί με τη μεγαλύτερη τιμή στον πίνακα και συνεχίζει προς τα πίσω με backtracking μέχρι να φτάσουμε σε κελί με τιμή 0, όπου σταματά η στοίχιση. Πιο συγκεκριμένα, σε κάθε βήμα:

- Αν ήρθαμε από διαγώνιο κελί δεν μπαίνει κενό, οπότε πραγματοποιείται στοίχιση χαρακτήρα με χαρακτήρα (match ή mismatch).
- Αν ήρθαμε από το πάνω κελί, εισάγεται κενό στην ακολουθία B (προστίθεται ο χαρακτήρας της A και _ στην B).
- Αν ήρθαμε από το αριστερό κελί, εισάγεται κενό στην A (προστίθεται _ στην A και ο χαρακτήρας της B).
- Αν φτάσουμε σε κελί με τιμή 0, η στοίχιση ολοκληρώνεται. Το αποτέλεσμα είναι το υποσύνολο των δύο ακολουθιών που εμφανίζουν τη μεγαλύτερη ομοιότητα, και η στοίχιση τους με μέγιστο σκορ, λαμβάνοντας υπόψη ταίριασμα, ασυμφωνίες και κενά.

Στον παρακάτω πίνακα φαίνεται το αποτέλεσμα της τοπικής στοίχισης. Η βασική διαφορά της τοπικής στοίχισης από την ολική είναι ότι δεν προσπαθεί να ταιριάξει ολόκληρες τις ακολουθίες αλλά μόνο το ή τα κομμάτια που ταιριάζουν καλύτερα. Πρακτικά αυτό σημαίνει ότι μας ενδιαφέρουν κομμάτια της ακολουθίας, όχι ολόκληρη η ακολουθία. Για αυτόν τον λόγο η πρώτη γραμμή και η πρώτη στήλη του πίνακα αρχικοποιούνται με 0, και επιτρέπεται να εισαχθεί μηδενική τιμή στα ενδιάμεσα κελιά. Όπως και στην ολική στοίχιση, κάθε κελί υπολογίζεται με βάση τις πιθανές κινήσεις, όμως το Traceback ξεκινά από τη μεγαλύτερη τιμή του πίνακα και τελειώνει μόλις συναντήσει μηδενική τιμή. Ακριβώς για αυτόν τον λόγο μπορεί **να υπάρχουν πολλές βέλτιστες εναλλακτικές στοίχισεις, όπως φαίνεται δεξιά του πίνακα.**



Εικόνα 28: Πίνακας δυναμικού προγραμματισμού τοπικής στοίχισης

Ερώτηση 6

6.1. Βελτιστοποιημένη Αναζήτηση σε Suffix Tree με Χρονικό Περιορισμό k

Περιγραφή του Αλγορίθμου

Για την επίλυση του προβλήματος, χρησιμοποιούμε τη δομή δεδομένων **Suffix Tree** επί της συμβολοσειράς T, ενισχυμένη με πρόσθετη πληροφορία σε κάθε κόμβο. Η διαδικασία χωρίζεται σε δύο φάσεις:

A. Φάση Προεπεξεργασίας (Preprocessing)

- **Κατασκευή Suffix Tree:** Κατασκευάζουμε το Suffix Tree για τη συμβολοσειρά T μήκους n.
- **Υπολογισμός Ελάχιστου Δείκτη (Min-Index):** Κάθε φύλλο του δέντρου αντιστοιχεί σε ένα επίθημα που ξεκινά στη θέση i. Για κάθε εσωτερικό κόμβο u, ορίζουμε μια τιμή C(u), η οποία αντιπροσωπεύει τη μικρότερη θέση έναρξης (min_index) όλων των επιθημάτων που περιλαμβάνονται στο υποδέντρο του u.
 - Η τιμή C(u) υπολογίζεται αναδρομικά (bottom-up) με μια διάσχιση κατά βάθος (DFS): $C(u) = \min\{C(v)\}$ για όλους τους απογόνους v του κόμβου u.

B. Φάση Ερωτήματος (Query)

Δεδομένης μιας συμβολοσειράς P μήκους m και ενός ακέραιου k:


1. **Αναζήτηση του P:** Διασχίζουμε το δέντρο ξεκινώντας από τη ρίζα, ακολουθώντας τους χαρακτήρες της P.
2. **Έλεγχος Ύπαρξης:** Αν η αναζήτηση αποτύχει (δεν υπάρχει μονοπάτι που να σχηματίζει την P), τότε η P δεν περιέχεται στο T και επιστρέφουμε **False**.
3. **Έλεγχος Θέσης k:** Αν η αναζήτηση ολοκληρωθεί επιτυχώς σε έναν κόμβο u (ή σε μια ακμή που οδηγεί στον u), εξετάζουμε την αποθηκευμένη τιμή C(u).
 - Αν $C(u) < k$, επιστρέφουμε True (υπάρχει εμφάνιση πριν τη θέση k).
 - Αλλιώς, επιστρέφουμε False.

Ανάλυση Πολυπλοκότητας:

- **Προεπεξεργασία - $O(n)$:**
 - Η κατασκευή του Suffix Tree μπορεί να γίνει σε $O(n)$ χρόνο
 - Ο υπολογισμός των τιμών $C(u)$ μέσω DFS απαιτεί χρόνο ανάλογο του αριθμού των κόμβων του δέντρου. Καθώς ένας Suffix Tree έχει το πολύ $2n-1$ κόμβους, η διάσχιση ολοκληρώνεται σε $O(n)$.
 - Συνολικός χρόνος: **$O(n)$** .
- **Ερώτημα (Query) - $O(m)$:**
 - Η αναζήτηση της συμβολοσειράς P στο δέντρο απαιτεί χρόνο ανάλογο του μήκους της, δηλαδή $O(m)$.
 - Η πρόσβαση στην τιμή $C(u)$ και η σύγκριση $C(u) < k$ είναι λειτουργίες σταθερού χρόνου, $O(1)$.
 - Συνολικός χρόνος: **$O(m)$** .


Παράδειγμα Εφαρμογής

Ας θεωρήσουμε ως παράδειγμα ένα μικρό τμήμα της αλληλουχίας της πρωτεΐνης-ακίδας: VGGVY, το οποίο αντιστοιχεί στα αμινοξέα Valine–Glycine–Glycine–Valine–Tyrosine. Η συγκεκριμένη ακολουθία, αν και σύντομη, είναι αρκετή για να αναδείξει βασικές έννοιες που σχετίζονται με την επεξεργασία και ανάλυση συμβολοσειρών.



Εικόνα 29: Οπτικοποίηση Παραδείγματος VGGVY


Για την καλύτερη κατανόηση της δομής και των υποακολουθιών της, μπορούμε να χρησιμοποιήσουμε ένα εργαλείο οπτικοποίησης, όπως το online περιβάλλον του Visualgo για suffix trees (<https://visualgo.net/en/suffixtree>). Μέσω αυτού, είναι δυνατό να παρατηρήσουμε πώς κατασκευάζεται το suffix tree της ακολουθίας βήμα προς βήμα, καθώς και πώς οργανώνονται όλα τα επιμέρους suffixes της.



Εικόνα 30: Αρχική εικόνα δένδρου μέσω του εργαλείου *visualgo*

Έστω $T = VGGVY\$$ και αναζητούμε το $P = GV$ για $k = 3$.

1. Στο Suffix Tree, η διαδρομή “GV” καταλήγει σε έναν κόμβο που έχει ως φύλλα τις θέσεις {2}. **Σημείωση: το “GVY\$” ξεκινά στο index 2.**
2. Η τιμή $C(u)$ για αυτόν τον κόμβο είναι 2.
3. Επειδή $2 < 3$, ο αλγόριθμος επιστρέφει **True**.



Εικόνα 31: Αποτέλεσμα αναζήτησης “GV” που καταλήγει στο κόμβο 2

6.2 Τεχνικές Συνδυασμού Bloom Filters, Suffix Arrays και Burrows Wheeler για Δεικτοδότηση Βιολογικών Δεδομένων

Στο συγκεκριμένο άρθρο, η κύρια τεχνική που αναλύεται είναι ο Masked Burrows-Wheeler Transform (MBWT), ο οποίος αποτελεί τη βάση του ευρετηρίου FMSI (From Superstring to Indexing). Παρακάτω αναλύουμε πώς το άρθρο προσεγγίζει τις έννοιες που μας ζητάει η εκφώνηση:

Burrows-Wheeler Transform (BWT) και MBWT

Το FMSI χρησιμοποιεί μια επέκταση του κλασικού μετασχηματισμού Burrows-Wheeler, τον MBWT, για την αποδοτική αποθήκευση και αναζήτηση συνόλων k -mer (τα k -mers ουσιαστικά είναι tokens ή αλλιώς χαρακτήρες του νουκλεοτιδικού αλφάβητου). Ενώ ο παραδοσιακός BWT χρησιμοποιείται για την ευρετηρίαση κειμένου, ο MBWT ενσωματώνει μια δυαδική μάσκα που επιτρέπει στην (superstring) να αναπαριστά αυθαίρετα σύνολα k -mer, εξαλείφοντας την ανάγκη για επικαλύψεις μήκους $k-1$. Αυτό καθιστά τη δομή πολύ πιο συμπαγή σε σύγκριση με προηγούμενες μεθόδους.

Suffix Arrays

Οι Suffix Arrays (SA) παίζουν κεντρικό ρόλο στον ορισμό και την κατασκευή του MBWT. Η μάσκα που συνοδεύει την υπερσυμβολοσειρά μετασχηματίζεται (SA-transformed mask) έτσι ώστε η σειρά των bits της να αντιστοιχεί στη λεξικογραφική σειρά των επιθημάτων της συμβολοσειράς. Κατά τη διάρκεια της αναζήτησης, το FMSI εκτελεί την κλασική backward search, παρόμοια με αυτή που χρησιμοποιείται στα FM-indexes, για να εντοπίσει το εύρος στον πίνακα επιθημάτων που αντιστοιχεί στο ερώτημα. Η τελική επικύρωση του k -mer γίνεται μέσω της μετασχηματισμένης μάσκας στο συγκεκριμένο εύρος SA.

Bloom Filters και Διαχείριση Ψευδώς Θετικών

Είναι σημαντικό να σημειωθεί ότι το συγκεκριμένο άρθρο δεν χρησιμοποιεί Bloom Filters ως τεχνική δεικτοδότησης. Τα Bloom Filters είναι πιθανοτικές δομές δεδομένων που

επιτρέπουν ψευδώς θετικά αποτελέσματα (false positives). Αντίθετα, το FMSI είναι μια ακριβής (exact) δομή δεδομένων.

Το άρθρο αναφέρει τα ψευδώς θετικά k-mers στο πλαίσιο της χρήσης υπερσυμβολοσειρών, μια υπερσυμβολοσειρά μπορεί να περιέχει k-mers που δεν υπήρχαν στο αρχικό σύνολο δεδομένων. Αντί για Bloom Filters, το FMSI χρησιμοποιεί τη δυαδική μάσκα (M) για να υποδείξει ακριβώς ποια k-mers της υπερσυμβολοσειράς είναι έγκυρα μέλη του συνόλου, εξασφαλίζοντας έτσι την ορθότητα των ερωτημάτων συμμετοχής (membership queries).

Σύνοψη Τεχνικών

- **Masked Superstrings:** Χρησιμοποιούνται για τη συμπίεση των δεδομένων k-mer.
- **MBWT:** Συνδυάζει τη συμπίεση του BWT με τη μάσκα εγκυρότητας.
- **Rank/Select Δομές:** Χρησιμοποιούνται πάνω στο MBWT και τη μάσκα για την επίτευξη σταθερού χρόνου αναζήτησης.

Το κύριο συμπέρασμα είναι ότι το FMSI αποτελεί μια εξαιρετικά αποδοτική δομή δεδομένων που επιτυγχάνει 2 έως 3 φορές μεγαλύτερη οικονομία χώρου σε σχέση με τις υπάρχουσες μεθόδους, διατηρώντας ταυτόχρονα ανταγωνιστικούς χρόνους αναζήτησης.

Η καινοτομία του βασίζεται στον συνδυασμό superstrings και του Masked Burrows-Wheeler Transform (MBWT), προσφέροντας μια ακριβή λύση χωρίς ψευδώς θετικά αποτελέσματα, η οποία παραμένει ισχυρή και κλιμακούμενη ακόμη και σε πολύπλοκα γονιδιωματικά ή μεταγονιδιωματικά δεδομένα.