



Πολυτεχνική Σχολή
Τμήμα Μηχανικών Η/Υ & Πληροφορικής

Εισαγωγή στη Βιοπληροφορική

**Ολοκληρωμένη Διάγνωση του Καρκίνου με χρήση AI,
Βαθιάς Μάθησης και Επεξηγησιμότητας**

Κιουρτ-Μεχμεταλή Αχμέτ

A.M. 1084672

**Συγκεκριμένα θα ήθελα να εξεταστώ στις 24/06 λόγω
εξετάσεων σε άλλα μαθήματα**

Περιεχόμενα

1 Εισαγωγή	4
1.1 Σκοπός	5
1.2 Στόχος	6
2 Προηγούμενες Σχετικές Μελέτες	7
2.1 Στατιστική Θεμελίωση	8
2.2 Μεθοδολογική Προσέγγιση και Χρήση Τεχνητής Νοημοσύνης	9
2.3 Θεμελίωση της Μεθοδολογίας και η Εξέλιξη του Διαγνωστικού Μοντέλου	11
2.4 Συγκριτική Ανάλυση Προηγούμενων Μοντέλων Μηχανικής Μάθησης	13
3 Θεωρητική και Πρακτική Περιγραφή	14
3.1 Θεωρητική Περιγραφή Εργασιών	15
3.1.1.1 Θεωρητική Προσέγγιση και Μετρικές	16
3.1.1.2 Ανάλυση Αλγορίθμων για Απομόνωση Όγκου και Απόδοση	17
3.1.2.1 Ορισμός και Μαθηματική Μοντελοποίηση του Όγκου (Mass/Cancer) στην Ψηφιακή Εικόνα	19
3.1.2.2 Θεωρία Χώρου Κλιμάκωσης και Πολυκλιμακωτή Ανίχνευση	19
3.1.2.3 Ανασκόπηση και Σύγκριση Ανιχνευτών Ενδιαφέροντος	19
3.1.2.4 Η Θεωρία της Ανάλυσης Υφής μέσω GLCM	20
3.1.2.5 Τεχνητή Νοημοσύνη και Μηχανική Μάθηση στην Ιατρική AIM	20
3.1.3.1 Εισαγωγή και Κλινικό Υπόβαθρο	21
3.1.3.2 Ενσωμάτωση της Τεχνητής Νοημοσύνης στη Διαγνωστική	21
3.1.4.1 Καρκίνο του Μαστού και Διάφορες Εξελίξεις	22
3.1.4.2 Θεωρητικό Υπόβαθρο για Ανάλυση του Καρκίνου Μαστού	23
3.2 Πρακτική Περιγραφή Εργασιών	25
3.2.1.1 Αρχική Πρακτική Προσέγγιση	25
3.2.1.2 Απομόνωση και Ανάλυση της Περιοχής Ενδιαφέροντος	26
3.2.1.3 Ταξινόμηση, Εκπαίδευση και Αξιολόγηση Μοντέλων	26
3.2.2.1 Προεπεξεργασία και Απομόνωση της Βλάβης	27
3.2.2.2 Ψηφιακή Ανάλυση Υφής και Εξαγωγή Χαρακτηριστικών	28
3.2.2.3 Εκπαίδευση και Ταξινόμηση με το Λογισμικό WEKA	28
3.2.2.4 Χρήση Νευρωνικών Δικτύων και Τελική Διάγνωση	29
3.2.2.4 Αποτελέσματα Εργαλείων Εκπαίδευσης	29
3.2.3.1 Πρακτική Αξιολόγηση με Βάση της Θεωρίας	30
3.2.3.2 Εκπαίδευση Μοντέλων και Αποτελέσματα	30

3.2.4.1 Χρήση Explainable Artificial Intelligence	31
3.2.4.2 Πειραματική Διαδικασία και Παράγοντες	31
3.2.4.3 Αποτελέσματα και Αξιολογήσεις Κάθε Διαφορετικής Μέθοδο	32
4 Μετέπειτα Εργασίας	34
5 Σύνοψη και Συμπεράσματα	38
5.1 Σύνοψη	38
5.2 Συμπεράσματα.....	38
6 Βιβλιογραφία.....	39

1 Εισαγωγή

Ο καρκίνος αποτελεί μία από τις πλέον κρίσιμες προκλήσεις για την παγκόσμια δημόσια υγεία, με τα δεδομένα του οργανισμού GLOBOCAN να αναφέρουν σχεδόν 20 εκατομμύρια νέα κρούσματα και 9,7 εκατομμύρια θανάτους για το έτος 2022 [2]. Ανάμεσα στις διάφορες μορφές της νόσου, ο καρκίνος του στόματος ξεχωρίζει για την εξαιρετικά επιθετική του φύση, καθώς επηρεάζει τους ιστούς του στόματος και του φάρυγγα. Η νόσος συχνά ξεκινά με ανεπαίσθητες αλλαγές στους μαλακούς ιστούς που μπορεί να διαφύγουν της προσοχής στα αρχικά στάδια, με αποτέλεσμα η διάγνωση να γίνεται σε προχωρημένο επίπεδο, γεγονός που μειώνει δραματικά τις πιθανότητες επιβίωσης των ασθενών [3].

Οι παραδοσιακές διαγνωστικές προσεγγίσεις, οι οποίες περιλαμβάνουν την οπτική επιθεώρηση, τις βιοψίες και τις ακτινολογικές απεικονίσεις, αντιμετωπίζουν σοβαρούς περιορισμούς [3]. Η χειροκίνητη ερμηνεία των ιατρικών εικόνων από τους ακτινολόγους είναι συχνά υποκειμενική, εντάσεως εργασίας και χρονοβόρα [2]. Επιπλέον, έρευνες δείχνουν ότι το ανθρώπινο σφάλμα αποτελεί την κύρια πηγή δυσμενών διαγνωστικών αποτελεσμάτων, αγγίζοντας σε ορισμένες περιπτώσεις το 96,3% [1]. Οι βιοψίες, αν και προσφέρουν οριστικά αποτελέσματα, παραμένουν επεμβατικές και απαιτούν χρόνο, προκαλώντας συχνά καθυστερήσεις στην έναρξη της θεραπείας [3].

Η ενσωμάτωση της τεχνητής νοημοσύνης και της μηχανικής μάθησης μέσω συστημάτων Υπολογιστικής Υποβοηθούμενης Διάγνωσης (CAD) προσφέρει καινοτόμες λύσεις που μεταμορφώνουν τη διαγνωστική διαδικασία. Αυτά τα συστήματα έχουν την ικανότητα να επεξεργάζονται σύνθετα σύνολα δεδομένων και να εντοπίζουν μικροσκοπικά χαρακτηριστικά και πρότυπα που το ανθρώπινο μάτι αδυνατεί να διακρίνει [2]. Η χρήση προηγμένων αλγορίθμων, όπως τα συνελκτικά νευρωνικά Δίκτυα (CNN), επιτρέπει την αυτόματη εξαγωγή χαρακτηριστικών υφής (μέσω μεθόδων όπως το GLCM), σχήματος και χρώματος από τις ιατρικές εικόνες, ενισχύοντας την ακρίβεια της ανίχνευσης [3].

Η έγκαιρη ταυτοποίηση μέσω αυτών των τεχνολογιών είναι καθοριστική, καθώς επιτρέπει την εφαρμογή λιγότερο επεμβατικών και πιο αποτελεσματικών θεραπειών, βελτιώνοντας θεαματικά την πρόγνωση [2] [3]. Μελέτες έχουν δείξει ότι με τη σωστή προεπεξεργασία δεδομένων, όπως η κανονικοποίηση η ακρίβεια των μοντέλων μπορεί να φτάσει έως και το 94% [3]. Παράλληλα, η ανάδυση της Επεξηγήσιμης Τεχνητής Νοημοσύνης (XAI), με τη χρήση εργαλείων όπως το SHAP και το LIME, ενισχύει τη διαφάνεια και την εμπιστοσύνη των κλινικών ιατρών, καθιστώντας τις αποφάσεις των μοντέλων κατανοητές και αξιόπιστες για την καθημερινή ιατρική πράξη [1].

Τέλος, η ερευνητική εργασία [4] εστιάζει στην έγκαιρη ανίχνευση του καρκίνου μέσω καινοτόμων τεχνικών μηχανικής μάθησης. Η προσέγγιση χρησιμοποιεί αναπαραστάσεις πολλαπλής κλίμακας για τον εντοπισμό όγκων μεταβλητού μεγέθους και τον αλγόριθμο GLCM για την ανάλυση της υφής των ιστών. Η διαδικασία περιλαμβάνει προεπεξεργασία με διάμεσα φίλτρα και συσταδοποίηση K-means για την απομόνωση των ύποπτων περιοχών. Μέσω αλγορίθμων όπως τα SVM και τα τεχνητά νευρωνικά δίκτυα (ANN), επιτυγχάνεται αυτοματοποιημένη διάγνωση με στόχο την ελαχιστοποίηση του ανθρώπινου σφάλματος [4].

Σύντομα, σε κουκίδες μπορούμε να εξηγήσουμε ότι στις ερευνητικές εργασίες που έχουμε εξηγούν τα εξής :

- **Early cancer detection using deep learning and medical imaging: A survey :**
Μια εκτενής επισκόπηση της διαγνωστικής ροής εργασίας (από τη συλλογή εικόνων έως την αξιολόγηση) για 12 τύπους καρκίνου.
- **An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage :** Παρουσίαση καινοτόμων μεθόδων (SVM, GLCM) για τη διάγνωση όγκων σε πρώιμο στάδιο μέσω ανάλυσης υφής εικόνας.
- **Predictive identification of oral cancer using AI and machine learning:**
Μελέτη εστιασμένη στον καρκίνο του στόματος που αναδεικνύει την κανονικοποίηση ως την πιο αποτελεσματική μέθοδο για τη βελτίωση της ακρίβειας των μοντέλων.
- **Detection of breast cancer using machine learning and explainable artificial intelligence :** Εφαρμογή εργαλείων Explainable Artificial Intelligence (όπως SHAP και LIME) για τη διασφάλιση διαφάνειας και τη μείωση των διαγνωστικών λαθών στην κλινική πράξη

1.1 Σκοπός

Ο γενικός σκοπός των τεσσάρων ερευνητικών εργασιών είναι η αντιμετώπιση του καρκίνου ως κρίσιμη παγκόσμια πρόκληση υγείας μέσω της έγκαιρης και ακριβούς διάγνωσης με χρήση εργαλείων της σύγχρονης εποχής. Οι προσπάθειες αυτές γίνονται για να διορθωθούν τα προβλήματα που έχουν οι παλιές μέθοδοι.

Αν αναλύσουμε για κάθε paper το σκοπό της εργασίας μαζί με κάποιες προσεγγίσεις για καλύτερη κατανόηση θα έχουμε:

Early cancer detection using deep learning and medical imaging: A survey :
Συστηματική Ανασκόπηση

- Σκοπός: Η παροχή μιας ολοκληρωμένης επισκόπησης των μεθόδων ανίχνευσης καρκίνου μέσω βαθιάς μάθησης και ιατρικής απεικόνισης για 12 διαφορετικούς τύπους καρκίνου, γεφυρώνοντας τα κενά της προηγούμενης βιβλιογραφίας.
- Προσεγγίσεις: Αναλύεται ολόκληρη η ροή εργασίας: συλλογή δεδομένων, προεπεξεργασία εικόνας, segmentation, εξαγωγή χαρακτηριστικών και εφαρμογή μοντέλων όπως τα CNN και η μεταφορά μάθησης.

An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage:
Διάγνωση σε Πρώιμο Στάδιο

- Σκοπός: Η ανάπτυξη καινοτόμων προσεγγίσεων για τη διάγνωση του καρκίνου σε πολύ αρχικό επίπεδο, εντοπίζοντας περιοχές που οι συμβατικοί ανιχνευτές άκρων αδυνατούν να διακρίνουν.
- Προσεγγίσεις: Χρησιμοποιείται αναπαράσταση πολλαπλής κλίμακας των εικόνων και ο αλγόριθμος GLCM για την ανάλυση της υφής των ιστών. Η μεθοδολογία περιλαμβάνει προ-κατάτμηση με K-means clustering και ταξινόμηση με SVM και τεχνητά νευρωνικά δίκτυα.

Predictive identification of oral cancer using AI and machine learning : Εστίαση στον Καρκίνο του Στόματος

- Σκοπός: Η βελτίωση της πρόβλεψης και διάγνωσης του καρκίνου του στόματος μέσω AI με εξέταση πώς οι τεχνικές καθαρισμού δεδομένων επηρεάζουν την απόδοση των μοντέλων.
- Προσεγγίσεις: Συγκρίνονται τρεις τεχνικές προεπεξεργασίας: η κανονικοποίηση, η ανίχνευση ακραίων τιμών (outlier detection) και η συμπλήρωση ελλειπουσών τιμών. Χρησιμοποιούνται αλγόριθμοι CNN, SVM και Random Forests, με την κανονικοποίηση min-max να επιτυγχάνει την υψηλότερη ακρίβεια (94%).

Detection of breast cancer using machine learning and explainable artificial intelligence: Επεξηγήσιμη Τεχνητή Νοημοσύνη (XAI)

- Σκοπός: Η ακριβής διάγνωση του καρκίνου του μαστού με παράλληλη ενίσχυση της διαφάνειας και της εμπιστοσύνης των ιατρών μέσω της κατανόησης των αποφάσεων του μοντέλου.
- Προσεγγίσεις: Χρησιμοποιούνται πολλαπλοί ταξινομητές και ένα μοντέλο συνόλου (stacked ensemble). Η καινοτομία έγκειται στην εφαρμογή ετερογενών τεχνικών XAI (όπως SHAP, LIME, ELI5, Anchor), οι οποίες αποκαλύπτουν τους παράγοντες που οδηγούν σε κάθε πρόβλεψη.

Τελός, θα μπορούσαμε να πούμε ότι ο κοινός τόπος όλων των εργασιών είναι η χρήση ιατρικών εικόνων και η εφαρμογή προηγμένων υπολογιστικών τεχνικών. Οι προσεγγίσεις τους επικεντρώνονται στην ποιότητα των δεδομένων (προεπεξεργασία) την ακριβή εξαγωγή χαρακτηριστικών και την ανάγκη για ερμηνεύσιμα αποτελέσματα που μπορούν να ενσωματωθούν στην καθημερινή κλινική πράξη.

1.2 Στόχος

Ο καρκίνος αποτελεί μία από τις μεγαλύτερες απειλές για την ανθρωπότητα, με εκατομμύρια νέα περιστατικά κάθε χρόνο. Ο βασικός και κυρίαρχος στόχος όλων των εργασιών που μελετήθηκαν είναι να βρεθεί ένας τρόπος ώστε η διάγνωση να γίνεται πιο γρήγορα, πιο νωρίς και με πολύ μεγαλύτερη ακρίβεια από ό,τι σήμερα.

Οι ερευνητές αναγνωρίζουν ότι οι παραδοσιακές μέθοδοι, όπως η απλή οπτική εξέταση ή οι επεμβατικές βιοψίες, έχουν όρια: είναι συχνά υποκειμενικές, μπορεί να καθυστερήσουν τη θεραπεία ή να οδηγήσουν σε ανθρώπινα σφάλματα, τα οποία αποτελούν την κύρια πηγή λανθασμένων διαγνώσεων.

Ένας κεντρικός στόχος είναι η ελαχιστοποίηση του ανθρώπινου λάθους. Επειδή οι γιατροί είναι άνθρωποι και μπορεί να κουραστούν ή να παραβλέψουν μικρές λεπτομέρειες, οι εργασίες στοχεύουν στη δημιουργία συστημάτων υπολογιστικής υποβοηθούμενης διάγνωσης ή αλλιώς CAD όπου με αυτά τα συστήματα θα στοχεύουμε να λειτουργούν σαν ένα άλλος ελεγκτής για ανθρώπινα λάθη. Το καλό τέτοιων συστημάτων είναι προφανές ότι δεν κουράζεται ποτέ και μπορεί να επεξεργάζεται τεράστιους όγκους δεδομένων σε δευτερόλεπτα.

Πέρα από την ταχύτητα, μεγάλο στοίχημα είναι η ποιότητα των δεδομένων. Ένας από τους στόχους είναι να αποδειχθεί ότι η σωστή προετοιμασία των ιατρικών εικόνων όπως ο καθαρισμός από θόρυβο ή η κανονικοποίηση είναι εξίσου σημαντική με τον ίδιο τον

αλγόριθμο. Για παράδειγμα, η έρευνα δείχνει ότι αν προετοιμάσουμε σωστά τα δεδομένα, η ακρίβεια της διάγνωσης μπορεί να εκτοξευθεί στο 94%, κάτι που σώζει ζωές.

Table 6
MSE and accuracy of models before and after normalization.

Model	MSE (Before Normalization)	Accuracy (Before Normalization)	MSE (After Normalization)	Accuracy (After Normalization)
CNN Model	0.020	89 %	0.013	94 %
SVM Model	0.025	85 %	0.018	91 %
Random Forest Model	0.022	87 %	0.016	92 %

Εικόνα 1: Παρατήρηση Βελτίωσης Ποσοστού ανά Κατηγορία με την Εξέλιξη

Ένας άλλος εξαιρετικά σημαντικός στόχος είναι η διαφάνεια και η εμπιστοσύνη. Οι ερευνητές δεν θέλουν απλώς μια μηχανή που ουσιαστικά να μας λέει μόνο ότι υπάρχει ή δεν υπάρχει στον καρκίνο, αλλά μια μηχανή που να μπορεί να εξηγήσει στον γιατρό το γιατί πήρε αυτή την απόφαση. Αυτό ονομάζεται explainable AI και ο στόχος της είναι να μετατρέψει τα σύνθετα μαθηματικά μοντέλα σε εργαλεία που ο γιατρός μπορεί να

Επιπλέον, οι εργασίες στοχεύουν στην ανίχνευση του καρκίνου σε πολύ αρχικά στάδια, εκεί όπου οι όγκοι είναι τόσο μικροί που οι παραδοσιακοί ανιχνευτές άκρων αδυνατούν να τους δουν. Μέσω της ανάλυσης της υφής των ιστών και της χρήσης αναπαραστάσεων πολλαπλής κλίμακας, ο στόχος είναι να εντοπίζονται οι αλλοιώσεις όταν είναι ακόμα διαχειρίσιμες, αυξάνοντας δραματικά τις πιθανότητες επιβίωσης των ασθενών.

Σε ένα πιο γενικό επίπεδο, οι εργασίες επιδιώκουν να δημιουργήσουν έναν ολοκληρωμένο workflow για τη χρήση της βαθιάς μάθησης στην ογκολογία. Δεν επικεντρώνονται μόνο σε έναν τύπο καρκίνου αλλά προσπαθούν να καλύψουν ένα ευρύ φάσμα προσφέροντας λύσεις που μπορούν να εφαρμοστούν σε διαφορετικά νοσοκομεία και πληθυσμούς.

Τέλος, ο απώτερος στόχος είναι η εκδημοκρατισμός της υψηλής ποιότητας διάγνωσης. Μέσω εφαρμογών για κινητά τηλέφωνα και ελαφριών μοντέλων AI, η έρευνα στοχεύει στο να φτάσει η έγκαιρη διάγνωση ακόμα και σε περιοχές με περιορισμένους πόρους ή έλλειψη εξειδικευμένων γιατρών, προσφέροντας μια προσιτή και αξιόπιστη λύση υγείας για όλους.

Θα πρέπει να προσέξουμε ότι ο στόχος δεν είναι να αντικατασταθεί ο γιατρός αλλά να εξοπλιστεί με πανίσχυρα ψηφιακά εργαλεία που θα κάνουν τη διάγνωση του καρκίνου μια διαδικασία διάφανη και το πιο σημαντικό ακριβή.

2 Προηγούμενες Σχετικές Μελέτες

Σε αυτή την ενότητα θα μελετήσουμε άλλες ερευνητικές εργασίες που είναι σχετικές με κάθε μία εργασία που έχουμε. Ο στόχος είναι να καταλάβουμε τα βήματα που έχουν ιδρυθεί για ένα τελικό αποτέλεσμα έτσι ώστε να εξελιχθεί στην συνέχεια η εργασία. Ουσιαστικά, είναι ένα πρώτο βήμα για κατανόηση και προορισμού σε επόμενα στάδια των εργασιών έτσι ώστε να έχουμε την δυνατότητα κατανόησης αλλά και ακόμη για περαιτέρω έρευνα που θα βοηθούσαν οι παλιότερες αλλά και συγκεκριμένες εργασίες που διαθέτουμε για την ερευνητική ανασκόπηση.

2.1 Στατιστική Θεμελίωση


Στην πρώτη υποενότητα θα βασιστούμε στην εργασία “Early cancer detection using deep learning and medical imaging: A survey” η οποία είναι ένα survey που θα μπορέσουμε να αναλύσουμε όλη την διαδικασία ανασκόπησης με στατιστικά και συγκρίσεις των διάφορων τρόπων ανίχνευσης καρκίνου. Βέβαια, εκτός από την δική μας εργασία έχουμε και άλλες προηγούμενες ανασκοπήσεις που βοηθάνε να καταλήγουμε σε ένα πιο ευρύ αποτέλεσμα.

Η ερευνητική προσέγγιση της συγκεκριμένης εργασίας θεμελιώνεται αρχικά στα ανησυχητικά στατιστικά δεδομένα παγκόσμιων οργανισμών, όπως ο GLOBOCAN [5] και η American Cancer Society [7], που αναδεικνύουν την επιτακτική ανάγκη για συστήματα έγκαιρης ανίχνευσης λόγω της αυξανόμενης επίπτωσης διαφόρων μορφών καρκίνου, συμπεριλαμβανομένου του καρκίνου του στόματος.

Η μελέτη αναπτύχθηκε ως απάντηση στους περιορισμούς προηγούμενων ανασκοπήσεων, όπως των [7]-[11] οι οποίες συχνά εστίαζαν σε συγκεκριμένους τύπους καρκίνου ή περιόριζαν την ανάλυσή τους μόνο στους αλγορίθμους, παραλείποντας κρίσιμα στάδια όπως η προεπεξεργασία εικόνας, η segmentation και η εξαγωγή χαρακτηριστικών.

Παράλληλα, η έρευνα αξιοποίησε το επιστημονικό υπόβαθρο των συστημάτων υπολογιστικής υποβοηθούμενης διάγνωσης, όπως αναφέρονται από την εργασία [6], με σκοπό τη μείωση του ανθρώπινου σφάλματος και την ενίσχυση της ακρίβειας μέσω της ανάλυσης σύνθετων δεδομένων που το ανθρώπινο μάτι μπορεί να παραβλέψει. Καταλήγοντας σε αυτή τη σύνθεση, οι συγγραφείς δημιούργησαν ένα ολοκληρωμένο συστηματικό workflow που καλύπτει 12 τύπους καρκίνου, γεφυρώνοντας το υπάρχον ερευνητικό χάσμα και προσφέροντας έναν πλήρη οδικό χάρτη για τη μελλοντική ανάπτυξη διαγνωστικών τεχνολογιών.

Το workflow που ουσιαστικά θα είναι ο εγκέφαλος της εργασίας, θα αναλυθεί στα επόμενα στάδια όπου θα περιγράψουμε την τεχνική όψη της εργασίας, συγκεκριμένα θα σε αυτό το στάδιο της εργασίας θα αναλύσουμε μία τεχνική που θα λέγαμε είναι βασικό και για το μάθημα ανάκτησης πληροφορίας, όπου θα γίνει η χρήση ουσιαστικά ενός φίλτρου για να καταλήξουμε σε ένα συγκεκριμένο αποτέλεσμα, βέβαια όπως αναφερθήκαμε αυτή η διαδικασία είναι ένα υπόβαθρο για τα επόμενα στάδια. Από την εργασία [6] έχουμε την συγκεκριμένη εικόνα όπου είναι μία τεχνική για σωστό detection.



Εικόνα 2: Διαδικασία Επιλογής Μελετών

Η διαδικασία ξεκινά με τον εντοπισμό 2.579 αναφορών από μεγάλες βάσεις δεδομένων όπως το Scopus, το PubMed και το ScienceDirect, εξασφαλίζοντας ότι καλύπτεται όλο το εύρος της διαθέσιμης βιβλιογραφίας για την ανίχνευση του καρκινώματος μέσω τεχνητής νοημοσύνης.

Στο επόμενο στάδιο πραγματοποιείται η αφαίρεση 1.221 διπλότυπων εγγραφών και ο προκαταρκτικός έλεγχος των τίτλων και των περιλήψεων, γεγονός που επιτρέπει στους ερευνητές να απορρίψουν άμεσα τις μελέτες που δεν σχετίζονται με το αντικείμενο.

Οι εναπομείνουσες μελέτες αξιολογούνται πλήρως βάσει αυστηρών κριτηρίων ένταξης και αποκλεισμού, όπου εξετάζεται η καταλληλότητα της μεθοδολογίας και η χρήση ιστοπαθολογικών εικόνων, οδηγώντας στην τελική επιλογή των 101 πιο ποιοτικών άρθρων.

Ολόκληρο το διάγραμμα ροής λειτουργεί ως εγγύηση για την επιστημονική εγκυρότητα της ανασκόπησης, καθώς επιτρέπει σε οποιονδήποτε τρίτο ερευνητή να κατανοήσει πλήρως πώς και γιατί επιλέχθηκαν οι συγκεκριμένες πηγές, διασφαλίζοντας την επαναληψιμότητα της μελέτης.

Τέλος, βέβαια, αυτή η μέθοδος είναι γενική αλλά μία τεχνική που καταλήγει σε κατάργηση ανωμαλιών για καλύτερα αποτελέσματα με αποτέλεσμα σε χρήση και στο πρακτικό μέρος της εργασίας σε πιο συγκεκριμένη στάση.

2.2 Μεθοδολογική Προσέγγιση και Χρήση Τεχνητής Νοημοσύνης

Συνεχίζουμε για με την εργασία “Predictive identification of oral cancer using AI and machine learning” όπου βασίζεται στην αναγνώριση των σοβαρών περιορισμών που παρουσιάζουν οι παραδοσιακές διαγνωστικές μέθοδοι, όπως η οπτική επιθεώρηση και οι βιοψίες, οι οποίες συχνά οδηγούν σε καθυστερημένη διάγνωση του καρκίνου του

στόματος. Για να οριστεί το θέμα και να τεκμηριωθεί η ανάγκη για τη χρήση της τεχνητής νοημοσύνης, η μελέτη στηρίχθηκε σε προηγούμενες εργασίες που ανέδειξαν την αποτελεσματικότητα των αλγορίθμων και τη σημασία της ποιότητας των δεδομένων.

Αρχίζοντας από το υπόβαθρο με την εργασία **[12]** όπου αποτέλεσε τη βάση για την κατανόηση των προκλήσεων στις παραδοσιακές μεθόδους προσυμπτωματικού ελέγχου, επισημαίνοντας ότι οι οπτικές εξετάσεις μπορεί να είναι υποκειμενικές και επιρρεπείς σε μεταβλητότητα. Δηλαδή, στην περίπτωση μας οι ανθρώπινες ενέργειες είναι πάρα πολύ σημαντικές με αποτέλεσμα πιθανών λαθών. Παρόλο αυτό, η εργασία είναι μία καλή όψη για οικονομικούς λόγους.

Συνεχίζουμε με την εργασία **[13]** που παρέχει μια ολοκληρωμένη αξιολόγηση των CNN για την ανίχνευση του καρκίνου του δέρματος και του στόματος μέσω ιατρικών εικόνων.

Αυτόματη Εξαγωγή Χαρακτηριστικών όπου το κύριο εύρημα είναι ότι τα CNN έχουν την ικανότητα να εξαγάουν και να αναλύουν αυτόματα σύνθετα πρότυπα από τις εικόνες, τα οποία είναι κρίσιμα για την ταυτοποίηση καρκινικών αλλοιώσεων.

Όπου υπάρχει μία υπεροχή διαδικασία έναντι παραδοσιακών μεθόδων με την μελέτη απέδειξε ότι οι προσεγγίσεις που βασίζονται στην Τεχνητή Νοημοσύνη (όπως τα CNN και οι Μηχανές Διανυσμάτων Υποστήριξης - SVM) μπορούν να ξεπεράσουν σε ακρίβεια και αξιοπιστία τις συμβατικές διαγνωστικές προσεγγίσεις.

Έπειτα, με την εργασία **[14]** εστιάζει στην επίδραση της κανονικοποίησης των δεδομένων στην απόδοση της ταξινόμησης των μοντέλων.

Με Ομοιόμορφη Κλίμακα απέδειξαν ότι η κλιμάκωση των τιμών των χαρακτηριστικών σε ένα ενιαίο εύρος όπως η min-max scaling είναι απαραίτητη για τη βελτίωση της εκπαίδευσης του μοντέλου και της προβλεπτικής του ακρίβειας.

Αλλά με μείωση μεροληψίας (bias) Η σωστή προεπεξεργασία μέσω κανονικοποίησης αποτρέπει την εμφάνιση μεροληψίας κατά τη διαδικασία εκπαίδευσης, επιτρέποντας στον αλγόριθμο να μαθαίνει πιο αποτελεσματικά από τα δεδομένα. Αυτό αποτέλεσε τη βάση για τους Patel και Kumar (συγκεκριμένη εργασία) ώστε να επιτύχουν το υψηλό ποσοστό ακρίβειας 94%

Τέλος, η διαδρομή προς την τρέχουσα μελέτη των Patel και Kumar ξεκίνησε βηματικά από την εργασία **[12]**, η οποία έθεσε το κλινικό θεμέλιο προσδιορίζοντας την υποκειμενικότητα και τις παγκόσμιες προκλήσεις των παραδοσιακών μεθόδων προσυμπτωματικού ελέγχου, αναδεικνύοντας έτσι την ανάγκη για πιο ακριβή διαγνωστικά εργαλεία. Στη συνέχεια, η έρευνα **[13]** παρείχε την τεχνολογική λύση αποδεικνύοντας ότι τα CNN μπορούν να εξαγάουν αυτόματα σύνθετα πρότυπα από ιατρικές εικόνες, ξεπερνώντας σε αξιοπιστία τις συμβατικές προσεγγίσεις. Η μεθοδολογική προσέγγιση ολοκληρώθηκε με την εργασία **[14]**, η οποία ήταν καθοριστική για την εστίαση στην κανονικοποίηση των δεδομένων, τεκμηριώνοντας ότι η σωστή προεπεξεργασία των χαρακτηριστικών είναι το κλειδί για τη βελτιστοποίηση της απόδοσης και την επίτευξη της υψηλής ακρίβειας.

2.3 Θεμελίωση της Μεθοδολογίας και η Εξέλιξη του Διαγνωστικού Μοντέλου

Σε αυτό το σημείο θα αναλύσουμε την ερευνητική εργασία “An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage” όπου θα προσπαθήσουμε να βρούμε βέλτιστες λύσεις για διάγνωση καρκίνου. Η προσέγγιση της εργασίας βασίζεται στην ανάγκη για έγκαιρη διάγνωση του καρκίνου, ένα στάδιο όπου η θεραπεία μπορεί να προσφέρει σχεδόν 100% ποσοστό επιβίωσης. Η μελέτη οδηγείται στη συγκεκριμένη μεθοδολογία αναγνωρίζοντας ότι οι παραδοσιακοί ανιχνευτές άκρων ή γωνιών αδυνατούν να εντοπίσουν κρίσιμες περιοχές ενδιαφέροντος, καθιστώντας αναγκαία τη χρήση προηγμένων αλγορίθμων.


Η εργασία αυτή βασίζεται σε προηγούμενες εργασίες που βοήθησαν στην μία εξαιρετική προσέγγιση της έρευνας. Αρχικά η εργασία [15] ήταν καθοριστική για την εστίαση στην ταυτοποίηση μικρών καρκινικών αλλοιώσεων (Small Cancer Identification). Όπου χρησιμοποίησαν τοπικά χαρακτηριστικά από τη λεγόμενη βέλτιστη κλίμακα ή αλλιώς optimum scale, παρέχοντας το υπόβαθρο για τη χρήση της θεωρίας χώρου-κλίμακας (scale space theory) που υιοθετήθηκε από τους συγγραφείς της συγκεκριμένης εργασίας, για τον εντοπισμό όγκων μεταβλητού μεγέθους

Η θεωρία του χώρου-κλίμακας (Scale space theory) αποτελεί ένα δομημένο πλαίσιο για την αναπαράσταση σημάτων σε πολλαπλές κλίμακες, επιτρέποντας την επεξεργασία δομών εικόνας έτσι ώστε τα χαρακτηριστικά λεπτής κλίμακας να καταστέλλονται σταδιακά. Στην πράξη, η θεωρία αυτή αντιμετωπίζει μια μεμονωμένη εικόνα ως μια στοίβα ή ένα σύνολο εικόνων, όπου κάθε επίπεδο συνδέεται με μια συγκεκριμένη παράμετρο κλίμακας (t). Όταν μια τοπική δομή είναι παρούσα σε ένα συγκεκριμένο εύρος κλιμάκων, τα σημεία ενδιαφέροντος αναγνωρίζονται σε κάθε κλίμακα εντός αυτού του εύρους, γεγονός που οδηγεί στον εντοπισμό πολλαπλών σημείων που αντιπροσωπεύουν την ίδια δομή αλλά με διαφορετική εντόπιση και μέγεθος.

Στον τομέα της έγκαιρης ανίχνευσης του καρκίνου, η θεωρία αυτή είναι ζωτικής σημασίας, καθώς οι καρκινικοί όγκοι και οι μάζες εμφανίζονται με διαφορετικούς τρόπους ανάλογα με την κλίμακά τους. Η δημιουργία αναπαράστασης επιτρέπει τον προσδιορισμό μιας ιδανικής κλίμακας για τον εντοπισμό μαζών με παρόμοια μεγέθη. Με την εφαρμογή κατάλληλων φίλτρων, όπως το Laplacian of Gaussian (LoG), τα συστήματα μπορούν να αναγνωρίσουν αποτελεσματικά καρκινικές αλλοιώσεις χωρίς να αυξάνεται υπερβολικά ο αριθμός των τοπικών μεγίστων στις φωτεινές μάζες.

Μια κεντρική έννοια αυτής της θεωρίας είναι οι scale-space masses οι οποίες επιτρέπουν τη μέτρηση της σταθερότητας των δομών της εικόνας. Η σταθερότητα αυτή υπολογίζεται μέσω του lifetime της μάζας στο χώρο-κλίμακα, η οποία ορίζεται ως ο αριθμός των κλιμάκων στις οποίες η δομή παραμένει ορατή.

Όσο μεγαλύτερη είναι η διάρκεια ζωής μιας μάζας, τόσο μεγαλύτερη σημασία αποκτά για τη διάγνωση, βοηθώντας στην επιλογή των πλέον κατάλληλων υποψηφίων περιοχών για περαιτέρω ανάλυση και ταξινόμηση μέσω αλγορίθμων όπως οι μηχανές διανυσμάτων υποστήριξης (SVM).



Εικόνα 3: Μέθοδος αναγνώρισης εικόνας σε διαφορετικό layout με χρήση Scale Space Theory [16]

Στην εργασία [17] παρείχε το ευρύτερο πλαίσιο για τις εφαρμογές της μηχανικής μάθησης στην πρόγνωση και πρόβλεψη του καρκίνου. Βοήθησε στον ορισμό του θέματος αναδεικνύοντας πώς τα υπολογιστικά μοντέλα μπορούν να ξεπεράσουν τους ανθρώπινους περιορισμούς στην ανάλυση τεράστιων όγκων ιατρικών δεδομένων.

Όπου ουσιαστικά χρησιμοποιούνται διάφορες τεχνικές που έχουμε μάθει από τη μάθημα τεχνητής νοημοσύνης όπως τα δέντρα απόφασης, και classification rules. Παρόλο που αυτές οι τεχνικές φαίνονται ότι είναι βασικές, χρησιμοποιούνται ακόμα και σε πιο περίπλοκες έρευνες για να καταλήξουμε σε ένα αποτέλεσμα.

Στην συνέχεια η εργασία [18] επικεντρώθηκε στην ανάπτυξη ενός αυτοματοποιημένου συστήματος διάγνωσης για τον καρκίνο του δέρματος, πραγματοποιώντας μια λεπτομερή ανάλυση της απόδοσης διαφόρων αλγορίθμων εκμάθησης νευρωνικών δικτύων για την ταξινόμηση των αλλοιώσεων. Η έρευνα αυτή ήταν ιδιαίτερα σημαντική για την πρόγνωση του μελανώματος, καθώς η έγκαιρη διάγνωση μπορεί να οδηγήσει σε ποσοστά επιβίωσης που αγγίζουν το 100%, ενώ η παραδοσιακή κλινική εξέταση παραμένει συχνά υποκειμενική και εξαρτάται από την εμπειρία του ιατρού. Μέσω της χρήσης αλγορίθμων όπως η backpropagation, η εργασία παρείχε ένα πλαίσιο για την αξιολόγηση της αποτελεσματικότητας των υπολογιστικών μοντέλων στην αναγνώριση προτύπων, γεγονός που αποτέλεσε τη βάση για τη χρήση της τεχνητής νοημοσύνης στην ιατρική διάγνωση.

Στο πλαίσιο της παρούσας μελέτης, η συνεισφορά της εργασίας είναι καθοριστική για τη διαχείριση της θεωρίας του χώρου-κλίμακας, καθώς αναδεικνύει την πρόκληση της εμφάνισης ενός υπερβολικά μεγάλου αριθμού σημείων ενδιαφέροντος όταν μια δομή αναγνωρίζεται σε πολλαπλές κλίμακες ταυτόχρονα. Αυτή η πολυπλοκότητα αυξάνει την πιθανότητα σφαλμάτων και απαιτεί αυστηρές μεθόδους επαλήθευσης των αποτελεσμάτων. Έτσι, τα ευρήματά του βοήθησαν στην επιλογή και την αξιολόγηση ισχυρών ταξινομητών, όπως τα ANN και οι SVM, διασφαλίζοντας ότι το προτεινόμενο σύστημα μπορεί να εντοπίζει με ακρίβεια τις καρκινικές περιοχές, μειώνοντας ταυτόχρονα το ανθρώπινο σφάλμα και την υπολογιστική επιβάρυνση.

2.4 Συγκριτική Ανάλυση Προηγούμενων Μοντέλων Μηχανικής Μάθησης

Τέλος, θα αναλύσουμε την εργασία “Detection of breast cancer using machine learning and explainable artificial intelligence” εστιάζει στην αντιμετώπιση του υψηλού ποσοστού ανθρώπινου σφάλματος στη διάγνωση, το οποίο σύμφωνα με τις πηγές αγγίζει το 96,3% των δυσμενών αποτελεσμάτων. Η μελέτη οδηγείται στη συγκεκριμένη μεθοδολογία αναγνωρίζοντας ότι, παρά την υψηλή ακρίβεια των μοντέλων μηχανικής μάθησης, η έλλειψη διαφάνειας στη λήψη αποφάσεων ουσιαστικά, το λεγόμενο πρόβλημα του “black box” αποτελεί εμπόδιο για την κλινική τους εφαρμογή.

Αν ξεκινήσουμε την ανάλυση από την εργασία [19] όπου αποτέλεσε κομβικό σημείο αναφοράς καθώς συνέκρινε άμεσα την απόδοση του AI με την ανθρώπινη εμπειρογνωμοσύνη. Οι ερευνητές δημιούργησαν ένα νέο σύνολο δεδομένων, το Breast-XD, το οποίο περιλάμβανε διαγνωστικές ετικέτες από 752 ασθενείς με καλοήθεις και κακοήθεις βλάβες,. Μεταξύ των έξι ταξινομητών που δοκιμάστηκαν, ο αλγόριθμος XGBoost πέτυχε την υψηλότερη ακρίβεια με 94,43%. Το πλέον αξιοσημείωτο εύρημα ήταν ότι το μοντέλο υπερείχε της διάγνωσης των ακτινολόγων, οι οποίοι πέτυχαν ακρίβεια 83,95%, επιβεβαιώνοντας έτσι την αξιοπιστία των αλγορίθμων μηχανικής μάθησης στην ιατρική. Για την κατανόηση των παραγόντων που οδήγησαν στις προβλέψεις, χρησιμοποιήθηκαν οι τεχνικές εξηγήσιμης τεχνητής νοημοσύνης SHAP και LIME.

Η έρευνα [20] εστίασε στη δυναμική των ensemble μοντέλων, προτείνοντας έναν συνδυασμό των αλγορίθμων SVM και Random Forest . Η μελέτη χρησιμοποίησε το γνωστό σύνολο δεδομένων Wisconsin (WDBC), το οποίο περιέχει 569 περιπτώσεις και 32 χαρακτηριστικά που προέρχονται από επεξεργασία εικόνας,. Αυτή η συνδυαστική προσέγγιση αποδείχθηκε εξαιρετικά σχολαστική και αποτελεσματική, επιτυγχάνοντας το εντυπωσιακό ποσοστό ακρίβειας και F1-score του 99,99%,. Όπως και στην προηγούμενη μελέτη, η τεχνική SHAP εφαρμόστηκε για την προώθηση της διαφάνειας στις αποφάσεις του μοντέλου, αποδεικνύοντας ότι η ένωση διαφορετικών τεχνικών μπορεί να μεγιστοποιήσει τη διαγνωστική ισχύ.

Η εργασία [20] επικεντρώθηκε στην ανάπτυξη ενός προγνωστικού μοντέλου ταξινόμησης σε ένα συγκεκριμένο δημογραφικό πλαίσιο, χρησιμοποιώντας δεδομένα από 500 ασθενείς του Dhaka Medical College Hospital στο Μπανγκλαντές,. Οι ερευνητές ανέλυσαν επτά γεωμετρικά χαρακτηριστικά που εξήχθησαν από ιατρικές εικόνες και εφάρμοσαν πέντε διαφορετικούς αλγορίθμους,. Ο αλγόριθμος XGBoost αναδείχθηκε και πάλι ως ο κορυφαίος, με ακρίβεια 97% και F1-score 96%,. Η χρήση της τεχνικής SHAP ήταν καθοριστική για την αποσαφήνιση των αποτελεσμάτων, ενισχύοντας την εμπιστοσύνη των ιατρών στις αυτοματοποιημένες προβλέψεις μέσω της παροχής διαφανών εξηγήσεων.

Το τελικό αποτέλεσμα αυτών των μελετών επιβεβαιώνει ότι η χρήση της AI, όταν τροφοδοτείται με μεγάλο όγκο δεδομένων, μπορεί να λειτουργήσει ως ένα πανίσχυρο υποστηρικτικό εργαλείο που ελαχιστοποιεί το ανθρώπινο σφάλμα το οποίο ευθύνεται για το 96,3% των δυσμενών διαγνωστικών εκβάσεων διασφαλίζοντας ταυτόχρονα διαφάνεια και εμπιστοσύνη στη διαδικασία λήψης ιατρικών αποφάσεων

3 Θεωρητική και Πρακτική Περιγραφή

Σε αυτή την ενότητα θα παρουσιάσουμε τις προτεινόμενες τεχνικές των εργασιών σε 2 στάδια, όπου στο πρώτο στάδιο θα βασιστούμε στην θεωρία με αναλύσεις και θεωρητικές προσεγγίσεις που έχουν γίνει πριν την πρακτική υλοποίηση. Έπειτα, θα δούμε το πρακτικό στάδιο για να καταλάβουμε πως εφαρμόζεται ουσιαστικά η θεωρία και τα αποτελέσματα που έχουμε ώστε να καταλάβουμε την εργασία σε κάθε στάδιο, αλλά και με την έννοια ότι θα υποστηρίζει και μελλοντικές εργασίες.

Οι περιγραφές θα γίνουν με μία σειρά έτσι ώστε να γίνεται μία καλύτερη σταδιακή κάλυψη χωρίς απορίες για τα επόμενα βήματα. Δηλαδή θα έχουμε μία ολοκληρωμένη διαδικασία έτσι ώστε η βέλτιστη σειρά παρουσίασης των τεσσάρων εργασιών ακολουθεί μια λογική πορεία από το γενικό πλαίσιο στην εξειδικευμένη θεωρία και, τέλος, στην προηγμένη κλινική εφαρμογή.

Αρχικά θα ξεκινήσουμε με το paper “ Early cancer detection using deep learning and medical imaging: A survey ” όπου πρόκειται για μια εκτενή ανασκόπηση (survey) 99 άρθρων που θέτει τις βάσεις για όλη τη συζήτηση.

Σαν θεωρία παρέχει μία συστηματική ροή εργασίας για την ανίχνευση του καρκίνου όπου είναι:

Απεικόνιση → Προεπεξεργασία → Κατάτμηση → Εξαγωγή Χαρακτηριστικών → Αλγόριθμοι → Αξιολόγηση.

Πρακτικά, παρέχει μια συγκριτική ανάλυση για 12 είδη καρκίνου και τις μετρικές αξιολόγησης (Accuracy, F1-Score κ.λπ.), λειτουργώντας ως ο χάρτης για τις επόμενες εξειδικευμένες μελέτες.

Στην συνέχεια σαν 2^ο paper έχουμε το “ An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage ” αφού ορίσαμε τη γενική ροή εργασίας, αυτή η εργασία εμβαθύνει σε μια κρίσιμη θεωρητική πτυχή της εξαγωγής χαρακτηριστικών που αναφέρθηκε στην πρώτη πηγή.

Εξηγεί το Scale Space Theory, η οποία επιτρέπει τον εντοπισμό καρκινικών όγκων μεταβλητού μεγέθους μέσω πολλών τομών αναπαράστασης της εικόνας. Παρουσιάζει τη χρήση του αλγορίθμου GLCM για την ανάλυση υφής και του SVM για την ταξινόμηση, δείχνοντας πώς η θεωρία εφαρμόζεται για τη μείωση του θορύβου και τον ακριβή εντοπισμό των αλλοιώσεων.

3^ο paper είναι το “Predictive identification of oral cancer using AI and machine learning” που μεταβαίνουμε σε μια συγκεκριμένη περίπτωση μελέτης (καρκίνος του στόματος), εστιάζοντας σε ένα πρακτικό βήμα που η πρώτη πηγή χαρακτήρισε απαραίτητο τον καθαρισμό των δεδομένων.

Αναδεικνύει την υποκειμενικότητα των παραδοσιακών μεθόδων και την ανάγκη για αντικειμενικά εργαλεία AI. Αλλά και αποδεικνύει μέσω πειραμάτων ότι η κανονικοποίηση και συγκεκριμένα το min-max scaling είναι η πιο καθοριστική τεχνική προεπεξεργασίας, επιτυγχάνοντας ακρίβεια 94% με μοντέλα CNN.

Τέλος έχουμε ως 4^ο paper το “ Detection of breast cancer using machine learning and explainable artificial intelligence ” που αποτελεί την κορύφωση της ανάλυσης, καθώς αντιμετωπίζει το μεγαλύτερο πρόβλημα που εντοπίστηκε στην πρώτη εργασία, την έλλειψη διαφάνειας των μοντέλων (black box με άλλη έννοια).

Εισάγει την έννοια της Εξηγήσιμης Τεχνητής Νοημοσύνης (XAI), η οποία καθιστά τις αποφάσεις των αλγορίθμων κατανοητές από τους γιατρούς. Χρησιμοποιεί ένα stacked ensemble μοντέλο (συνδυασμός πολλών αλγορίθμων) και πέντε διαφορετικές τεχνικές ερμηνείας (SHAP, LIME κ.λπ.) για τη διάγνωση του καρκίνου του μαστού, προσφέροντας μια λύση που είναι ταυτόχρονα ακριβής και κλινικά αξιόπιστη.

Σε ένα πίνακα έχουμε αυτή την σειρά:

no	Τίτλος Εργασίας
1	Early cancer detection using deep learning and medical imaging: A survey
2	An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage
3	Predictive identification of oral cancer using AI and machine learning
4	Detection of breast cancer using machine learning and explainable artificial intelligence

Πίνακας 1: Σειρά Ανάλυσης Εργασιών Θεωρητικά και Πρακτικά

3.1 Θεωρητική Περιγραφή Εργασιών


Η θεωρητική προσέγγιση των επιστημονικών εργασιών στον τομέα της ογκολογίας εστιάζει στην έγκαιρη και ακριβή διάγνωση, η οποία αποτελεί τον κρίσιμότερο παράγοντα για την επιτυχή θεραπεία και την αύξηση των ποσοστών επιβίωσης. Οι εργασίες αυτές αναγνωρίζουν ότι οι παραδοσιακές μέθοδοι, όπως η οπτική επιθεώρηση και οι επεμβατικές βιοψίες, ενέχουν περιορισμούς που σχετίζονται με την υποκειμενικότητα και το υψηλό ποσοστό ανθρώπινου σφάλματος, το οποίο μπορεί να αγγίξει το 96,3% των δυσμενών διαγνωστικών αποτελεσμάτων. Για την αντιμετώπιση αυτών των προκλήσεων, η έρευνα στρέφεται στο AI και ML αναπτύσσοντας υπολογιστικά μοντέλα που μπορούν να επεξεργάζονται τεράστιους όγκους ιατρικών δεδομένων και να εντοπίζουν μικροσκοπικές ανωμαλίες που διαφεύγουν από το ανθρώπινο μάτι.

Η μεθοδολογική τους βάση στηρίζεται σε τρεις πυλώνες: την αυστηρή προεπεξεργασία δεδομένων (όπως η κανονικοποίηση min-max) για τη βελτίωση της προβλεπτικής ακρίβειας, την εφαρμογή εξελιγμένων θεωριών εξαγωγής χαρακτηριστικών (όπως η θεωρία χώρου-κλίμακας για τον εντοπισμό όγκων μεταβλητού μεγέθους) και τη χρήση προηγμένων αρχιτεκτονικών, όπως τα CNN και τα ensemble μοντέλα. Τέλος, μια αναδυόμενη τάση στις μελέτες είναι η ενσωμάτωση του XAI όπως αναφερθήκαμε και σε άλλες ενότητες η οποία προσθέτει ένα επίπεδο διαφάνειας και ερμηνευσιμότητας στις αποφάσεις των αλγορίθμων, ενισχύοντας την εμπιστοσύνη των κλινικών ιατρών στα αυτοματοποιημένα διαγνωστικά εργαλεία.

3.1.1.1 Θεωρητική Προσέγγιση και Μετρικές

Αρχίζοντας από το 1^ο paper, ο καρκίνος ορίζεται θεωρητικά ως μια σύνθετη βιολογική διαδικασία όπου τα κύτταρα χάνουν τον έλεγχο του πολλαπλασιασμού τους, οδηγώντας σε κακοήθειες. Η σημασία της έγκαιρης ανίχνευσης δεν είναι μόνο ιατρική αλλά και στατιστική. Οι πιθανότητες ίασης αυξάνονται εκθετικά όταν η διάγνωση γίνει στα αρχικά στάδια (Stage I ή II). Η θεωρητική βάση της σύγχρονης διάγνωσης στηρίζεται στα συστήματα Computer-Aided Diagnosis (CAD), τα οποία λειτουργούν ως δεύτερη γνώμη για τον ακτινολόγο. Η ανάγκη για αυτά προκύπτει από τον τεράστιο όγκο δεδομένων που παράγουν οι ιατρικές απεικονίσεις, καθιστώντας τη χειροκίνητη ανάλυση επιρρεπή σε ανθρώπινα σφάλματα και κόπωση.

Θα εξηγήσουμε την ροή της εργασίας με τον τρόπο που έχει γίνει η ανάλυση και έπειτα θα περιγράψουμε τα βήματα. Όπου είναι αναλυτικές με segmentation κάθε καρκίνου για καλύτερη διαχείριση των δεδομένων.



Εικόνα 4: Συστηματική Ροή Εργασίας για την Ανίχνευση του Καρκίνου

Η Εικόνα 4 παρουσιάζει λεπτομερώς την ταξινόμηση των τύπων καρκίνου και τη συστηματική ροή εργασίας για τη διάγνυσή τους μέσω ιατρικής απεικόνισης και αλγορίθμων βαθιάς μάθησης. Στο πάνω μέρος της εικόνας, οι 12 τύποι καρκίνου ομαδοποιούνται με βάση το ανθρώπινο σύστημα που επηρεάζουν που είναι αναπαραγωγικό (μαστός, τράχηλος, ωοθήκες, προστάτης), πεπτικό (οισοφάγος, ήπαρ, πάγκρεας, παχύ έντερο), αναπνευστικό (πνεύμονας, στόμα) και άλλα συστήματα (εγκέφαλος, δέρμα).

Το κάτω μέρος περιγράφει τα απαραίτητα βήματα της διαγνωστικής διαδικασίας, ξεκινώντας από τη λήψη των ιατρικών εικόνων (ακτινολογία, παθολογία) και την προεπεξεργασία τους, η οποία περιλαμβάνει τεχνικές όπως η κανονικοποίηση, η αύξηση δεδομένων και η μείωση θορύβου.

Στη συνέχεια, ακολουθούν τα στάδια της segmentation για την απομόνωση των ύποπτων περιοχών της εξαγωγής χαρακτηριστικών και της εφαρμογής αλγορίθμων βαθιάς μάθησης (CNN, GAN, κ.ά.), συμπεριλαμβανομένης της χρήσης προεκπαιδευμένων μοντέλων μέσω μεταφοράς μάθησης (transfer learning). Η ροή εργασίας ολοκληρώνεται με το στάδιο της αξιολόγησης, όπου χρησιμοποιούνται δείκτες όπως η ακρίβεια (accuracy), η ανάκληση (recall) και το F1-score για την επιβεβαίωση της αποτελεσματικότητας του συστήματος ανίχνευσης

Η θεωρία ξεκινά με την κατανόηση του τρόπου λήψης των δεδομένων. Διαφορετικές τεχνολογίες προσφέρουν διαφορετικά επίπεδα πληροφορίας: η αξονική τομογραφία (CT) βασίζεται στην εξασθένηση των ακτίνων Χ, η μαγνητική τομογραφία (MRI) στην απόκριση των πρωτονίων σε μαγνητικά πεδία και οι υπέρηχοι στην ανάκλαση ηχητικών κυμάτων. Κάθε μέσο παράγει σήματα που μετατρέπονται σε ψηφιακές εικόνες (πίνακες pixels ή voxels), οι οποίες αποτελούν την είσοδο για τους αλγορίθμους βαθιάς μάθησης.

Πριν την ανάλυση, η θεωρία της επεξεργασίας σήματος επιβάλλει τον καθαρισμό των δεδομένων. Η εξίσωση του θορύβου (noise reduction) είναι κρίσιμη. Για παράδειγμα, χρησιμοποιούνται φίλτρα Gaussian για την εξομάλυνση:

$$Gauss(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

Εικόνα 5: Gaussian Fiter

Αυτή η μαθηματική προσέγγιση επιτρέπει στον αλγόριθμο να εστιάσει στα σημαντικά χαρακτηριστικά της εικόνας, μειώνοντας τις παρεμβολές από το μηχάνημα λήψης. Επιπλέον, η τεχνική του Histogram Equalization χρησιμοποιείται για τη βελτίωση της αντίθεσης, ώστε να γίνονται διακριτές οι οριακές διαφορές μεταξύ υγιούς και καρκινικού ιστού.

Έπειτα, οι μετρικές αξιολόγησης αποτελούν το θεωρητικό και μαθηματικό εργαλείο για την επαλήθευση της αξιοπιστίας των μοντέλων βαθιάς μάθησης. Η αναγκαιότητά τους πηγάζει από το γεγονός ότι στην ιατρική διάγνωση, ένα στατιστικό λάθος δεν είναι απλώς ένας αριθμός, αλλά μπορεί να σημαίνει είτε μια χαμένη ευκαιρία για έγκαιρη θεραπεία (ψευδώς αρνητικό), είτε μια αδικαιολόγητη ψυχολογική και σωματική ταλαιπωρία για τον εξεταζόμενο (ψευδώς θετικό). Η θεωρία των μετρικών βασίζεται στον confusion matrix, ο οποίος επιτρέπει τον διαχωρισμό της συνολικής ορθότητας (Accuracy) από την ικανότητα του μοντέλου να εντοπίζει συγκεκριμένα τους ασθενείς (Sensitivity/Recall) ή να αποκλείει με ακρίβεια τους υγιείς (Specificity).

Μαθηματικά, μετρικές όπως το F1-Score ή ο συντελεστής MCC χρησιμοποιούνται για να δώσουν μια πιο αντικειμενική εικόνα όταν τα δεδομένα είναι ανισοκατανομημένα (για παράδειγμα, όταν οι υγιείς εικόνες είναι πολύ περισσότερες από τις καρκινικές), διασφαλίζοντας ότι η πρακτική εφαρμογή του αλγορίθμου θα είναι κλινικά έγκυρη και ασφαλής.

3.1.1.2 Ανάλυση Αλγορίθμων για Απομόνωση Όγκου και Απόδοση

Η κατάτμηση είναι η θεωρητική διαδικασία απομόνωσης του όγκου από το υπόλοιπο όργανο. Εδώ χρησιμοποιούνται αλγόριθμοι όπως το U-Net [22]. Η θεωρία πίσω από το U-Net βασίζεται σε μια αρχιτεκτονική encoder-decoder. Ο encoder συρρικνώνει την εικόνα

για να καταλάβει το «τι» (το περιεχόμενο), ενώ ο decoder επεκτείνει την πληροφορία για να προσδιορίσει το «πού» (τη θέση).

Στη θεωρητική ανάλυση, η εξαγωγή χαρακτηριστικών αφορά τη μετατροπή της εικόνας σε διανύσματα χαρακτηριστικών (feature vectors). Χρησιμοποιούνται μέθοδοι όπως οι Grey-Level Co-occurrence Matrices (GLCM) για την ανάλυση του texture analysis. Οι εξισώσεις για την Ενέργεια, την Αντίθεση και την Εντροπία περιγράφουν μαθηματικά αν ένας ιστός είναι ομοιογενής ή παρουσιάζει ανωμαλίες.


Η καρδιά της σύγχρονης θεωρίας είναι τα CNNs. Η βασική πράξη είναι η συνέλιξη (convolution), η οποία περιγράφεται από την εξίσωση:

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau) g(t - \tau) d\tau$$

Εικόνα x: Συνέλιξη

Στην πράξη, μικρά φίλτρα (kernels) περνούν πάνω από την εικόνα για να ανιχνεύσουν γραμμές, σχήματα και τελικά σύνθετες δομές όγκων. Η θεωρία της Μεταφοράς Μάθησης (Transfer Learning) είναι επίσης κομβική: επιτρέπει τη χρήση μοντέλων που έχουν εκπαιδευτεί σε εκατομμύρια γενικές εικόνες (π.χ. ResNet, VGG16) και την προσαρμογή τους (fine-tuning) σε εξειδικευμένα ιατρικά δεδομένα, λύνοντας το πρόβλημα της έλλειψης μεγάλων ιατρικών συνόλων δεδομένων.

Τέλος, καμπύλη AUC-ROC (Area Under the Receiver Operating Characteristic) αποτελεί το θεωρητικό εργαλείο για να μετρήσουμε την απόδοση του μοντέλου σε διαφορετικά κατώφλια απόφασης, διασφαλίζοντας ότι ο αλγόριθμος είναι αξιόπιστος πριν εφαρμοστεί σε πραγματικούς ασθενείς.



Εικόνα 6: AUC-ROC για μέτρηση της απόδοσης

3.1.2.1 Ορισμός και Μαθηματική Μοντελοποίηση του Όγκου (Mass/Cancer) στην Ψηφιακή Εικόνα

Η θεωρητική προσέγγιση της ερευνητικής εργασίας (2^ο paper “An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage”) επικεντρώνεται στη σύγκλιση του computer vision, της ψηφιακής επεξεργασίας εικόνας και της μηχανικής μάθησης με σκοπό την έγκαιρη διάγνωση του καρκίνου. Το κείμενο αναλύει πώς οι αλγόριθμοι μπορούν να αναγνωρίζουν low-level objects και δομές σε ιατρικές εικόνες, προσφέροντας μια στέρεη μαθηματική και υπολογιστική βάση πριν από οποιαδήποτε πρακτική υλοποίηση.

Στο πεδίο της υπολογιστικής όρασης, η αναγνώριση ύποπτων περιοχών (όπως κυτταρικοί πυρήνες, εγκεφαλικοί όγκοι ή δερματικές αλλοιώσεις) ορίζεται θεωρητικά ως ανίχνευση μαζών (mass detection).

Ένας όγκος (mass) ορίζεται στην ένταση της εικόνας ως μια περιοχή που συνδέεται με τουλάχιστον ένα τοπικό ακρότατο (local extremum), δηλαδή ένα τοπικό μέγιστο ή ελάχιστο, το οποίο αντιπροσωπεύει μια φωτεινή ή σκοτεινή περιοχή αντίστοιχα.

Έπειτα, στη συνάρτηση έντασης της εικόνας, το saddle point είναι εκείνο το γεωμετρικό σημείο όπου η μεταβολή της έντασης σταματά να μειώνεται και αρχίζει να αυξάνεται (ή το αντίστροφο). Αυτό το σημείο θέτει το αυστηρό χωρικό όριο (spatial extent) της μάζας, επιτρέποντας τον θεωρητικό διαχωρισμό της από το υπόβαθρο.

3.1.2.2 Θεωρία Χώρου Κλιμάκωσης και Πολυκλιμακωτή Ανίχνευση

Ένα από τα σημαντικότερα θεωρητικά προβλήματα στην ιατρική απεικόνιση είναι ότι οι όγκοι εμφανίζονται σε διαφορετικά μεγέθη και κλίμακες. Η εργασία βασίζεται στο scale-space theory, η οποία αποτελεί ένα τυποποιημένο πλαίσιο για τη διαχείριση των δομών μιας εικόνας σε πολλαπλά επίπεδα ανάλυσης.

Δηλαδή μια εικόνα αντιμετωπίζεται θεωρητικά ως ένα «στοιβαγμένο» σύνολο εικόνων (heap of images). Καθώς αυξάνεται η παράμετρος κλίμακας (t), οι λεπτομέρειες μικρής κλίμακας καταστέλλονται σταδιακά (μέσω διάχυσης/θολώματος), επιτρέποντας στις γειτονικές δομές να συγχωνευθούν και να αναδειχθούν οι κυρίαρχες μάζες.

Στο χώρο κλιμάκωσης εισάγεται η έννοια του scale-space tree. Κάθε δομή αξιολογείται με βάση το mass lifetime της, δηλαδή τον αριθμό των κλιμάκων στις οποίες καταφέρνει να επιβιώσει πριν εξαφανιστεί λόγω του θολώματος. Όσο μεγαλύτερο είναι το lifetime μιας μάζας, τόσο μεγαλύτερη είναι η στατιστική και φυσική της σημασία, υποδεικνύοντας ότι δεν πρόκειται για θόρυβο αλλά για πραγματικό αντικείμενο ενδιαφέροντος.

3.1.2.3 Ανασκόπηση και Σύγκριση Ανιχνευτών Ενδιαφέροντος

Η εργασία προβαίνει σε μια εκτενή θεωρητική αναδρομή των κλασικών ανιχνευτών σημείων και περιοχών ενδιαφέροντος, αναδεικνύοντας τα πλεονεκτήματα και τις αδυναμίες τους:

- **Laplacian of Gaussian (LoG):** Ένας από τους πιο διαδεδομένους ανιχνευτές που βασίζεται στη θεωρία χώρου κλιμάκωσης. Παρά την αποτελεσματικότητά του, η συμμετρική του φύση περιορίζει την απόδοσή του όταν καλείται να εντοπίσει ασύμμετρες (μη κυκλικές) μάζες.

- **Difference of Gaussians (DoG) & Generalized LoG (gLoG):** Προτάθηκαν ως μαθηματικές προσεγγίσεις και επεκτάσεις του LoG για τη βελτίωση της υπολογιστικής απόδοσης και την ανίχνευση γενικότερων ελλειπτικών ή περιστροφικά ασύμμετρων δομών.
- **Μειονεκτήματα Κλασικών Μεθόδων:** Οι περισσότεροι παραδοσιακοί ανιχνευτές (όπως SIFT, SURF, Harris-affine, Hessian-Laplace) λειτουργούν κυρίως σε gray-scale. Αυτό αποκλείει την πολύτιμη πληροφορία του χρώματος, η οποία είναι κρίσιμη για τον διαχωρισμό των φυσικών αιτιών της διαφοροποίησης (π.χ. σκιές, αντανakλάσεις, ιδιότητες ιστών). Επιπλέον, παράγουν μεγάλο αριθμό τοπικών ακρότατων, γεγονός που αυξάνει την πολυπλοκότητα και την πιθανότητα σφαλμάτων.

3.1.2.4 Η Θεωρία της Ανάλυσης Υφής μέσω GLCM

Για την υπέρβαση των περιορισμών των απλών ανιχνευτών ακμών (edge/corner detectors), η εργασία εισάγει το θεωρητικό υπόβαθρο του Πίνακα Συνυπάρξεων Επιπέδων Γκρι (GLCM).

Το GLCM είναι μια στατιστική μέθοδος εξέτασης της υφής που λαμβάνει υπόψη τη χωρική σχέση των εικονοστοιχείων. Υπολογίζει πόσο συχνά ζεύγη pixel με συγκεκριμένες τιμές έντασης (i, j) εμφανίζονται σε μια προκαθορισμένη χωρική γεωμετρική σχέση (π.χ. οριζόντια εφαπτόμενα pixel) μέσα στην εικόνα.

Ο πίνακας αυτός αποκαλύπτει ιδιότητες της χωρικής κατανομής των επιπέδων του γκρι. Για παράδειγμα, αν τα στοιχεία του πίνακα είναι συγκεντρωμένα κατά μήκος της διαγωνίου του, αυτό υποδηλώνει θεωρητικά ότι η υφή της συγκεκριμένης περιοχής είναι αδρή (coarse).

3.1.2.5 Τεχνητή Νοημοσύνη και Μηχανική Μάθηση στην Ιατρική AIM

Το τελευταίο σκέλος της θεωρητικής προσέγγισης αφορά τη μετάβαση από τα απλά μαθηματικά μοντέλα επεξεργασίας εικόνας στα συστήματα που μπορούν να μαθαίνουν από προηγούμενα δεδομένα και εμπειρίες.

Η μετάβαση από τα παραδοσιακά μαθηματικά μοντέλα επεξεργασίας εικόνας στα συστήματα που αναπτύσσουν αυτόνομη γνώση μέσω δεδομένων αποτελεί τον κεντρικό άξονα του machine learning στην ιατρική. Σε αντίθεση με τις κλασικές στατιστικές μεθόδους, οι οποίες απαιτούν ρητό προγραμματισμό για κάθε σενάριο, οι σύγχρονες προσεγγίσεις βασίζονται σε συμβολικά μοντέλα ασθενειών που συσχετίζουν τα ψηφιακά χαρακτηριστικά μιας εικόνας με τις πραγματικές κλινικές εκδηλώσεις.

Στο επίκεντρο βρίσκονται τα ANN, τα οποία είναι υπολογιστικά συστήματα εμπνευσμένα από το βιολογικό νευρικό σύστημα. Αν και ο ανθρώπινος εγκέφαλος λειτουργεί με δισεκατομμύρια νευρώνες, μια τυπική μαθηματική προσομοίωση περιορίζεται σε μια πολύ μικρότερη κλίμακα (από 10 έως 10.000 τεχνητούς νευρώνες), η οποία όμως επαρκεί για την αναγνώριση σύνθετων μοτίβων σε ιατρικές εικόνες.

Η ιστορική εξέλιξη ξεκινά από το Perceptron του Rosenblatt, ένα μοντέλο τριών επιπέδων (retina, association units, output). Το μοντέλο αυτό είχε περιορισμούς στην εκπαίδευση λόγω της αποκλειστικής χρήσης step functions. Το πρόβλημα λύθηκε με τα πολυεπίπεδα δίκτυα και τις differentiable transfer functions, οι οποίες επέτρεψαν την

εφαρμογή του backpropagation, του αλγορίθμου που υπολογίζει το σφάλμα στην έξοδο και το διαδίδει προς τα πίσω για να ρυθμίσει τα βάρη του δικτύου.

Η θεωρία δίνει έμφαση στη generalization, δηλαδή στην ικανότητα του δικτύου να αποδίδει σωστά σε νέα, άγνωστα δεδομένα. Για τον σκοπό αυτό, η διατήρηση ενός μικρού αριθμού από hidden neurons είναι κρίσιμη, καθώς αναγκάζει το σύστημα να μάθει τους γενικούς κανόνες των δεδομένων αντί να απομνημονεύσει τις λεπτομέρειές τους, αποτρέποντας έτσι το φαινόμενο του Overfitting.

Συνοψίζοντας, η θεωρητική προσέγγιση του paper χτίζει μια γέφυρα ανάμεσα στη γεωμετρική ανάλυση των pixel (μέσω σαγματικών σημείων και χώρου κλιμάκωσης) και στη στατιστική/νευρωνική επεξεργασία τους (μέσω GLCM και ANN) θέτοντας τους κανόνες με τους οποίους μια μηχανή μπορεί να αναγνωρίσει αυτόνομα την παθολογία σε μια ιατρική εικόνα.

3.1.3.1 Εισαγωγή και Κλινικό Υπόβαθρο

Σε αυτό το σημείο θα αναλύσουμε την ερευνητική εργασία “Predictive identification of oral cancer using AI and machine learning” όπου θα έχουμε το θεωρητικό υπόβαθρο για καρκίνο του στόματος.

Ο καρκίνος του στόματος αποτελεί ένα από τα πιο κρίσιμα και επιθετικά παγκόσμια προβλήματα υγείας, το οποίο χαρακτηρίζεται από υψηλά ποσοστά θνησιμότητας αν δεν εντοπιστεί σε αρχικό στάδιο. Η νόσος ξεκινά συνήθως με ανεπαίσθητες αλλοιώσεις στους μαλακούς ιστούς της στοματικής κοιλότητας οι οποίες εύκολα περνούν απαρατήρητες από τους ίδιους τους ασθενείς. Καθώς η νόσος εξελίσσεται σε πιο προχωρημένα στάδια, η θεραπευτική αντιμετώπιση γίνεται σημαντικά πιο περίπλοκη και οι πιθανότητες επιβίωσης μειώνονται δραματικά.

Οι παραδοσιακές διαγνωστικές μέθοδοι περιλαμβάνουν την κλινική οπτική εξέταση, τις βιοψίες και διάφορες τεχνικές ιατρικής απεικόνισης. Ωστόσο, η συμβατική αυτή προσέγγιση παρουσιάζει σοβαρούς περιορισμούς. Η οπτική εξέταση μπορεί να αποτύχει να εντοπίσει τις πρώιμες ενδείξεις της νόσου, ενώ η ερμηνεία των απεικονιστικών εξετάσεων βασίζεται σε μεγάλο βαθμό στην εμπειρία και την εξειδίκευση του εκάστοτε επαγγελματία υγείας, εισάγοντας διαγνωστική αστάθεια. Αν και η βιοψία προσφέρει την πιο οριστική διάγνωση αποτελεί μια επεμβατική και χρονοβόρα διαδικασία η οποία συχνά καθυστερεί την έναρξη της θεραπείας. Οι περιορισμοί αυτοί αναδεικνύουν την επιτακτική ανάγκη για την ανάπτυξη νέων μη επεμβατικών αντικειμενικών και πιο αποδοτικών εργαλείων που θα ενισχύσουν την έγκαιρη διάγνωση.

3.1.3.2 Ενσωμάτωση της Τεχνητής Νοημοσύνης στη Διαγνωστική

Οι πρόσφατες εξελίξεις στον τομέα AI και της ML προσφέρουν καινοτόμες λύσεις για την αναβάθμιση της ανίχνευσης του καρκίνου του στόματος. Η θεωρητική βάση της χρήσης αυτών των τεχνολογιών στηρίζεται στην ικανότητά τους να αναλύουν σύνθετα δεδομένα και ιατρικές εικόνες, εντοπίζοντας μοτίβα και δομικά χαρακτηριστικά των ιστών που είναι αδύνατο να αξιολογηθούν με γυμνό μάτι.

Στο επίκεντρο αυτής της προσέγγισης βρίσκονται τα CNNs, τα οποία θεωρούνται ιδιαίτερα υποσχόμενα καθώς έχουν τη θεωρητική ικανότητα να εξάγουν αυτόματα πολύπλοκα χαρακτηριστικά από ιατρικές εικόνες.

Μια θεμελιώδης θεωρητική παραδοχή στη ML είναι ότι η απόδοση και η αξιοπιστία οποιουδήποτε μοντέλου εξαρτώνται άμεσα από την ποιότητα των δεδομένων εισόδου. Η ύπαρξη θορύβου στα ιατρικά δεδομένα μπορεί να οδηγήσει σε εσφαλμένα συμπεράσματα ή σε μείωση της γενικευτικής ικανότητας των αλγορίθμων. Για τον λόγο αυτό, η θεωρία της προεπεξεργασίας δεδομένων (data cleaning) εστιάζει σε τρεις βασικούς άξονες:


1. **Missing Value Imputation:** Εστιάζει στην αποκατάσταση των κενών στοιχείων ενός συνόλου δεδομένων, ώστε να αποφευχθεί η απώλεια πληροφορίας αν και θεωρητικά θεωρείται η λιγότερο επιδραστική τεχνική σε σύγκριση με άλλους μεθόδους
2. **Outlier Detection:** Αφορά τον εντοπισμό και τη διαχείριση ανωμαλιών και στατιστικών λαθών στα δεδομένα ή απομάκρυνση των οποίων σταθεροποιεί τη συμπεριφορά των μοντέλων.
3. **Normalization:** Αποτελεί τη θεωρητικά πιο κρίσιμη διαδικασία, καθώς μετατρέπει τα χαρακτηριστικά του δείγματος σε μια ενιαία, κοινή κλίμακα. Η κανονικοποίηση αποτρέπει την επικράτηση συγκεκριμένων μεταβλητών έναντι άλλων λόγω διαφορετικής μονάδας μέτρησης εξαλείφει τις συστηματικές αποκλίσεις (bias) και επιτρέπει στα νευρωνικά δίκτυα να συγκλίνουν ταχύτερα και να εκπαιδεύονται πολύ πιο αποτελεσματικά.

Τέλος, θα μπορούσαμε να πούμε πως η θεωρητική προσέγγιση της εργασίας αναδεικνύει ότι ο συνδυασμός προηγμένων αλγορίθμων μηχανικής μάθησης με αυστηρές τεχνικές προεπεξεργασίας δεδομένων μπορεί να φέρει επανάσταση στη διαγνωστική πρακτική, προσφέροντας έγκαιρη, έγκυρη και ασφαλή ανίχνευση του καρκίνου του στόματος, βελτιώνοντας τελικά την πρόγνωση και την ποιότητα ζωής των ασθενών.

3.1 4.1 Καρκίνο του Μαστού και Διάφορες Εξελίξεις

Η θεωρητική προσέγγιση της 4^{ης} εργασίας το οποίο είναι το “Detection of breast cancer using machine learning and explainable artificial intelligence” εστιάζει στη σύνδεση της μηχανικής μάθησης και της ΧΑΙ με τη διάγνωση του καρκίνου του μαστού.

Το paper ξεκινά παρουσιάζοντας τον καρκίνο του μαστού ως μία από τις πιο συχνές και επικίνδυνες μορφές καρκίνου παγκοσμίως, η οποία προκαλείται από τον ανεξέλεγκτο πολλαπλασιασμό ανώμαλων κυττάρων στον μαστικό ιστό. Η ασθένεια μπορεί να εξαπλωθεί σε άλλα όργανα μέσω μετάστασης, γεγονός που αυξάνει σημαντικά τη θνησιμότητα. Η βιβλιογραφία αναδεικνύει ότι η έγκαιρη διάγνωση αποτελεί τον σημαντικότερο παράγοντα για την αύξηση των ποσοστών επιβίωσης των ασθενών, καθώς μειώνει την πιθανότητα εξάπλωσης της νόσου και επιτρέπει την ταχύτερη θεραπευτική παρέμβαση.



Εικόνα 7: Συχνά συμπτώματα, αίτια, θεραπείες και μέθοδοι για τον καρκίνο του μαστού.

Παρά τις εξελίξεις στις ιατρικές διαγνωστικές τεχνικές όπως η μαστογραφία, η μαγνητική τομογραφία και η βιοψία, η εργασία επισημαίνει ότι εξακολουθούν να υπάρχουν σοβαροί περιορισμοί. Οι παραδοσιακές μέθοδοι συχνά παρουσιάζουν περιορισμένη ακρίβεια, υψηλό κόστος, αργή επεξεργασία αποτελεσμάτων και αυξημένη πιθανότητα ανθρώπινου λάθους. Σύμφωνα με τα δεδομένα που αναφέρονται στο paper, ένα πολύ μεγάλο ποσοστό διαγνωστικών σφαλμάτων αποδίδεται στον ανθρώπινο παράγοντα. Για τον λόγο αυτό, η ενσωμάτωση τεχνικών μηχανικής μάθησης θεωρείται ιδιαίτερα σημαντική, καθώς τα υπολογιστικά μοντέλα μπορούν να επεξεργάζονται μεγάλους όγκους ιατρικών δεδομένων, να αναγνωρίζουν σύνθετα μοτίβα και να παρέχουν ταχύτερες και πιο αξιόπιστες προβλέψεις.

3.1.4.2 Θεωρητικό Υπόβαθρο για Ανάλυση του Καρκίνου Μαστού

Η θεωρητική βάση της μηχανικής μάθησης στην ιατρική στηρίζεται στην ικανότητα των αλγορίθμων να μαθαίνουν από δεδομένα και να δημιουργούν πρότυπα ταξινόμησης χωρίς να απαιτείται ρητός προγραμματισμός όλων των κανόνων. Στην περίπτωση του καρκίνου του μαστού, οι αλγόριθμοι χρησιμοποιούνται για τη διάκριση ανάμεσα σε καλοήθεις και κακοήθεις όγκους, αξιοποιώντας κλινικά χαρακτηριστικά των ασθενών. Το paper αναλύει ότι η αποτελεσματικότητα ενός μοντέλου εξαρτάται από την ποιότητα των δεδομένων, τη σωστή επιλογή χαρακτηριστικών και τη δυνατότητα γενίκευσης του μοντέλου σε νέα περιστατικά. Ιδιαίτερη έμφαση δίνεται στην έννοια της αξιοπιστίας των μοντέλων, επειδή σε ιατρικές εφαρμογές ακόμα και ένα μικρό ποσοστό λανθασμένων προβλέψεων μπορεί να οδηγήσει σε σοβαρές συνέπειες για τους ασθενείς.

Σημαντικό κομμάτι της θεωρητικής ανάλυσης αποτελεί και η ΧΑΙ. Η εργασία υποστηρίζει ότι τα περισσότερα μοντέλα μηχανικής μάθησης λειτουργούν ως black box όπου ο χρήστης γνωρίζει μόνο το τελικό αποτέλεσμα χωρίς να κατανοεί τη διαδικασία λήψης απόφασης. Στον ιατρικό τομέα αυτή η έλλειψη διαφάνειας δημιουργεί προβλήματα εμπιστοσύνης, καθώς οι γιατροί χρειάζονται σαφείς εξηγήσεις για να αποδεχθούν ή να αξιοποιήσουν μία πρόβλεψη. Η ΧΑΙ επιχειρεί να αντιμετωπίσει αυτό το πρόβλημα προσφέροντας ερμηνευσιμότητα και διαφάνεια στις αποφάσεις των αλγορίθμων. Μέσα από τεχνικές επεξήγησης, οι γιατροί μπορούν να γνωρίζουν ποια χαρακτηριστικά επηρέασαν περισσότερο τη διάγνωση και σε ποιο βαθμό.

Το paper αναφέρει ότι η ανάγκη για ΧΑΙ δεν περιορίζεται μόνο στη βελτίωση της εμπιστοσύνης, αλλά επεκτείνεται και στη δυνατότητα εντοπισμού σφαλμάτων και προκαταλήψεων των μοντέλων. Μέσω της ερμηνείας των αποτελεσμάτων, είναι δυνατόν να αναγνωριστούν προβληματικά χαρακτηριστικά προσαρμογής των μοντέλων ή λανθασμένες συσχετίσεις μέσα στα δεδομένα. Παράλληλα, η ΧΑΙ βοηθά στην κατανόηση της σχέσης μεταξύ των ιατρικών χαρακτηριστικών και της νόσου, ενισχύοντας όχι μόνο την τεχνολογική αλλά και την κλινική αξία των συστημάτων τεχνητής νοημοσύνης.

Η θεωρητική προσέγγιση της εργασίας εμβαθύνει επίσης στην έννοια της σημαντικότητας των χαρακτηριστικών. Αναλύεται ότι ορισμένοι παράγοντες, όπως η ηλικία, το μέγεθος του όγκου, οι λεμφαδένες και η μετάσταση, έχουν ισχυρή συσχέτιση με την πιθανότητα εμφάνισης κακοήθους καρκίνου. Η διερεύνηση αυτών των συσχετίσεων θεωρείται κρίσιμη, διότι επιτρέπει στα μοντέλα να εστιάζουν στα πιο ουσιαστικά δεδομένα και ταυτόχρονα παρέχει στους ιατρούς επιστημονική τεκμηρίωση για τις προβλέψεις του συστήματος. Η θεωρία της πληροφορίας και οι στατιστικές μέθοδοι που παρουσιάζονται στο paper χρησιμοποιούνται για να εξεταστεί πόσο σημαντικό είναι κάθε χαρακτηριστικό για την τελική διάγνωση.

Επιπλέον, η εργασία συνδέει τη θεωρία της ερμηνευσιμότητας με τη λήψη κλινικών αποφάσεων. Ένα μοντέλο που μπορεί να εξηγή τη λογική πίσω από τις προβλέψεις του θεωρείται περισσότερο αποδεκτό από τους επαγγελματίες υγείας και μπορεί να χρησιμοποιηθεί ως υποστηρικτικό εργαλείο στη διάγνωση. Η θεωρητική συζήτηση δείχνει ότι η ΧΑΙ δεν αντικαθιστά τον ιατρό, αλλά λειτουργεί συμπληρωματικά, προσφέροντας ενδείξεις και αναλυτική πληροφόρηση που βοηθούν στη μείωση των διαγνωστικών λαθών.

Ιδιαίτερη αναφορά γίνεται και στη σημασία της ισορροπίας ανάμεσα στην απόδοση και την ερμηνευσιμότητα των μοντέλων. Πολλά πολύπλοκα μοντέλα παρουσιάζουν υψηλή ακρίβεια αλλά χαμηλή διαφάνεια, ενώ πιο απλά μοντέλα είναι ευκολότερα κατανοητά αλλά συχνά λιγότερο αποδοτικά. Το paper υποστηρίζει ότι η σύγχρονη έρευνα επιδιώκει να γεφυρώσει αυτό το χάσμα, δημιουργώντας συστήματα που να είναι ταυτόχρονα αποδοτικά και επεξηγήσιμα. Αυτή η ισορροπία θεωρείται απαραίτητη ειδικά στον τομέα της υγείας, όπου η εμπιστοσύνη και η αξιοπιστία έχουν την ίδια σημασία με την ακρίβεια.

Τέλος, η θεωρητική θεμελίωση της εργασίας καταλήγει στο ότι η συνδυαστική χρήση μηχανικής μάθησης και επεξηγήσιμης τεχνητής νοημοσύνης μπορεί να αλλάξει σημαντικά τον τρόπο διάγνωσης του καρκίνου του μαστού. Η αξιοποίηση υπολογιστικών μοντέλων επιτρέπει την ταχύτερη επεξεργασία δεδομένων και τη μείωση των ανθρώπινων σφαλμάτων, ενώ η ΧΑΙ καθιστά αυτές τις προβλέψεις κατανοητές και αξιοποιήσιμες από τους επαγγελματίες υγείας. Έτσι, δημιουργείται ένα θεωρητικό πλαίσιο όπου η τεχνητή

νοημοσύνη δεν λειτουργεί απλώς ως εργαλείο αυτοματοποίησης, αλλά ως μέσο ενίσχυσης της ιατρικής γνώσης και της κλινικής απόφασης.

3.2 Πρακτική Περιγραφή Εργασιών

Σε αυτό το σημείο της εργασίας θα προσπαθήσουμε να εξηγήσουμε την ανάλυση σε πρακτικό επίπεδο, με την έννοια όπου θα καταλάβουμε τα εργαλεία που έχουν χρησιμοποιηθεί και την ένωση διαφορετικών και παλιότερων εργαλείων για κάτι που ουσιαστικά βοηθά στην ανθρωπότητά με σωστή διαχείριση εργαλείων και έχοντας σφάλμα στο σχεδόν μηδέν.

Όπως κάναμε και στο θεωρητική περιγραφή έχουμε πάλι την ίδια σειρά εργασιών όπου θα αναπτύξουμε αναλυτικά την ιδέα για σωστό αποτέλεσμα.

3.2.1.1 Αρχική Πρακτική Προσέγγιση

Στο πρώτο σημείο της πρακτική προσέγγισης θα αναλύσουμε την εργασία “Early cancer detection using deep learning and medical imaging: A survey”. Το πρακτικό μέρος της εργασίας επικεντρώνεται στην υλοποίηση μιας δομημένης υπολογιστικής ροής για την αυτόματη ανάλυση ιατρικών εικόνων. Η διαδικασία αυτή οργανώνεται σε συγκεκριμένα διαδοχικά στάδια, όπου το κάθε στάδιο προετοιμάζει τα δεδομένα για το επόμενο, με τελικό σκοπό την έγκαιρη και ακριβή διάγνωση του καρκίνου.

Στο πρώτο στάδιο, η πρακτική διαδικασία ξεκινά με τη συγκέντρωση και τη διαχείριση των δεδομένων. Χρησιμοποιούνται εκτενείς βάσεις δεδομένων που περιέχουν χιλιάδες ιατρικές εικόνες από διαφορετικές απεικονιστικές μεθόδους, όπως μαγνητικές τομογραφίες (MRI), αξονικές τομογραφίες (CT), μαστογραφίες, υπέρηχους και ψηφιοποιημένες ιστοπαθολογικές εικόνες.

Το βασικό πρόβλημα που αντιμετωπίζεται πρακτικά εδώ είναι η ανομοιογένεια και η έλλειψη επαρκών δεδομένων. Για να ξεπεραστεί αυτό, εφαρμόζονται τεχνικές επαύξησης δεδομένων όπου καλύτερα είναι το data augmentation. Τα εργαλεία αυτά παίρνουν τις υπάρχουσες εικόνες και δημιουργούν αυτόματα νέες παραλλαγές τους μέσω γεωμετρικών μετασχηματισμών, όπως τυχαίες περιστροφές, οριζόντιες ή κάθετες ανακλάσεις, αλλαγές στην κλίμακα και ελεγχόμενες μετατοπίσεις. Με τον τρόπο αυτό, το ψηφιακό δείγμα εκπαίδευσης πολλαπλασιάζεται, γεγονός που βοηθά τα υπολογιστικά μοντέλα να μάθουν να αναγνωρίζουν τον καρκίνο ανεξάρτητα από τη γωνία λήψης ή τον φωτισμό της εξέτασης.

Στη συνέχεια, η ροή εργασίας περνά στο στάδιο της προεπεξεργασίας και της βελτίωσης της ποιότητας της εικόνας. Οι πρωτογενείς ιατρικές εικόνες συχνά περιέχουν ψηφιακό θόρυβο, τεχνικά τεχνουργήματα από τα μηχανήματα ή χαμηλή αντίθεση, στοιχεία που δυσκολεύουν την αυτόματη ανάλυση. Στην πράξη, χρησιμοποιούνται εξειδικευμένα ψηφιακά φίλτρα, όπως το φίλτρο Gauss και τα οποία εξομαλύνουν την εικόνα και αφαιρούν τον θόρυβο χωρίς όμως να καταστρέφουν τις κρίσιμες λεπτομέρειες και τα όρια των ιστών. Παράλληλα, εφαρμόζονται τεχνικές histogram equalization οι οποίες ενισχύουν την αντίθεση μεταξύ των υγιών και των ύποπτων περιοχών, κάνοντας τις αλλοιώσεις και τους όγκους πολύ πιο ευδιάκριτους για τα επόμενα υπολογιστικά εργαλεία.

3.2.1.2 Απομόνωση και Ανάλυση της Περιοχής Ενδιαφέροντος

Το επόμενο κρίσιμο βήμα είναι η κατάτμηση της εικόνας (image segmentation), όπου ο στόχος είναι να εντοπιστεί και να απομονωθεί με ακρίβεια η περιοχή του όγκου από τον υπόλοιπο υγιή ιστό. Αντί ο ακτινολόγος να σχεδιάζει χειροκίνητα τα όρια ενός όγκου, χρησιμοποιούνται αυτοματοποιημένα εργαλεία που βασίζονται σε εξελιγμένα νευρωνικά δίκτυα κατάτμησης, με πιο διαδεδομένο το δίκτυο U-Net, καθώς και σε αλγορίθμους ομαδοποίησης (όπως ο K-means clustering). Αυτά τα εργαλεία αναλύουν την εικόνα σε επίπεδο pixel και διαχωρίζουν την ακριβή γεωμετρία της βλάβης. Η πρακτική σημασία αυτού του σταδίου είναι τεράστια καθώς επιτρέπει τον ακριβή υπολογισμό του μεγέθους και του σχήματος του όγκου, στοιχεία απαραίτητα για την παρακολούθηση της εξέλιξης της νόσου.


Αμέσως μετά την απομόνωση της περιοχής, ακολουθεί η διαδικασία εξαγωγής χαρακτηριστικών. Σε αυτό το σημείο, η εργασία εστιάζει στη μετατροπή των οπτικών πληροφοριών της εικόνας σε συγκεκριμένα αριθμητικά δεδομένα που περιγράφουν τα χαρακτηριστικά του ιστού. Χρησιμοποιούνται εργαλεία στατιστικής ανάλυσης υφής όπως ο πίνακας συνύπαρξης επιπέδων γκρι (GLCM), και εργαλεία συχνότητας, όπως ο διακριτός wavelet transform. Αυτά τα εργαλεία μετρούν και ποσοτικοποιούν παραμέτρους όπως η τραχύτητα, η ανομοιογένεια, η κατεύθυνση των μοτίβων και η πολυπλοκότητα των εικονοστοιχείων στην περιοχή του όγκου. Αυτές οι ψηφιακές υπογραφές είναι που επιτρέπουν στον υπολογιστή να καταλάβει αν η δομή ενός ιστού παρουσιάζει ανωμαλίες που σχετίζονται με κακοήθεια.

3.2.1.3 Ταξινόμηση, Εκπαίδευση και Αξιολόγηση Μοντέλων

Το κεντρικό κομμάτι του πρακτικού μέρους αφορά την εκπαίδευση των μοντέλων βαθιάς μάθησης για την τελική ταξινόμηση. Εδώ χρησιμοποιούνται τα CNNs, τα οποία είναι σχεδιασμένα να επεξεργάζονται εικόνες σε πολλαπλά επίπεδα αφαίρεσης αναγνωρίζοντας αυτόματα από απλές γραμμές και σκιές μέχρι πολύπλοκα παθολογικά μοτίβα. Λόγω του ότι η εκπαίδευση ενός τέτοιου δικτύου από το μηδέν απαιτεί τεράστιο χρόνο και δεδομένα, η πρακτική προσέγγιση βασίζεται στη transfer learning. Χρησιμοποιούνται έτοιμα, αρχιτεκτονικά προηγμένα δίκτυα, όπως τα ResNet, VGG, DenseNet και Inception, τα οποία έχουν ήδη εκπαιδευτεί σε εκατομμύρια γενικές εικόνες. Οι επιστήμονες παγώνουν τα πρώτα επίπεδα αυτών των δικτύων που αναγνωρίζουν βασικά σχήματα και επανεκπαιδεύουν μόνο τα τελευταία επίπεδα χρησιμοποιώντας τις ιατρικές εικόνες, ώστε το σύστημα να εξειδικευτεί στον εντοπισμό συγκεκριμένων μορφών καρκίνου.

Η ροή εργασίας ολοκληρώνεται με τη φάση της αξιολόγησης, η οποία ελέγχει την πρακτική αξιοπιστία του συστήματος πριν αυτό προταθεί για κλινική χρήση. Τα εργαλεία που χρησιμοποιούνται εδώ είναι στατιστικοί δείκτες απόδοσης που εφαρμόζονται πάνω σε ένα ξεχωριστό σύνολο εικόνων δοκιμής (test set), το οποίο το μοντέλο δεν έχει ξαναδεί. Υπολογίζεται η ακρίβεια για το συνολικό ποσοστό των σωστών προβλέψεων, η ευαισθησία (sensitivity/recall) για το πόσο καλά το σύστημα εντοπίζει τους πραγματικά ασθενείς χωρίς να χάνει περιπτώσεις, και η ειδικότητα για το πόσο σωστά αναγνωρίζει τους υγιείς αποφεύγοντας τους ψευδείς συναγερμούς. Η συνδυαστική ανάλυση αυτών των δεικτών δείχνει στην πράξη αν το μοντέλο είναι έτοιμο να υποστηρίξει έναν γιατρό στη λήψη κρίσιμων αποφάσεων.

Για καλύτερη κατανόηση της διαδικασίας έχουμε ένα παράδειγμα από ένα άλλο paper [23] όπου μας παρουσιάζει την χρήση transfer learning και απομόνωση θορύβου.



Εικόνα 8: Διάγραμμα ροής του pipeline ανάλυσης ιατρικής εικόνας για το segmentation πνευμονικής λοίμωξης COVID-19. Η ροή εργασίας ξεκινά με το dataset COVID-19 και καταλήγει στα υπολογισμένα αποτελέσματα αξιολόγησης για κάθε fold της cross-validation

Όπως μπορούμε να παρατηρήσουμε η **εικόνα 8** ξεκινά από τη συλλογή των ιατρικών εικόνων, προχωρά στην προεπεξεργασία τους για τον καθαρισμό του θορύβου και την data augmentation, συνεχίζει με το segmentation για την απομόνωση του όγκου και την εξαγωγή των ψηφιακών χαρακτηριστικών του, και καταλήγει στην τροφοδότηση αυτών των δεδομένων σε ένα μοντέλο μηχανικής μάθησης το οποίο εκτελεί την τελική ταξινόμηση/διάγνωση.

3.2.2.1 Προεπεξεργασία και Απομόνωση της Βλάβης

Η πρακτική υλοποίηση της εργασίας “ An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage” εστιάζει στη δημιουργία μιας ολοκληρωμένης, αυτοματοποιημένης ροής επεξεργασίας και ανάλυσης ιατρικών εικόνων με σκοπό την έγκαιρη ανίχνευση καρκινικών αλλοιώσεων, κυρίως δερματικών όγκων. Αντί να βασίζεται αποκλειστικά στην υποκειμενική οπτική εκτίμηση ενός γιατρού, η προσέγγιση αυτή μετατρέπει την εικόνα σε ψηφιακά δεδομένα, απομονώνει την περιοχή ενδιαφέροντος και χρησιμοποιεί εξειδικευμένο λογισμικό για να αποφανθεί αν μια αλλοίωση είναι κακοήθης ή καλοήθης. Η όλη διαδικασία έχει σχεδιαστεί για να λειτουργεί ως ένα υποστηρικτικό εργαλείο Computer-Aided Diagnosis, το οποίο μπορεί να μειώσει τα ποσοστά λάθους και την ανάγκη για επώδυνες βιοψίες.

Το πρώτο πρακτικό βήμα ξεκινά με την εισαγωγή των ακατέργαστων ιατρικών εικόνων, οι οποίες συχνά προέρχονται από MRI και αξονικές τομογραφίες όπως και στην προηγούμενη εργασία. Αυτές οι λήψεις περιέχουν θόρυβο στον φωτισμό ή

περιοχέςυγιούς δέρματος που δεν παρουσιάζουν ενδιαφέρον, το σύστημα εφαρμόζει τεχνικές προεπεξεργασίας για τον καθαρισμό τους.

Στη συνέχεια, το κρίσιμότερο στάδιο αυτής της φάσης είναι το image segmentation. Αυτό επιτυγχάνεται πρακτικά με τη χρήση του αλγορίθμου ομαδοποίησης K-means, ο οποίος χωρίζει την εικόνα σε ξεχωριστές περιοχές με βάση τη χρωματική ομοιογένεια και τη φωτεινότητα. Με αυτόν τον τρόπο, το σύστημα κόβει το υπόβαθρο και απομονώνει με ακρίβεια τα γεωμετρικά όρια του ύποπτου όγκου, προκειμένου η περαιτέρω ανάλυση να γίνει αποκλειστικά πάνω στη βλάβη

Ουσιαστικά η συγκεκριμένη εργασία είναι μία «υπο-εργασία» της προηγούμενης η οποία έκανε ένα survey με πάρα πολλά δεδομένα. Ενώ τώρα βλέπουμε μία συγκεκριμένη διαδικασία που έχει τις ίδιες λειτουργίες

3.2.2.2 Ψηφιακή Ανάλυση Υφής και Εξαγωγή Χαρακτηριστικών

Μόλις απομονωθεί ο όγκος, το σύστημα πρέπει να «διαβάσει» τα μορφολογικά στοιχεία που το ανθρώπινο μάτι μπορεί να προσπεράσει. Αυτό γίνεται μέσω της feature extraction. Το βασικό εργαλείο που χρησιμοποιείται εδώ είναι το Gray-Level Co-Occurrence Matrix - GLCM. Στην πράξη, το GLCM σκανάρει την εικόνα της βλάβης και εξετάζει τη χωρική σχέση μεταξύ των pixels. Μετρά, δηλαδή, πόσο συχνά εμφανίζονται γειτονικά pixels με τις ίδιες ή παρόμοιες αποχρώσεις του γκρι σε συγκεκριμένες κατευθύνσεις και αποστάσεις. Από αυτή τη διαδικασία παράγονται συγκεκριμένοι στατιστικοί δείκτες που περιγράφουν την τραχύτητα, την ομοιογένεια, την αντίθεση και την ενέργεια της επιφάνειας του όγκου. Αυτοί οι δείκτες μετατρέπουν την οπτική πληροφορία της εικόνας σε έναν πίνακα αριθμητικών τιμών, ο οποίος αποτελεί την ψηφιακή ταυτότητα που θα μπορούσαμε να πούμε της συγκεκριμένης αλλοίωσης.

3.2.2.3 Εκπαίδευση και Ταξινόμηση με το Λογισμικό WEKA

Οι αριθμητικοί πίνακες με τα χαρακτηριστικά όλων των εικόνων συγκεντρώνονται σε ένα ενιαίο σύνολο δεδομένων, το οποίο εισάγεται στο εξειδικευμένο λογισμικό εξόρυξης δεδομένων WEKA (Waikato Environment for Knowledge Analysis). Το WEKA αποτελεί το κεντρικό περιβάλλον δοκιμών της εργασίας καθώς παρέχει έτοιμες υλοποιήσεις πολλών αλγορίθμων μηχανικής μάθησης.

Στο στάδιο αυτό, το σύνολο δεδομένων χρησιμοποιείται για την εκπαίδευση των μοντέλων και το υπόλοιπο για τον έλεγχο και την αξιολόγηση της ακρίβειάς τους σε άγνωστες εικόνες. Μέσα στο λογισμικό WEKA, η εργασία θέτει σε λειτουργία και συγκρίνει διαφορετικούς ταξινομητές όπως τον αλγόριθμο k-NN που βασίζεται στη γεωμετρική ομοιότητα, τον πιθανολογικό Naive Bayes καθώς και τη μέθοδο Random Forest η οποία συνδυάζει πολλαπλά δέντρα απόφασης για την εξαγωγή ενός πιο σταθερού και έγκυρου αποτελέσματος.

Το εργαλείο WEKA από προηγούμενα εργαστήρια του τμήματος, όπου χρησιμοποιήθηκε για την πρόβλεψη καθημερινών σεναρίων όπως οι καιρικές συνθήκες ή η κατηγοριοποίηση αντικειμένων αποδεικνύει την ευελιξία του. Αποτελεί ένα εξαιρετικό εργαλείο για την εισαγωγή στον κόσμο της τεχνητής νοημοσύνης και της στατιστικής ανάλυσης, καθώς επιτρέπει την άμεση πειραματική εφαρμογή σύνθετων αλγορίθμων χωρίς την ανάγκη συγγραφής κώδικα. Η πρακτική αυτή εμπειρία διευκολύνει σημαντικά τη μετάβαση από απλά προβλήματα καθημερινότητας στην επίλυση απαιτητικών και

κρίσιμων ζητημάτων όπως είναι η επεξεργασία και η ανάλυση σύνθετων ιατρικών δεδομένων.

3.2.2.4 Χρήση Νευρωνικών Δικτύων και Τελική Διάγνωση

Πέρα από τους κλασικούς αλγορίθμους του WEKA, το πρακτικό μέρος επεκτείνεται στη χρήση των ANNs. Η διαδικασία αυτή προσομοιώνει τη λειτουργία του ανθρώπινου εγκεφάλου για την αναγνώριση σύνθετων προτύπων. Το δίκτυο τροφοδοτείται με τα χαρακτηριστικά υφής που εξήγαγε το GLCM και μέσω του αλγορίθμου backpropagation αυτοδιορθώνεται συνεχώς κατά τη διάρκεια της εκπαίδευσης.

Όταν η εκπαίδευση ολοκληρωθεί, το σύστημα είναι πλέον έτοιμο για πρακτική χρήση όπου ο χρήστης εισάγει μια νέα άγνωστη εικόνα, η ροή εργασίας την επεξεργάζεται αυτόματα, εξάγει τα χαρακτηριστικά της και το εκπαιδευμένο μοντέλο (είτε πρόκειται για το νευρωνικό δίκτυο είτε για κάποιον αλγόριθμο του WEKA) εκδίδει μια τελική απάντηση η οποία ουσιαστικά είναι διάγνωση, κατηγοριοποιώντας την τροποποίηση ως benign ή malignant. Μέσα από τη σύγκριση των αποτελεσμάτων όλων αυτών των εργαλείων η εργασία προσδιορίζει ποιο μοντέλο επιτυγχάνει τα υψηλότερα ποσοστά επιτυχίας προσφέροντας μια έτοιμη προς χρήση υπολογιστική λύση για ταχεία ιατρική αξιολόγηση.

3.2.2.4 Αποτελέσματα Εργαλείων Εκπαίδευσης

Ο πίνακας SNR δείχνει τη σύγκριση της ποιότητας εικόνας μεταξύ της υπάρχουσας και της προτεινόμενης μεθόδου ανίχνευσης καρκίνου. Το SNR (Signal-to-Noise Ratio) μετρά πόσο καθαρή είναι η εικόνα σε σχέση με τον θόρυβο. Όσο μεγαλύτερη είναι η τιμή SNR, τόσο καλύτερη είναι η ποιότητα της εικόνας.

Image	Existing SNR value	Proposed SNR value
Image 1	40	68.3707
Image 2	40	68.2665
Image 3	40.439	68.2316
Image 4	38.26	68.3098
Image 5	41.93	68.2435
Image 6	39.114	68.3603
Image 7	68.2783	79.86
Image 8	68.2925	85

Εικόνα 9: Αποτελέσματα SNR

Στον πίνακα φαίνεται ότι η προτεινόμενη μέθοδος έχει μεγαλύτερες τιμές SNR από την παλιά μέθοδο, άρα απομακρύνει καλύτερα τον θόρυβο και εντοπίζει πιο σωστά τις καρκινικές περιοχές. Για παράδειγμα, στην Image 1 το SNR αυξάνεται από 40 σε 68.3707.

Η διαδικασία γίνεται ως εξής:

Πρώτα η εικόνα μετατρέπεται σε grayscale, μετά εφαρμόζεται φιλτράρισμα για αφαίρεση θορύβου και στη συνέχεια χρησιμοποιείται ο αλγόριθμος GLCM για εξαγωγή χαρακτηριστικών της εικόνας. Τέλος, με SVM και clustering γίνεται η αναγνώριση της καρκινικής περιοχής.

3.2.3.1 Πρακτική Αξιολόγηση με Βάση της Θεωρίας

Συνεχίζουμε με την εργασία “ Predictive identification of oral cancer using AI and machine learning” όπου η βασική λειτουργία της μεθοδολογίας στηρίζεται σε μια δομημένη ροή επεξεργασίας που ξεκινά από τις ιατρικές εικόνες.

Αρχικά, πραγματοποιείται η εξαγωγή χαρακτηριστικών, όπου το σύστημα αναλύει τις εικόνες για να εντοπίσει μοτίβα υφής, γεωμετρικά σχήματα των αλλοιώσεων, χρωματικές αποκλίσεις, καθώς και τα όρια των πληγών μέσω ειδικών εργαλείων ανίχνευσης ακμών όπως ο αλγόριθμος Canny. Το πιο κρίσιμο πρακτικό κομμάτι της εργασίας είναι η εφαρμογή και η σύγκριση τριών διαφορετικών τεχνικών καθαρισμού αυτών των δεδομένων:

- της συμπλήρωσης ελλειπών τιμών
- της αφαίρεσης ακραίων/αντικανονικών τιμών
- της κανονικοποίησης των δεδομένων.

Η εργασία ουσιαστικά βασίζεται να δει στην πράξη ποια από αυτές τις προετοιμασίες βοηθά το σύστημα να αποδώσει καλύτερα. Αφού ολοκληρωθεί ο καθαρισμός, το σύνολο των δεδομένων χωρίζεται πρακτικά σε δύο μέρη που το 70% χρησιμοποιείται για την εκπαίδευση των μοντέλων και το υπόλοιπο 30% κρατείται για τη δοκιμή τους σε άγνωστα, νέα δεδομένα ώστε να ελεγχθεί η αξιοπιστία τους.

3.2.3.2 Εκπαίδευση Μοντέλων και Αποτελέσματα

Για την πρόβλεψη και τη διάγνωση, η εργασία επιστρατεύει τρία γνωστά υπολογιστικά εργαλεία μηχανικής μάθησης: τα CNNs, τις Μηχανές Διανυσμάτων Υποστήριξης (SVM) και τα Random Forests. Αυτά τα μοντέλα τροφοδοτούνται με τα δεδομένα των εικόνων και μαθαίνουν να ξεχωρίζουν τις υγιείς από τις επικίνδυνες αλλοιώσεις. Στην πράξη, αποδείχθηκε ότι η τεχνική της κανονικοποίησης (και συγκεκριμένα η κλιμάκωση min-max που φέρνει όλες τις τιμές στο ομοιόμορφο εύρος 0 έως 1) ήταν το πιο αποτελεσματικό εργαλείο προετοιμασίας.

Όταν τα μοντέλα και κυρίως το νευρωνικό δίκτυο CNN, εκπαιδεύτηκαν με κανονικοποιημένα δεδομένα, κατάφεραν να φτάσουν στο κορυφαίο ποσοστό ακρίβειας 94% και στο χαμηλότερο δυνατό σφάλμα, ξεπερνώντας τις επιδόσεις που είχαν όταν εφαρμόστηκε απλή αφαίρεση ακραίων τιμών (93% ακρίβεια) ή συμπλήρωση κενών (92% ακρίβεια). Μπορούμε να το παρατηρήσουμε και από την εικόνα 1 που αναφερθήκαμε στην ενότητα Στόχος.

3.2.4.1 Χρήση Explainable Artificial Intelligence

Στην τελευταία εργασία που είναι η “ Detection of breast cancer using machine learning and explainable artificial intelligence ” δημιουργεί ένα σύστημα τεχνητής νοημοσύνης που να μπορεί να βοηθήσει στην ανίχνευση καρκίνου του μαστού, χρησιμοποιώντας πραγματικά ιατρικά δεδομένα ασθενών.

Η εργασία δεν επικεντρώνεται μόνο στο να βγάλει ένα αποτέλεσμα, αλλά κυρίως στο να εξετάσει ποιο μοντέλο λειτουργεί καλύτερα, πόσο αξιόπιστες είναι οι προβλέψεις του και αν μπορούμε να καταλάβουμε γιατί το μοντέλο πήρε μια συγκεκριμένη απόφαση. Για αυτόν τον λόγο χρησιμοποιούνται τόσο εργαλεία μηχανικής μάθησης όσο και τεχνικές XAI, δηλαδή τεχνικές που κάνουν τις αποφάσεις της τεχνητής νοημοσύνης πιο κατανοητές.

3.2.4.2 Πειραματική Διαδικασία και Παράγοντες

Αρχικά χρησιμοποιείται ένα dataset που περιέχει δεδομένα από 213 ασθενείς. Τα χαρακτηριστικά αυτά αφορούν πληροφορίες όπως ηλικία, μέγεθος όγκου, μετάσταση, λεμφαδένες, ιστορικό καρκίνου και άλλα ιατρικά στοιχεία. Το πρώτο πρακτικό βήμα είναι η προεπεξεργασία των δεδομένων. Σε αυτή τη φάση τα δεδομένα καθαρίζονται ώστε να μπορούν να χρησιμοποιηθούν σωστά από τους αλγόριθμους. Αφαιρούνται ελλιπείς τιμές, μετατρέπονται οι κατηγορίες σε αριθμητική μορφή και γίνεται κανονικοποίηση των δεδομένων ώστε όλα τα χαρακτηριστικά να βρίσκονται σε παρόμοια κλίμακα. Αυτό είναι σημαντικό γιατί διαφορετικά ορισμένα χαρακτηριστικά θα επηρέαζαν δυσανάλογα το αποτέλεσμα.

Στη συνέχεια γίνεται ανάλυση των χαρακτηριστικών για να φανεί ποια στοιχεία των ασθενών επηρεάζουν περισσότερο τη διάγνωση. Η εργασία προσπαθεί ουσιαστικά να καταλάβει ποια δεδομένα έχουν τη μεγαλύτερη πληροφορία για το αν ένας όγκος είναι καλοήθης ή κακοήθης. Μέσα από αυτή τη διαδικασία παρατηρείται ότι το μέγεθος του όγκου, η ηλικία και οι προσβεβλημένοι λεμφαδένες είναι από τα πιο σημαντικά χαρακτηριστικά. Η ανάλυση αυτή βοηθά τόσο στην καλύτερη εκπαίδευση των μοντέλων όσο και στην κατανόηση του προβλήματος από ιατρική πλευρά.

Anchors	Prediction	Precision	Coverage
Age <= 0.40 AND Tumor Size (cm) <= 0.29	Benign	0.97	0.23
Tumor Size (cm) <= 0.14 AND Inv-Nodes <= 0.00	Benign	0.9	0.27
Age <= 0.40 AND Tumor Size (cm) <= 0.14	Benign	1	0.12
Tumor Size (cm) <= 0.14 AND Inv-Nodes <= 0.00	Benign	0.89	0.28
Tumor Size (cm) <= 0.29 AND Inv-Nodes <= 0.00	Benign	0.87	0.55
Inv-Nodes > 0.00 AND Tumor Size (cm) > 0.29	Malignant	0.98	0.32
Inv-Nodes > 0.00 AND Age > 0.64	Malignant	0.99	0.15
Tumor Size (cm) > 0.29 AND Inv-Nodes > 0.00	Malignant	0.99	0.31
Age <= 0.53 AND Tumor Size (cm) <= 0.14	Malignant	0.99	0.21
Inv-Nodes > 0.00 AND Age > 0.53	Malignant	1	0.26

Εικόνα 10: Κανόνες που δημιούργησε η τεχνική Anchor Explainability για την ερμηνεία των προβλέψεων του μοντέλου. Οι κανόνες δείχνουν ότι χαρακτηριστικά όπως η ηλικία, το μέγεθος όγκου και οι προσβεβλημένοι λεμφαδένες επηρεάζουν σημαντικά την πρόβλεψη καλοήθους ή κακοήθους όγκου.

Έπειτα εφαρμόζονται διαφορετικοί αλγόριθμοι μηχανικής μάθησης. Η εργασία δεν βασίζεται σε ένα μόνο μοντέλο αλλά συγκρίνει πολλές διαφορετικές τεχνικές όπως Random Forest, Logistic Regression, XGBoost, LightGBM, CatBoost, KNN και άλλες. Ο λόγος είναι ότι κάθε μοντέλο βλέπει τα δεδομένα διαφορετικά και μπορεί να έχει διαφορετική συμπεριφορά στις προβλέψεις. Τα μοντέλα εκπαιδεύονται πάνω στα δεδομένα των ασθενών ώστε να μάθουν να ξεχωρίζουν τις καλοήθειες από τις κακοήθειες περιπτώσεις. Μετά την εκπαίδευση γίνεται αξιολόγηση της απόδοσής τους για να φανεί ποιο μοντέλο κάνει τις πιο σωστές προβλέψεις και ποιο κάνει λιγότερα λάθη.

Ένα πολύ σημαντικό κομμάτι του πρακτικού μέρους είναι η δημιουργία ενός ensemble μοντέλου stacking. Αντί να χρησιμοποιείται μόνο ένας αλγόριθμος, η εργασία συνδυάζει πολλά μοντέλα μαζί ώστε να αξιοποιήσει τα πλεονεκτήματα του καθενός. Το stacking λειτουργεί σαν ένα τελικό σύστημα απόφασης που λαμβάνει τα αποτελέσματα από όλα τα επιμέρους μοντέλα και παράγει μια πιο σταθερή και αξιόπιστη πρόβλεψη. Ο στόχος εδώ είναι να μειωθούν τα λάθη και να βελτιωθεί η γενίκευση του συστήματος σε νέα δεδομένα ασθενών.

Το πιο ιδιαίτερο στοιχείο της εργασίας είναι η χρήση Explainable AI. Συνήθως τα μοντέλα τεχνητής νοημοσύνης λειτουργούν σαν μαύρα κουτιά, δηλαδή δίνουν αποτέλεσμα χωρίς να εξηγούν τον λόγο. Εδώ όμως χρησιμοποιούνται εργαλεία όπως SHAP, LIME, Eli5, Anchor και QLattice για να εξηγηθεί πώς παίρνονται οι αποφάσεις. Για παράδειγμα τα εργαλεία αυτά δείχνουν ποια χαρακτηριστικά επηρέασαν περισσότερο την πρόβλεψη ενός ασθενούς. Έτσι ο γιατρός μπορεί να δει αν το μοντέλο βασίστηκε κυρίως στο μέγεθος του όγκου, στην ηλικία ή στους λεμφαδένες. Αυτό είναι ιδιαίτερα σημαντικό στον ιατρικό χώρο γιατί οι γιατροί πρέπει να εμπιστεύονται και να κατανοούν τα αποτελέσματα της τεχνητής νοημοσύνης πριν τα χρησιμοποιήσουν σε πραγματικές αποφάσεις.

Η εργασία προσπαθεί επίσης να δείξει ότι οι εξηγήσεις των μοντέλων δεν είναι τυχαίες. Για αυτό συγκρίνονται τα αποτελέσματα των XAI εργαλείων με τα στατιστικά ευρήματα και την ανάλυση χαρακτηριστικών. Όταν διαφορετικές μέθοδοι καταλήγουν στα ίδια σημαντικά χαρακτηριστικά, αυξάνεται η αξιοπιστία του συστήματος. Με αυτόν τον τρόπο η έρευνα δεν περιορίζεται μόνο στην ακρίβεια πρόβλεψης αλλά δίνει έμφαση και στη διαφάνεια κάτι που θεωρείται απαραίτητο στις ιατρικές εφαρμογές.

Συνολικά, το πρακτικό μέρος της εργασίας δείχνει μια πλήρη διαδικασία ανάπτυξης ενός συστήματος τεχνητής νοημοσύνης για ιατρική διάγνωση. Ξεκινά από την επεξεργασία πραγματικών δεδομένων, συνεχίζει με την εκπαίδευση και αξιολόγηση πολλών μοντέλων μηχανικής μάθησης, συνδυάζει τα καλύτερα μοντέλα μέσω ensemble learning και τέλος χρησιμοποιεί Explainable AI ώστε οι προβλέψεις να είναι κατανοητές και αξιοποιήσιμες από τους γιατρούς.

3.2.4.3 Αποτελέσματα και Αξιολογήσεις Κάθε Διαφορετικής Μέθοδο

Παρατηρούμε ότι συγκρίνονται όλοι οι αλγόριθμοι μηχανικής μάθησης που χρησιμοποιήθηκαν στην εργασία. Περιλαμβάνει μοντέλα όπως Random Forest, Logistic Regression, Decision Tree, XGBoost και το STACK ensemble model. Για κάθε μοντέλο παρουσιάζονται μετρικές απόδοσης όπως accuracy, precision, recall και F1-score. Ουσιαστικά καταλαβαίνουμε πόσο καλά μπορεί κάθε μοντέλο να ξεχωρίζει τις καλοήθειες (benign) από τις κακοήθειες (malignant) περιπτώσεις καρκίνου.


Το σημαντικότερο αποτέλεσμα του πίνακα είναι ότι το μοντέλο Random Forest είχε την καλύτερη συνολική απόδοση, με accuracy 89% και F1-score 84%. Αυτό σημαίνει ότι το μοντέλο κατάφερε να κάνει αρκετά σωστές προβλέψεις χωρίς να παράγει υπερβολικά πολλά λάθη. Το Logistic Regression είχε επίσης πολύ καλή απόδοση, ενώ το STACK ensemble model πέτυχε F1-score 83% κάτι που δείχνει ότι ο συνδυασμός πολλών μοντέλων μπορεί να δώσει σταθερά και αξιόπιστα αποτελέσματα. Η εργασία δίνει ιδιαίτερη σημασία στο F1-score, επειδή στην ιατρική διάγνωση είναι πολύ σημαντικό να υπάρχει ισορροπία ανάμεσα στα false positives και στα false negatives.

Algorithm	Accuracy (%)	Precision (%)	Recall (%)	F1-score (%)	Area under curve	Average precision	Hamming loss	Jaccard score	Log loss	Mathew's correlation coefficient
Random Forest	89	84	93	84	0.96	0.93	0.11	0.79	3.94	0.78
Logistic Regression	89	87	90	83	0.94	0.94	0.11	0.79	3.94	0.78
Decision Tree	80	71	93	79	0.92	0.9	0.2	0.68	7.32	0.63
KNN	78	76	76	83	0.78	0.8	0.22	0.61	7.88	0.56
Adaboost	86	81	90	81	0.93	0.9	0.14	0.74	5.06	0.72
Catboost	89	84	93	80	0.95	0.91	0.1	0.79	3.94	0.78
Lightgbm	83	76	90	80	0.93	0.91	0.17	0.7	6.2	0.67
Xgboost	86	79	93	81	0.94	0.92	0.14	0.75	5.07	0.73
STACK	84	81	86	83	0.93	0.92	0.16	0.71	5.63	0.69

Εικόνα 11: Ανάλυση απόδοσης των αλγορίθμων μηχανικής μάθησης χρησιμοποιώντας διαφορετικές μετρικές αξιολόγησης

Επιπλέον, πολύ σημαντικό είναι και η εικόνα χ, το οποίο παρουσιάζει αναλυτικά την απόδοση του STACK ensemble model. Το σχήμα αυτό περιλαμβάνει τρία βασικά γραφήματα: την καμπύλη AUC, την precision-recall curve και τον confusion matrix.

Ο confusion matrix είναι ίσως το πιο εύκολο και χρήσιμο γράφημα για να καταλάβουμε τα τελικά αποτελέσματα. Εκεί φαίνεται πόσες περιπτώσεις ταξινομήθηκαν σωστά και πόσες λανθασμένα. Με απλά λόγια, δείχνει πόσοι ασθενείς με καρκίνο εντοπίστηκαν σωστά και πόσοι ταξινομήθηκαν λάθος. Η εργασία αναφέρει ότι το STACK model είχε πολύ λίγα λανθασμένα αποτελέσματα, κάτι που δείχνει ότι το μοντέλο μπορεί να χρησιμοποιηθεί αξιόπιστα ως εργαλείο υποστήριξης για τους γιατρούς.




Εικόνα 12: Απόδοση του stacking classifier (a) AUC καμπύλη (b) precision-recall curve (c) Confusion matrix.

Η καμπύλη AUC δείχνει πόσο καλά μπορεί το μοντέλο να ξεχωρίζει τις δύο κατηγορίες ασθενών. Όσο πιο κοντά βρίσκεται η καμπύλη στην ιδανική περιοχή, τόσο καλύτερο θεωρείται το μοντέλο. Στην εργασία το Random Forest και το STACK model είχαν πολύ υψηλές τιμές AUC, κάτι που σημαίνει ότι έχουν ισχυρή ικανότητα διάκρισης μεταξύ καλοήθων και κακοήθων όγκων.

4 Μετέπειτα Εργασίας


Η εργασία “Early cancer detection using deep learning and medical imaging: A survey” επικεντρώνεται κυρίως σε τεχνικές βαθιάς μάθησης για ανίχνευση καρκίνου μέσω ιατρικών εικόνων, παρουσιάζοντας CNNs, transfer learning, U-Net segmentation και image preprocessing τεχνικές όπως Gaussian filtering, augmentation και feature extraction μέσω GLCM/HOG/wavelets. Μία σημαντική μετέπειτα κατεύθυνση που θα μπορούσε να επεκτείνει αυτήν την εργασία είναι το paper [24] που σχετίζεται με TransUNet. Το συγκεκριμένο paper προτείνει έναν υβριδικό συνδυασμό CNN και Transformer architectures για segmentation. Ενώ το κλασικό U-Net καταγράφει κυρίως τοπικά χαρακτηριστικά εικόνας, το TransUNet εισάγει self-attention μηχανισμούς που επιτρέπουν στο μοντέλο να συσχετίζει απομακρυσμένες περιοχές της εικόνας. Αυτό είναι ιδιαίτερα σημαντικό σε MRI ή histopathology images όπου τα καρκινικά patterns είναι διάσπαρτα και όχι μόνο τοπικά. Άρα το TransUNet μπορεί να θεωρηθεί φυσική εξέλιξη των segmentation τεχνικών που αναφέρονται στο survey.



Εικόνα 13: TransUNet Framework

Μία δεύτερη πολύ σημαντική προτεινόμενη εργασία είναι το Swin-Unet [25], το οποίο βασίζεται εξ ολοκλήρου σε hierarchical transformers. Σε αντίθεση με τα CNNs που χρησιμοποιούν σταθερά convolution kernels, το Swin-Unet χρησιμοποιεί shifted window attention mechanisms ώστε να μαθαίνει multi-scale πληροφορία με πιο αποδοτικό τρόπο. Αυτό το καθιστά ιδιαίτερα χρήσιμο σε cancer detection tasks όπου διαφορετικά μεγέθη όγκων πρέπει να εντοπίζονται ταυτόχρονα. Η εργασία μπορεί να συνδεθεί άμεσα με το survey, επειδή το survey δείχνει ότι το U-Net είναι μία από τις πιο βασικές segmentation μεθόδους, άρα το Swin-Unet αποτελεί πιο σύγχρονη transformer-based εξέλιξη του.

Για την εργασία “An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage” μία πολύ χρήσιμη μετέπειτα μέθοδος θα μπορούσε να είναι το Vision Transformer (ViT) [26]. Η αρχική εργασία βασίζεται κυρίως σε multiscale blob detection, feature extraction και κλασικά machine learning μοντέλα όπως SVM και KNN. Αντίθετα, το Vision Transformer χρησιμοποιεί self-attention μηχανισμούς ώστε να μαθαίνει global σχέσεις μέσα στην ιατρική εικόνα χωρίς handcrafted features. Αυτό βοηθά ιδιαίτερα στην ανίχνευση μικρών ή διάσπαρτων καρκινικών περιοχών σε MRI και histopathology images. Βέβαια αυτή η μέθοδος θα μπορούσε να χρησιμοποιηθεί και για τις άλλες εργασίες αφού έχουμε image processing σε κάθε περίπτωση.




Εικόνα 14: ViT Αρχιτεκτονική

Όπως μπορούμε να παρατηρήσουμε από την **εικόνα 14** το Vision Transformer χωρίζει μια εικόνα σε μικρά τετράγωνα κομμάτια (patches), τα οποία λειτουργούν σαν λέξεις. Κάθε κομμάτι μετατρέπεται σε διάνυσμα και αποκτά μια αριθμητική ταυτότητα θέσης η οποία είναι το position embedding. Στην αρχή της σειράς προστίθεται ένα επιπλέον, ειδικό διάνυσμα (το [class] token), με σκοπό να μαζέψει τη συνολική πληροφορία της εικόνας.

Αυτά τα διανύσματα μπαίνουν στον transformer encoder. Εκεί, μέσω του μηχανισμού multi-head attention, κάθε κομμάτι συσχετίζεται με όλα τα υπόλοιπα για να κατανοήσει το μοντέλο το ευρύτερο περιβάλλον. Η διαδικασία σταθεροποιείται με επίπεδα κανονικοποίησης (Norm) και βελτιώνεται με ενδιάμεσα νευρωνικά δίκτυα (MLP).

Στο τέλος, το μοντέλο απομονώνει μόνο το [class] token, το οποίο πλέον έχει συγκεντρώσει όλη τη γνώση για το περιεχόμενο. Αυτό τροφοδοτείται στο MLP Head που αναγνωρίζει και αποφασίζει τι δείχνει η εικόνα.


Η εργασία “Predictive identification of oral cancer using AI and machine learning” που χρησιμοποιεί όπως αναφερθήκαμε κυρίως CNNs, SVMs και Random Forests μαζί με preprocessing techniques όπως normalization, missing value imputation και outlier detection. Ένα paper που θα μπορούσε να επεκτείνει αυτή τη λογική είναι το XGBoost [27]. Το XGBoost αποτελεί boosting ensemble algorithm που χτίζει διαδοχικά decision trees ώστε κάθε νέο tree να διορθώνει τα λάθη του προηγούμενου. Σε clinical/tabular cancer datasets αποδίδει συχνά καλύτερα από Random Forest και SVM επειδή χειρίζεται καλύτερα feature interactions και class imbalance. Επιπλέον παρέχει feature importance scores που μπορούν να χρησιμοποιηθούν για explainability. Επομένως, θα μπορούσε να αντικαταστήσει ή να συγκριθεί με τα Random Forest models της oral cancer εργασίας.



Εικόνα 15: Εφαρμογή του XGBoost

Στην ίδια κατεύθυνση, το LightGBM [28] θα μπορούσε να χρησιμοποιηθεί ως πιο αποδοτική boosting μέθοδος. Το LightGBM χρησιμοποιεί histogram-based learning και leaf-wise tree growth, κάτι που επιταχύνει σημαντικά την εκπαίδευση και μειώνει τη χρήση μνήμης. Σε datasets με πολλά χαρακτηριστικά ή μεγάλους όγκους δεδομένων αποδίδει εξαιρετικά. Για oral cancer prediction models θα μπορούσε να προσφέρει υψηλότερη ακρίβεια και καλύτερο handling categorical/continuous medical variables.

Ακόμη πιο εξειδικευμένο για medical tabular data είναι το CatBoost [29]. Το CatBoost σχεδιάστηκε ειδικά για datasets με categorical features και μειώνει το prediction shift μέσω ordered boosting. Στην breast cancer εργασία χρησιμοποιούνται πολλές categorical μεταβλητές όπως menopause, metastasis και breast quadrant. Το CatBoost θα μπορούσε να βελτιώσει την απόδοση χωρίς πολύπλοκο preprocessing ή encoding, ενώ παράλληλα διατηρεί υψηλή interpretability.




Εικόνα 16: catBoost Algorithm Flow

Όπου το CatBoost είναι ένας αλγόριθμος machine learning βασισμένος στο gradient boosting πάνω σε decision trees, σχεδιασμένος ιδιαίτερα για δεδομένα με κατηγορικές μεταβλητές. Ξεχωρίζει επειδή μπορεί να επεξεργάζεται κατηγορικά δεδομένα χωρίς εκτεταμένο preprocessing, χρησιμοποιώντας τεχνικές όπως ordered boosting και target statistics ώστε να μειώνει το overfitting και το prediction shift. Ο αλγόριθμος εκπαιδεύει διαδοχικά πολλά μικρά δέντρα αποφάσεων, όπου κάθε νέο δέντρο διορθώνει τα λάθη των προηγούμενων, επιτυγχάνοντας υψηλή ακρίβεια σε tasks ταξινόμησης, παλινδρόμησης και ranking. Σε περιπτώσεις όπως έχουμε και στο Breast Cancer θα μπορούσε να χρησιμοποιηθεί για καλύτερη απόδοση.

Η εργασία για breast cancer detection με explainable AI δηλαδή η εργασία “Detection of breast cancer using machine learning and explainable artificial intelligence” δίνει ιδιαίτερη έμφαση σε explainability μέσω SHAP, LIME, Anchor και QLattice. Ένα πολύ σημαντικό extension αυτής της ιδέας είναι το Grad-CAM. Το Grad-CAM χρησιμοποιείται κυρίως σε CNN-based medical imaging και δημιουργεί heatmaps που δείχνουν ποιες περιοχές της εικόνας επηρέασαν περισσότερο την απόφαση του μοντέλου. Σε αντίθεση με το SHAP που λειτουργεί κυρίως σε tabular explainability, το Grad-CAM προσφέρει οπτική εξήγηση πάνω στην ίδια την ιατρική εικόνα. Αυτό είναι εξαιρετικά χρήσιμο για radiologists και clinicians επειδή μπορούν να δουν αν το μοντέλο “κοιτάζει” πραγματικά την περιοχή του όγκου.

Άλλη μία ιδιαίτερα σημαντική και σύγχρονη επέκταση της εργασίας θα μπορούσε να είναι η ενσωμάτωση self-supervised learning μέσω της μεθόδου SimCLR [30] σε συνδυασμό με explainable AI χρησιμοποιώντας Integrated Gradients [31] το οποίο βασίζεται για explainable AI σε deep learning μοντέλα. Η τεχνική δημιουργεί attribution maps που δείχνουν ποια pixels ή features συνέβαλαν περισσότερο στην τελική πρόβλεψη του μοντέλου, κάτι ιδιαίτερα σημαντικό για explainable breast cancer diagnosis. Η υπάρχουσα εργασία βασίζεται κυρίως σε classical machine learning models όπως Random Forest, ensemble classifiers και XAI τεχνικές όπως SHAP, LIME, Anchor και Eli5 για explainability.



Εικόνα 17: Grad-CAM heatmaps πάνω σε mammography images, όπου φαίνεται ποιες περιοχές επηρέασαν την πρόβλεψη του μοντέλου για breast cancer για τεχνική Integrated Gradients

Ωστόσο, το dataset που χρησιμοποιείται είναι σχετικά μικρό, αφού περιλαμβάνει μόνο 213 ασθενείς, γεγονός που περιορίζει τη δυνατότητα γενίκευσης των μοντέλων. Το SimCLR μπορεί να αντιμετωπίσει αυτό το πρόβλημα μέσω self-supervised pretraining σε μεγάλες ποσότητες unlabeled mammography ή histopathology εικόνων. Η μέθοδος λειτουργεί δημιουργώντας διαφορετικά augmentations της ίδιας ιατρικής εικόνας, όπως rotation, cropping, contrast αλλαγές και Gaussian noise, και εκπαιδεύει το μοντέλο ώστε να αναγνωρίζει ότι αυτές οι εικόνες προέρχονται από το ίδιο δείγμα. Με αυτόν τον τρόπο το μοντέλο μαθαίνει ισχυρά representations των cancer patterns χωρίς να απαιτούνται χιλιάδες annotated δεδομένα, κάτι ιδιαίτερα σημαντικό στο medical AI λόγω κόστους και privacy περιορισμών.

Στη συνέχεια, το pretrained μοντέλο θα μπορούσε να γίνει fine-tuning για classification benign και malignant tumors χρησιμοποιώντας CNN architectures. Για explainability, αντί των κλασικών tabular explainability methods, θα μπορούσε να χρησιμοποιηθεί το Integrated Gradients, το οποίο δημιουργεί pixel-level attribution maps πάνω στις mammography εικόνες.

Αυτό σημαίνει ότι ο γιατρός θα μπορεί να βλέπει ακριβώς ποιες περιοχές της εικόνας οδήγησαν το μοντέλο στην πρόβλεψη malignant tumor, όπως irregular tumor borders ή suspicious calcifications. Έτσι, η εργασία θα εξελισσόταν από ένα παραδοσιακό ML + XAI framework σε ένα σύγχρονο explainable deep learning σύστημα με μεγαλύτερη ακρίβεια, καλύτερη generalization ability και σημαντικά αυξημένη κλινική αξιοπιστία.

5 Σύνοψη και Συμπεράσματα

5.1 Σύνοψη

Η παρούσα εργασία εξετάζει την ενσωμάτωση του AI, Deep Learning και του XAI στην ογκολογία, με έμφαση στην έγκαιρη ανίχνευση και διάγνωση μορφών καρκίνου όπως του στόματος και του μαστού. Λαμβάνοντας υπόψη τους περιορισμούς των παραδοσιακών μεθόδων (βιοψίες, χειροκίνητη οπτική εξέταση), οι οποίες είναι χρονοβόρες και επιρρεπείς στο ανθρώπινο σφάλμα η μελέτη προτείνει μια ολοκληρωμένη υπολογιστική ροή εργασίας.

Μέσω μιας συστηματικής ανασκόπησης, αναλύονται τεχνικές προεπεξεργασίας δεδομένων όπως η κανονικοποίηση min-max η οποία βελτιώνει την ακρίβεια των μοντέλων έως και το 94% αποτρέποντας τη μεροληψία. Για την απομόνωση και ταξινόμηση των ύποπτων περιοχών εξετάζονται προηγμένοι αλγόριθμοι, όπως τα CNNs, SVM, τα ANNs, τα Random Forests και μοντέλα Gradient Boosting (XGBoost, CatBoost).

Παράλληλα, εισάγεται η Θεωρία Χώρου-Κλίμακας και ο αλγόριθμος GLCM για τον εντοπισμό πολύ μικρών όγκων μεταβλητού μεγέθους μέσω ανάλυσης υφής. Τέλος, για την αντιμετώπιση του προβλήματος του black box των δικτύων, η εργασία ενσωματώνει εργαλεία Explainable AI (SHAP, LIME, Eli5, Anchor) που αποσαφηνίζουν τα κριτήρια λήψης αποφάσεων των μοντέλων.

5.2 Συμπεράσματα

Τα υπολογιστικά συστήματα Υπολογιστικής Υποβοηθούμενης Διάγνωσης (CAD) επιδεικνύουν σαφή υπεροχή έναντι των συμβατικών μεθόδων, καθώς εντοπίζουν μικροσκοπικά χαρακτηριστικά ιστών που το ανθρώπινο μάτι αδυνατεί να διακρίνει,

μειώνοντας δραματικά το διαγνωστικό σφάλμα. Η μελέτη αναδεικνύει ότι η ποιότητα και η σωστή προετοιμασία των ιατρικών εικόνων (καθαρισμός θορύβου, κανονικοποίηση) είναι εξίσου κρίσιμη με την αρχιτεκτονική του ίδιου του αλγορίθμου για τη μεγιστοποίηση της προβλεπτικής ικανότητας.

Επιπλέον, η χρήση stacked ensemble μοντέλων (συνδυασμός πολλών αλγορίθμων) προσφέρει πιο σταθερές, σχολαστικές και αξιόπιστες προβλέψεις σε σχέση με μεμονωμένους αλγορίθμους. Η επιτυχής ενσωμάτωση του AI στην καθημερινή κλινική πράξη δεν εξαρτάται μόνο από την υψηλή ακρίβεια, αλλά και από τη διαφάνεια. Τα εργαλεία XAI όπως το SHAP μετατρέπουν τα σύνθετα μαθηματικά μοντέλα σε κατανοητά εργαλεία για τους γιατρούς, χτίζοντας την απαραίτητη εμπιστοσύνη για τη λήψη κρίσιμων κλινικών αποφάσεων.

Τέλος, ο απώτερος σκοπός αυτών των τεχνολογιών δεν είναι η αντικατάσταση του ιατρικού προσωπικού αλλά ο εξοπλισμός του με πανίσχυρα ψηφιακά εργαλεία. Στόχος παραμένει ο εκδημοκρατισμός της υψηλής ποιότητας υγείας επιτρέποντας την έγκαιρη και ακριβή διάγνωση του καρκίνου ακόμη και σε απομακρυσμένες περιοχές με περιορισμένους πόρους. Κάθε μέρα ουσιαστικά προσπαθούμε να βελτιώσουμε την ανθρώπινη δύναμη σε κάθε κλάδο της επιστήμης με διάφορες τεχνολογίες βασίζοντας και πάλι στην επιστήμη για πιο αποδοτικά αποτελέσματα αλλά και χωρίς σφάλματα.

6 Βιβλιογραφία

- [1] Arravalli, T., et al., "Detection of breast cancer using machine learning and explainable artificial intelligence", *Scientific Reports*, 2025.
- [2] Ahmad, I. & Alqurashi, F., "Early cancer detection using deep learning and medical imaging: A survey", *Critical Reviews in Oncology/Hematology*, 2024.
- [3] Patel, S. & Kumar, D., "Predictive identification of oral cancer using AI and machine learning", *Oral Oncology Reports*, 2025.
- [4] Poongodi, P., et al., "An Innovative Machine Learning Approach to Diagnose Cancer at an Early Stage", *Data Analytics in Bioinformatics*, 2021.
- [5] Bray, F., et al., "Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries", *CA: A Cancer Journal for Clinicians*, 2024.
- [6] Prabhu, S., et al., "AI-based carcinoma detection and classification using histopathological images: A systematic review", *Computers in Biology and Medicine*, 2022.
- [7] Siegel, R. L., et al., "Cancer statistics, 2024", *CA: A Cancer Journal for Clinicians*, 2024.
- [8] Rai, H. M., "Cancer detection and segmentation using machine learning and deep learning techniques: a review", *Multimedia Tools and Applications*, 2024.
- [9] Yaqoob, A., et al., "Applications and Techniques of Machine Learning in Cancer Classification: A Systematic Review", *Journal of Data Intelligence (ή Volume 3)*, 2023.
- [10] Yaqoob, A., et al., "A Review on Nature-Inspired Algorithms for Cancer Disease Prediction and Classification", *Mathematics*, 2023.

- [11] Sharma, P., et al., "A survey on cancer detection via convolutional neural networks: Current challenges and future directions", *Neural Networks*, 2024.
- [12] Haj-Hosseini N, Lindblad J, Hass ´eus B, et al. Early detection of oral potentially malignant disorders: a review on prospective screening methods with regard to global challenges. *J Maxillofac Oral Surg* 2024;23:23–32.
- [13] Raval D, Undavia JN. A comprehensive assessment of convolutional neural networks for skin and oral cancer detection using medical images. *Healthc Anal* 2023;3:100199. <https://doi.org/10.1016/j.health.2023.100199>
- [14] Singh D, Singh B. Investigating the impact of data normalization on classification performance. *Appl Soft Comput* 2020;97(Part B):105524.
- [15] Zhang, M., Wu, T., Bennett, K.M., Small Cancer Identification in Medical Images Using Regional Features from Optimum Scale. *IEEE Trans. Biomed. Eng.*, 1051–1062, April 2015.
- [16] ter Haar Romeny, B. M., "Scale-Space Theory for Multiscale Geometric Image Analysis," Utrecht University, 2004.
- [17] Kourou, K. et al., Machine learning applications in cancer prognosis and prediction. *Comput. Struct. Biotechnol. J.*, 13, 8–17, 2015.
- [18] Masood, A., Al-Jumaily, A.A., Adnan, T., Development of Automated Diagnostic System for Skin Cancer: Performance Analysis of Neural Network Learning Algorithms for Classification, in: *Artificial Neural Networks and Machine Learning—ICANN 2014*. ICANN 2014. Lecture Notes in Computer Science, vol. 8681, S. Wermter et al. (Ed.), Springer, Cham, 2014.
- [19] Oztekin, P. S. et al. Comparison of explainable artificial intelligence model and radiologist review performances to detect breast Cancer in 752 patients. *J. Ultrasound Med.* (2024).
- [20] Munshi, R. M. et al. A novel approach for breast cancer detection using optimized ensemble learning framework and XAI. *Image Vis. Comput.* 142, 104910 (2024).
- [21] Islam, T. et al. Predictive modeling for breast cancer classification in the context of Bangladeshi patients by use of machine learning approach with explainable AI. *Sci. Rep.* 14 (1), 8487 (2024).
- [22] Ronneberger, O., Fischer, P., Brox, T., 2015. U-net: Convolutional networks for biomedical image segmentation. *Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III* 18. Springer, pp. 234–241.
- [23] Müller, D., et al., "Robust chest CT image segmentation of COVID-19 lung infection based on limited data", *Informatics in Medicine Unlocked*, 2021.
- [24] Chen, J., et al., "TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation", *arXiv preprint*, 2021.
- [25] Cao, H., et al., "Swin-Unet: Unet-like Pure Transformer for Medical Image Segmentation", *arXiv preprint*, 2021.

- [26] Dosovitskiy, A., et al., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", *arXiv preprint*, 2020.
- [27] Chen, T., & Guestrin, C., "XGBoost: A Scalable Tree Boosting System", *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [28] Ke, G., et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree", *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [29] Prokhorenkova, L., et al., "CatBoost: unbiased boosting with categorical features", *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [30] Chen, T., et al., "A Simple Framework for Contrastive Learning of Visual Representations", *International Conference on Machine Learning (ICML)*, 2020.
- [31] Sundararajan, M., Taly, A., & Yan, Q., "Axiomatic Attribution for Deep Networks", *Proceedings of the 34th International Conference on Machine Learning (ICML)*, 2017.